

基于Sentinel-2和3D多源域自注意力模型的湿地分类

楼桉君¹, 贺智^{1,2}, 肖曼¹, 李心媛¹

1. 中山大学 地理科学与规划学院, 广州 510275;
2. 南方海洋科学与工程广东省实验室(珠海), 珠海 519082

摘要: 准确的湿地分类可掌握湿地时空分异特征, 在湿地研究中占据重要地位。针对现有基于小样本学习的湿地分类方法仅局限于利用目标域或单源域数据的问题, 本文提出一种3D多源域自注意力小样本学习模型3D-MDAFSL (3D Multi-source Domain self-Attention Few-Shot Learning)。首先, 结合卷积和注意力机制的优势, 设计基于自注意力机制和深度残差卷积的3D特征提取器; 然后, 采用对抗域自适应策略实现多源域特征对齐, 在每个域分别进行小样本学习; 最后, 利用训练好的模型提取特征, 并将特征输入至K近邻(K-nearest Neighbor)分类器以获取分类结果。结果表明, 3D特征提取器相比无特征提取框架的湿地总体分类精度提升约6.79%; 当使用多源域数据集时, 3D-MDAFSL模型对中山市Sentinel-2湿地数据集的总体分类精度能达到93.52%, 相比于现有算法有明显提升。本文所提出的3D-MDAFSL模型在湿地地物高精度提取和分类中有较好的应用价值。

关键词: 遥感, 小样本, 湿地分类, 多源域, 自注意力

中图分类号: TP701/P2

引用格式: 楼桉君, 贺智, 肖曼, 李心媛. 2024. 基于Sentinel-2和3D多源域自注意力模型的湿地分类. 遥感学报, 28(1): 266-279
Lou A J, He Z, Xiao M and Li X Y. 2024. Wetland classification based on Sentinel-2 and 3D multisource domain self-attention model. National Remote Sensing Bulletin, 28(1): 266-279 [DOI: 10.11834/jrs.20232246]

1 引言

湿地是重要碳库, 对实现碳达峰碳中和目标、推进区域可持续发展具有重要意义。湿地覆被类型复杂, 特征相似, 存在“同物异谱”和“同谱异物”现象(莫利江等, 2012), 季节性植被动态、水文波动和人类活动等影响也增加了湿地遥感分类的难度。

湿地遥感分类方法包括人工目视解译和计算机自动分类法(孟祥锐, 2019)。人工目视解译法精度高, 但主观性强、分类效率低(张康永, 2019)。在计算机自动分类法中, 决策树(Guo等, 2021)、支持向量机SVM (Support Vector Machine) (Gxokwe等, 2022)、随机森林(宁晓刚等, 2022)等监督分类方法, 能够对多尺度和多源数据进行自动优化学习, 实现大范围的湿地制图。

但由于制图精度和制图效率要求进一步提高, 新的湿地分类方法也被不断地开发。

近年来, 深度学习在湿地遥感自动化分类中被广泛关注(龚健雅和季顺平, 2017)。Stahl和Weimann (2022) 基于卷积神经网络CNN (Convolutional Neural Network) 对历史地图数据提取湿地信息。Fu等(2021)利用SegNet和无人机数据对岩溶湿地植被进行分类。Hu等(2021)基于无监督学习、多尺度CNN和注意力机制进行湿地覆盖图绘制。这些基于深度学习的方法有效提升了分类精度, 但需要大量湿地标记数据, 可迁移性有待提高(刘玮, 2020)。

湿地遥感影像地物复杂、标记困难, 如何在有限标记样本情况下训练一个较好的分类模型是目前研究的难点。小样本学习方法能解决这一困境, 该方法从有足够标记数据的源域中学习信息、

收稿日期: 2022-05-13; 预印本: 2023-01-13

基金项目: 国家重点研发计划(编号: 2020YFA0714103); 国家自然科学基金面上项目(编号: 42271325); 南方海洋科学与工程广东省实验室(珠海)创新团队建设项目(编号: 311021018); 广东省自然科学基金面上项目(编号: 2019A1515011877); 广州市科技计划(编号: 202002030240); 国防基础科研计划(编号: WDZC20205500205)

第一作者简介: 楼桉君, 研究方向为湿地遥感。E-mail: louanj@mail2.sysu.edu.cn

通信作者简介: 贺智, 研究方向为高分/高光谱遥感、模式识别和深度学习等。E-mail: Hezh8@mail.sysu.edu.cn

训练模型, 实现对仅有少量标记数据的目标域的推理。典型的小样本方法包括基于神经网络和 SVM 的深度小样本学习 DFSL (Deep Few-Shot Learning) (Liu 等, 2019)、空谱关系网络 SS-RN (Spatial-Spectral Relation Network) (Rao 等, 2019) 和深度关系网络 (Deep Relation Network) (Gao 等, 2020) 等。由于源域数据和目标域数据来自分布不同的域, 存在严重的域转移误差。为实现跨域学习任务, 学者们提出多种方法, 大致可以分为基于域自适应 (Deng 等, 2018; Othman 等, 2017; Wang 等, 2019; Yang 和 Crawford, 2016) 和基于微调的方法 (Jiao 等, 2017; Mei 等, 2017; Yang 等, 2017)。上述方法主要涉及单源域的域自适应算法, 可能导致次优解 (Shen 等, 2018)。有学者提出了多源域自适应的算法, 例如多源蒸馏域自适应 MDDA (Multi-source Distilling Domain Adaptation) 方法 (Zhao 等, 2020) 以及多源域适应和标签统一 mDALU (Multi-source Domain Adaptation and Label Unification) 方法 (Gong 等, 2021)。多源域自适应算法可充分利用现有遥感影像标记样本库, 同时能解决源域和目标域影像由于传感器、成像时间、成像地点的不同而特征分布差异较大的问题 (Tuia 等, 2016)。目前多源域自适应的方法尚未涉及湿地遥感分类, 湿地遥感影像训练样本量少, 同时特征分布差异更明显, 因此利用多场景源域影像和多源域自适应算法来提取高精度的湿地信息具有可行性。

卷积网络作为常用的特征提取器, 通过卷积运算来获取图像有效的局部信息, 不同深度的卷积层可以提取不同的特征 (Wang 等, 2017)。堆叠多层网络可以获取缺失的全局特征 (Simonyan 和 Zisserman, 2015), 但容易造成过拟合。相比之下, 利用注意力机制建立局部信息之间的关系来获取全局特征是一种更好的选择 (顾勇翔 等, 2023)。Transformer (Vaswani 等, 2017) 在自然语言处理时能够充分利用上下文关系, 通过编码器-解码器构架 (Bahdanau 等, 2014; Cho 等, 2014; Sutskever 等, 2014) 以及自注意力机制进行并行训练。在计算机视觉领域, Vision Transformer (Dosovitskiy 等, 2021) 表明, 仅使用 1 层 Transformer 就可以在 ImageNet-1K (Deng 等, 2009) 上获得较好的效果。将 Transformer 应用于高分辨率湿地遥感影像分类, 可充分利用相邻湿地地物之间的空间关系,

获取全局信息, 得到更强有力的特征 (Cao 等, 2021)。但遥感影像尺寸较大, 直接使用自注意力部分代替卷积, 会提高时间复杂度 (Chen 等, 2021)。因此, 本文先利用卷积网络获取图像局部特征, 再通过 Transformer 模型增强对图像全局特征的提取能力。

为解决小样本湿地分类中可能存在多场景分布的源域以及提取特征缺失全局信息的问题, 本文提出基于 3D 多源域自注意力的小样本学习模型 3D-MDAFSL (3D Multi-source Domain self-Attention Few-Shot Learning) (图 1)。以 Chikusei 高光谱数据集, 东莞—广州、江门—佛山部分区域 Sentinel-2 数据为源域数据集, 以中山市部分区域 Sentinel-2 数据为目标域数据集, 进行多源域小样本湿地分类。

2 研究方法

2.1 3D-MDAFSL 框架

3D-MDAFSL 框架包括源域小样本学习和目标域小样本学习。模型的训练过程如图 2 所示, 共有 N 个源域数据集, 1 个目标域数据集。在目标域数据集中每类分别选取了 1—10 个标记样本, 并通过加入随机高斯噪声等方式将每类样本增广至 200 个, 作为目标域小样本学习的支持集, 剩余的样本作为目标域未标记的查询集用于检验模型精度。而源域则随机选取 200 个标记样本作为源域小样本学习的支持集, 剩余作为源域查询集。每个域支持集和查询集样本不重合。小样本学习在每一源域和目标域中交替执行, 不仅可以发现源域中可迁移的元知识 (例如地物内在的纹理规律、光谱规律、空间结构规律等), 还可以学习到目标域的特征信息。

训练阶段流程如图 1 所示, 每一组小样本学习可分为 4 个步骤: (1) 利用由 2D 卷积构成的映射层 $M^s (n = 1, 2, 3, \dots, N)$ 和 M^t 分别对每一源域和目标域的数据进行变换, 提取相同维数的特征输入模型。(2) 利用特定域特征提取器 $F^s (n = 1, 2, 3, \dots, N)$ 和 F^t 将源域和目标域特征嵌入到光谱空间中, 以提升类内紧凑性和类间可分离性。(3) 通过计算未标记和已标记特征之间的欧氏距离来执行小样本学习。(4) 为了减小域转移所造成的误差, 对每一源域和目标域提取的特征

采用有条件的对抗域自适应策略, 实现域分布对齐, 使提取的空谱特征具有域不变性。因此具有域自适应的源域小样本学习损失函数为

$$L_{S_n} = L_{\text{fsl}}^{S_n} + L_{d_n} \quad (n = 1, 2, 3, \dots, N) \quad (1)$$

式中, L_{S_n} 为第 n 个源域的总损失, $L_{\text{fsl}}^{S_n}$ 为第 n 个源域小样本学习损失, L_{d_n} 为第 n 个源域的域转移损失。




图1 训练阶段的3D多源域自注意力小样本学习框架

Fig. 1 3D Multi-source domain self-attention few-shot learning framework during the training phase




图2 模型训练和测试过程

Fig. 2 Training and testing process of the model

类似地, 具有域自适应的目标域小样本学习损失函数为

$$L_T = L_{\text{fsl}}^T + L_{d_1} \quad (2)$$

式中, L_T 为目标域损失, L_{fsl}^T 为目标域小样本学习损失, L_{d_1} 为目标域与第一个源域的域转移损失。

最后, 多源域小样本模型的总损失函数为

$$L_n = L_{S_n} + L_T \quad (n = 1, 2, 3, \dots, N) \quad (3)$$

式中, L_n 为第 n 组源域和目标域的总损失。

测试阶段流程如图2所示, 首先, 利用映射层 M^T 对目标域数据进行特征提取; 其次, 通过训练好的3D特征提取器 F 将特征映射至光谱空间维度; 最后, 利用K近邻 (K-nearest Neighbor) 分类器对未标记样本进行分类。

在阐述完模型训练和测试流程后, 下面将重点对框架中的特定域特征提取器及特定域鉴别器进行详细介绍。

2.2 特定域特征提取器

特定域特征提取器 F 的作用是将映射层输出特征映射到光谱空间中。为进一步提高模型精度, 本文基于Transformer编码器与深度残差卷积设计了一个3D光谱-空间提取网络, 分别对每一源域与目标域的输入特征进行空谱联合映射。特定域特征提取器由一个深度残差3D卷积块、一个Transformer块、一个3D卷积层和两个Max pooling层组成, 网络结构和部分参数见图3。其中, 深度残差3D卷积块包括3个3D卷积 (步长为1, 卷积核大小为3, 填充大小为1), 3个归一化层, 以及3个激活层, 激活层采用Swish函数。该模块使用残差连接的方式来缓解梯度消失问题, 使原有特征得以保留。

Transformer块由多个Transformer层组成, 每层Transformer包括一个3D卷积 (步长为1, 卷积核大小为1)、多头自注意力机制和前馈神经网络。其中, 3D卷积与多头自注意力机制、多头自注意

力机制与前馈神经网络之间均使用残差连接。多头自注意力机制采用了全局感受域，而 3D 卷积的计算主要集中于局部区域，前者的计算量较大。

为此，本文在第一层 Transformer 中利用 Max pooling 来降低计算量。




图3 特定域特征提取器
Fig. 3 Domain-specific feature extractor

本文将采用调换卷积模块与Transformer模块位置、仅保留其中一个模块、仅在卷积网络中加入SimAM注意力模块 (Yang 等, 2021)、直接使用CoatNet (Dai 等, 2021) 作为特征提取器的方式来验证 3D 特征提取器 F 结构的有效性。其中 SimAM 是一种新的 3D 注意力模块，不同于现有的通道注意力模块，该模块无需额外参数，只是设计了一种能量函数为特征图推导出 3D 注意力权值，可以嵌入到现有的卷积网络中。而 CoatNet 是以有原则的方式垂直堆叠卷积层和注意力层的混合模型，在不

同数据集大小以及不同资源约束下均达到了最佳，在数据有限的情况下也表现出很高的精度。

2.3 特定域鉴别器

本文采用有条件的对抗域自适应策略对每一源域和目标域特征分布进行对齐。域鉴别器 D (图4) 的作用是判断样本属于源域还是目标域， D 由 5 个全连接层组成，除最后一层外，每一个全连接层后接一个 ReLU 激活层和 Dropout 层，最后利用 Softmax 函数判断输入特征属于源域还是目标域。




图4 特定域鉴别器
Fig. 4 Domain-specific discriminator

在特定域鉴别器上定义域对抗损失函数 $L_{d_n}(n = 1, 2, 3, \dots, N)$ 。

$$\min_D \max_{F, G} L_{d_n} = -E_{x_i^S \sim P_{S_n(x)}} \log(D(f_i^S, g_i^S)) - E_{x_j^T \sim P_{T(x)}} \log(1 - D(f_j^T, g_j^T)) \quad (4)$$

式中, $P_{S_n(x)}$ 是第 n 个源域的分布, $P_{T(x)}$ 是目标域的分布。 f_i^S 为第 n 个源域的第 i 个特征, f_j^T 为目标域的第 j 个特征。 g 为对抗域自适应的判别信息, 定义为 0 或 1, g_i^S 为第 n 个源域的第 i 个判别信息, g_j^T 为目标域的第 j 个判别信息。 $D(\cdot)$ 是域鉴别器判断 x 属于第 n 个源域样本的概率, $1 - D(\cdot)$ 是域鉴别器判断 x 属于目标域样本的概率。

3 数据结果处理与分析

3.1 实验数据

本文共使用了 4 个数据集, 包括 Chikusei 高光谱数据集, 以及 3 个自制的 Sentinel-2 S2MSI2A 级数据集, 均选自粤港澳大湾区内湿地类型较为丰富的区域, 分别为东莞—广州部分区域数据集、江门—佛山部分区域数据集以及中山市部分区域数据集, 空间分辨率为 10 m, 由 9 个光谱波段组成, 成像时间为 2020 年 10 月 26 日, 其中前两者作为补充的源域数据集, 中山市部分区域数据集用作本文的目标域数据集。

(1) 源域标准数据集。现有的遥感分类标准数据集大多为高光谱数据集, 本文选择 Chikusei 高光谱数据集作为标准源域数据集, 该数据集于 2014 年 7 月 29 日在日本茨城县 Chikusei 使用高光谱可见光/近红外相机采集。它包含 19 个类, 共 2517 像素×2335 个像素, 空间分辨率为 2.5 m, 由 128 个光谱波段组成, 波段范围为 363—1018 nm。

(2) 源域数据集 1。源域数据集 1 为东莞—广州部分区域的 Sentinel-2 S2MSI2A 级数据, 共 3108×3970 个像素, 主要包括海鸥岛红树林湿地公园、东莞水道、大岭山森林公园、同沙生态公园、水濂山森林公园等地。

(3) 源域数据集 2。源域数据集 2 为江门—佛山部分区域的 Sentinel-2 S2MSI2A 级数据, 共 1561×1647 个像素, 主要包括西江、大雁山、华侨城古劳水乡、南海湾森林生态园、龙江大金山森林公园等地。

(4) 目标域数据集。目标域数据集为中山市

部分区域的 Sentinel-2 S2MSI2A 级数据, 共 1349×1517 个像素, 主要包括横门水道、翠湖公园、广东中山翠亨国家湿地公园、象棚山等地。




图 5 Chikusei 数据集

Fig. 5 Chikusei dataset




图 6 东莞—广州部分区域数据集

Fig. 6 Dongguan-Guangzhou partial regional dataset




图 7 江门—佛山部分区域数据集

Fig. 7 Jiangmen-Foshan partial regional dataset




图8 中山市部分区域数据集
Fig. 8 Dataset of some areas of Zhongshan City

3个自制的湿地数据集参照《全国湿地资源调查与监测技术规程（试行）（林湿发〔2008〕265号）》和研究区真实地表情况，将研究区地表分非湿地、自然湿地和人工湿地3大类共9小类，具体分类情况及每类样本的数量如表1所示。

表1 湿地分类情况及样本数				
Table 1 Wetland classification system and sample size				
一级分类	二级分类	目标域数据集	源域数据集1	源域数据集2
非湿地	林地	53754	126784	53853
	建设用地	19809	30768	13947
	裸地	19600	3971	5053
自然湿地	河流	70783	83155	102697
	湖泊	—	93162	5317
	沼泽	5263	3351	5517
	滩涂	2246	685	965
人工湿地	库塘	8787	17842	2345
	盐田	14929	4408	3588

3.2 实验设置

本文选择 PyTorch 深度学习框架，共训练 1200 个 Epoch，学习率为 0.001。分类性能通过总体精度 OA（Overall Accuracy）、平均精度 AA（Average Accuracy）、Kappa 系数、用户精度 UA（User’s Accuracy）以及制图精度 PA（Producer’s Accuracy）进行评价。为保证公平性，本文所有实验的输入特征为遥感影像的空谱联合信息，每组实验重复 10 次，保留均值结果和标准差。

为了验证 3D-MDAFSL 模型性能，本文选取了六种监督分类的方法进行对比，分别为 SVM、随机森林、3DCSN（3D Convolutional Siamese Network）

（Cao 等，2020）、CNN-HSI（Convolutional Neural Networks for Hyperspectral Image）（Yu 等，2017）、DCFSL+SVM（Deep Cross-domain Few-Shot Learning+SVM Classifier）（Li 等，2022）、DCFSL+KNN（Deep Cross-domain Few-Shot Learning + KNN Classifier）（Li 等，2022）。其中，SVM 和随机森林的算法可作为传统机器学习分类方法的代表；3DCSN 和 CNN-HIS 算法是仅有目标域的小样本分类算法；DCFSL+SVM 和 DCFSL+KNN 是两种跨域的小样本分类算法。此外，本文针对特征提取器和源域通道数设置了两组消融实验：将特征提取器进行更改或者删去以验证本文设计的 3D 特征提取器的性能，更改输入源域的通道数以验证多源域通道的效果。

3.3 不同分类方法的对比实验

本文选择了 6 种监督分类方法，因这 6 种方法或没有源域数据或仅有一组源域数据，为保证实验公平性，选取单一源域通道的 3D-MDAFSL 模型进行比较。不同方法的分类结果如表 2 和图 9，10，11 所示。

从图 9 的实验结果可看出：（1）随着目标域标记样本数目的增加，跨域的方法在湿地小样本数据集中表现更稳定。DCFSL+SVM、DCFSL+KNN 和 3D-MDAFSL 在标记样本数极少时也能获得高于 83% 的精度，其他方法则明显受训练样本数制约。（2）单源域通道的 3D-MDAFSL 相比于其他方法可以得到最优的分类效果，在小样本的情况下提取出更高精度的湿地信息。就图 9 总体趋势而言，基于深度学习网络的小样本学习方法 3DCSN 和 CNN-HSI 要优于传统的机器学习模型，而跨域的小样本学习方法 DCFSL+SVM 和 DCFSL+KNN 相比于只有目标域数据作为训练集的 3DCSN 和 CNN-HSI 算法分类精度更佳。

实验结果充分验证了 3D-MDAFSL 模型在小样本分类中的优势，在少量训练样本的情况下，均能获得理想的分类结果，其在目标域湿地数据集中的稳定性和精度均要高于其他模型，具有较高的应用价值。但由于引入注意力机制，3D-MDAFSL 模型的时间复杂度增加，计算效率相对降低。

如表 2 所示，当目标域数据集中每类地物只含 5 个标记样本时，3D-MDAFSL 的总体分类结果明显优于其他方法，且标准差较低，模型性能稳定。相比于传统机器学习 SVM 和随机森林方法，OA 分别

提高了14.52%和14.50%，相比于3DCSN和CNN-HIS则提高了4.95%和6.40%，与跨域的DCFSL+SVM和DCFSL+KNN相比，3D-MDAFSL的OA提

高了2.40%和4.31%。这说明相比于其他模型，3D-MDAFSL在实际应用中能取得较优的效果，更适合用于本文湿地数据集的分类。

表2 目标域数据集分类结果(每类5个标记样本)

Table 2 The target domain dataset classification results (Five labeled samples per class)

参量	SVM	RF	3DCSN	CNN-HSI	DCFSL+SVM	DCFSL+KNN	3D-MDAFSL
OA	78.82±2.73	78.84±2.30	86.01±2.41	84.84±3.19	88.15±2.11	86.54±2.32	90.27±1.66
AA	70.24±3.54	72.47±2.26	76.48±3.07	70.09±5.90	79.24±3.17	78.88±2.97	82.09±3.58
Kappa	0.7253±0.03	0.7309±0.03	0.8189±0.03	0.8018±0.04	0.8458±0.03	0.8257±0.03	0.8727±0.03
训练时间/s	1.02	0.31	61.31	77.01	148.36	162.70	208.44
测试时间/s	7.27	8.10	30.16	37.09	23.87	39.38	58.61

注:粗体表示最优精度。




图9 不同方法分类精度及kappa系数随标记样本数量变化图

Fig. 9 Variation of classification accuracy and kappa coefficient of different methods with the number of labeled samples

就各类地物的分类精度而言，3D-MDAFSL模型在各类地物的表现均衡，UA和PA综合较高。其他方法均有明显的错分漏分现象，UA和PA值差异较大。例如在提取建设用地时，SVM、随机森林、DCFSL+SVM以及DCFSL+KNN有显著的错分现象，在沼泽和滩涂用地中CNN-HSI、3DCSN方法漏分明显。3D-MDAFSL能较为准确且均衡地对各类别进行分类，在林地、河流、沼泽等水体和植被的信息提取中占据优势，适合用于湿地分类和信息提取。

3.4 消融实验

3.4.1 3D特征提取器的对比实验

为验证本文提出的3D特征提取器 F 的有效性，设计了6组对照实验，将 F 分别与2个深度残差3D卷积块(2-3D Res)、加入SimAM模块的深度残差3D卷积网络(3D Res-SimMA)、Transformer块和

深度残差3D卷积块调换位置(Transformer-3D Res)、直接使用Transformer编码器、直接使用CoatNet作为特征提取器以及无特征提取器的单源域小样本分类模型进行比较。

图12的实验结果表明：(1)相比于无特征提取器的框架，分类精度提升约6.79%，最高总体精度可达90.27，分类Kappa系数为0.8727。相比于仅使用深度残差3D卷积块和Transformer编码器的特征提取器，分类精度分别提高约4.31%和3.24%。这说明本文设计的3D特征提取器 F 能够提高模型分类精度，在本文的小样本多源域框架中更具优势。(2)引入注意力机制能够提升模型提取特征的能力。在深度残差3D卷积网络中加入3D注意力SimAM能优化分类结果。(3)本文的3D特征提取器 F 在各类地物上的分类表现较为均衡(表3)，UA和PA值相对较高，差异较小。由此可见本文设计的3D特征提取器 F 在提高整体分类精度的基础上，也能稳定提取各个类别的湿地信息，更具实用性。

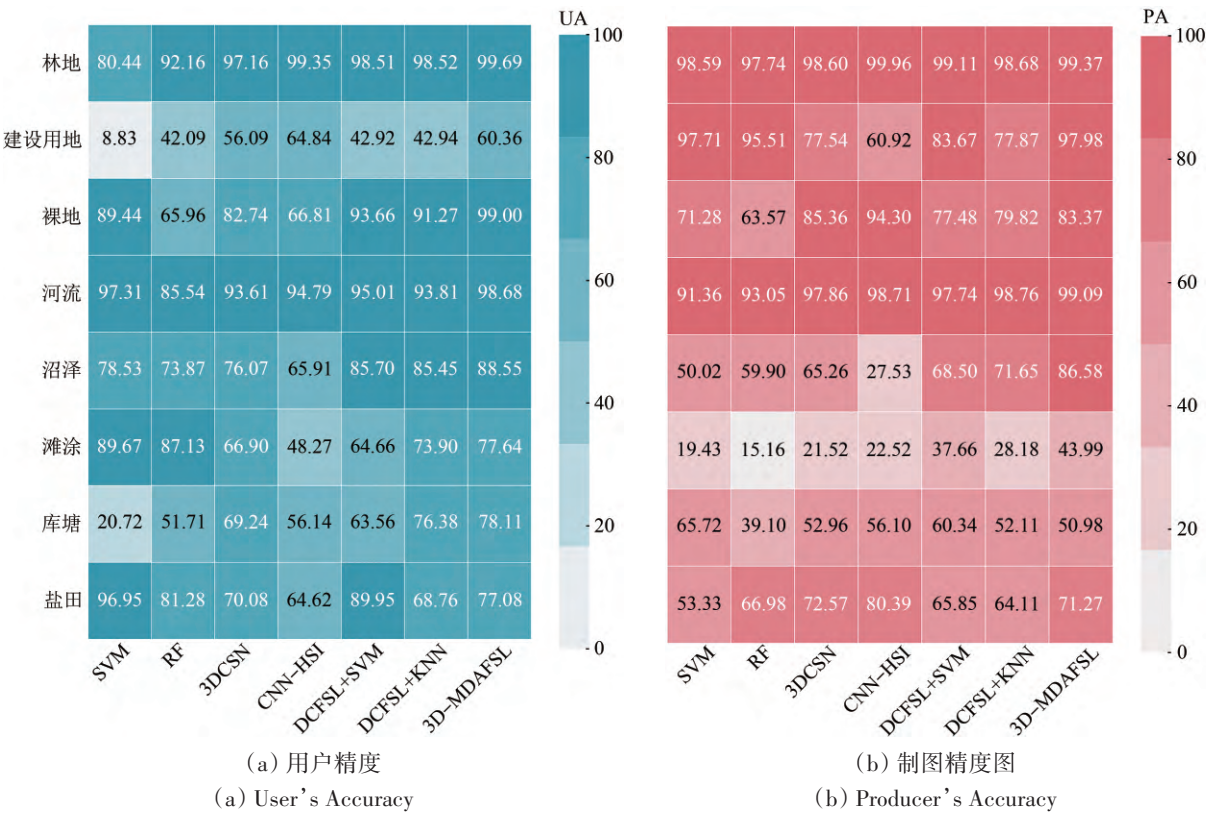


图 10 不同用地类型的用户精度和制图精度(每类 5 个标记样本)
Fig. 10 User's accuracy and producer's accuracy of different landuse types(Five labeled samples per class)




图 11 不同方法分类结果对比图(每类 5 个标记样本)
Fig. 11 Comparison chart of classification results by different methods (Five labeled samples per class)




图 12 不同特征提取器分类精度对比图(每类 5 个标记样本)
Fig. 12 Comparison chart of classification accuracy for different feature extractors (Five labeled samples per class)

表 3 不同特征提取器的用户精度和制图精度(每类 5 个标记样本)
Table 3 User's accuracy and producer's accuracy of different feature extractors (Five labeled samples per class) %

特征		非湿地			自然湿地			人工湿地	
		林地	建设用地	裸地	河流	沼泽	滩涂	库塘	盐田
F	UA	99.69	60.36	99.00	98.68	88.55	77.64	78.11	77.08
	PA	99.37	97.98	83.37	99.09	86.58	43.99	50.98	71.27
2-3D Res	UA	98.52	42.94	91.27	93.81	85.45	73.90	76.38	68.76
	PA	98.79	93.02	88.05	97.47	76.44	34.07	56.85	76.93
3D Res-SimAM	UA	99.77	38.89	90.55	98.66	76.53	84.29	39.21	90.43
	PA	99.00	92.67	90.42	98.21	80.51	36.61	54.81	74.04
Transformer-3DRes	UA	96.25	79.45	88.88	94.86	66.47	92.55	78.32	54.27
	PA	99.36	92.27	95.01	96.27	72.20	39.95	46.34	79.33
Transformer	UA	99.83	37.69	93.34	96.86	77.42	55.02	50.57	86.42
	PA	99.24	97.50	86.88	98.23	47.61	34.22	49.73	76.83
CoatNet	UA	99.70	22.45	90.53	96.25	70.12	92.10	51.33	85.26
	PA	99.81	96.89	79.07	96.90	66.85	19.48	41.73	79.63
无特征提取器	UA	97.55	27.98	91.85	94.38	78.61	78.13	67.37	69.44
	PA	98.77	83.34	69.48	97.32	63.79	24.29	53.65	73.04

注:粗体为最优值。

观察基于 Transformer 和深度残差卷积的 3D 特征提取器损失随迭代次数的变化, 1200 个 Epoch 内, 小样本学习损失、域转移损失和总损失均随迭代次数增加而收敛, 总体精度则随迭代次数增加而增加, 符合模型的训练要求。

可视化特征提取器部分层对光谱特征处理后的结果, 每层选取 9 个波段、8 个通道共 72 张特征图进行展示 (图 14), 第一层输出的特征图大小为 9×9, 第二层特征图输出大小为 5×5, 可以观察到更深层网络的特征更为抽象, 不同的通道对不同信息进行学习, 特征之间的差异增大。

3.4.2 多源域通道的对比实验

为验证多源域通道的有效性, 本文选择基于 Transformer 和深度残差卷积的 3D 特征提取器 F 作为特定域的特征提取器, 设置了 5 组对照实验, 分别为以 Chikusei 数据集作为单一源域, 以源域数据集 1 作为单一源域, 以 Chikusei 数据集和源域数据集 1 作为双源域, 以源域数据集 1 和源域数据集 2 作为双源域, 以 Chikusei 数据集、源域数据集 1 和源域数据集 2 作为三源域通道的对比实验, 实验结果如表 4 和图 15 所示。




图 13 特定域特征提取器的损失和精度随训练次数的变化

Fig. 13 The loss and accuracy of domain specific feature extractor vary with the number of epochs




图 14 特征提取器部分层可视化结果

Fig. 14 Partial layer visualization results of feature extractor

实验结果表明：（1）在源域数据集中增加与目标域数据集解译标准类似的数据集能够使分类

结果更加准确。相比只用 Chikusei 标准数据集作为单一源域的模型，添加 1 组自制的源域数据集能够使模型的分类精度提升至 91.75%，当源域数量为 3 组数据集（1 组标准数据集 + 2 组自制数据集）时，分类精度相比于单源域（1）实验约提高 3.00%。而双源域（1 + 2）实验全部选择自制的源域数据集，相比于单源域（1）分类精度提高了 3.60%。这说明多源域通道的输入能够提升分类精度，提取更加准确的湿地信息。（2）多源域通道的输入通过提升部分用地类型的分类精度优化了总体分类表现，河流、沼泽、滩涂和盐田等用地类型的分类精度都有了一定程度上的提升。

表 4 不同源域通道的对比实验(每类 5 个标记样本)

Table 4 Comparative experiments with different source domain channels (Five labeled samples per class)											
湿地类型		单源域(Chikusei)		单源域(1)		双源域 (Chikusei +1)		双源域(1 + 2)		三源域 (Chikusei +1 +2)	
		UA/%	PA/%	UA/%	PA/%	UA/%	PA/%	UA/%	PA/%	UA/%	PA/%
非湿地	林地	99.69	99.37	99.91	99.51	99.37	99.80	98.39	99.73	99.54	99.95
	建设用地	60.36	97.98	78.54	96.35	79.36	87.06	80.29	86.99	74.57	87.91
	裸地	99.00	83.37	82.43	77.02	88.96	98.29	92.57	97.67	96.33	97.48
自然湿地	河流	98.68	99.09	95.65	98.30	97.87	98.87	99.55	98.70	95.88	99.22
	沼泽	88.55	86.58	83.57	75.02	68.62	86.23	84.33	87.92	93.42	83.49
	滩涂	77.64	43.99	84.43	49.82	93.89	54.74	81.62	44.96	86.66	51.02
人工湿地	库塘	78.11	50.98	78.82	69.45	77.85	44.45	59.90	56.80	69.85	49.20
	盐田	77.08	71.27	67.32	75.91	71.41	78.22	90.95	86.59	90.06	75.83
OA/%		90.27±1.66		90.37±2.05		91.75±1.67		93.52±2.58		92.98±2.14	
AA/%		82.09±3.58		83.83±4.23		84.67±3.60		85.95±3.33		88.29±3.71	
Kappa		0.8727±0.02		0.8749±0.03		0.8924±0.02		0.9150±0.03		0.9085±0.03	
训练时间/s		208.44		206.46		274.76		272.41		301.20	
测试时间/s		58.61		63.49		58.33		59.28		59.73	

注:粗体表示最优精度。




图 15 不同源域通道分类结果对比图(每类 5 个标记样本)

Fig. 15 Comparison chart of classification results for different source domain channels (Five labeled samples per class)

4 结 论

为解决现有小样本遥感影像分类算法在地物精细分类上精度不足的问题, 本文引入自注意力机制和多源域自适应算法, 构建了 3D-MDAFSL 模型。首先通过映射层对每一源域和目标域的输入数据提取相同维数的特征, 之后利用 3D 特征提取器将特征映射到空谱维度, 并进行小样本学习, 特定域鉴别器能够使多个源域和目标域之间的特征空间分布对齐, 最后将特征输入至 K 近邻分类器得到分类结果。3D-MDAFSL 模型可实现对中山市 Sentinel-2 湿地数据集的精细分类, 当目标域标记样本数为 5 时, 单源域的 3D-MDAFSL 模型相比于传统机器学习的 SVM 和随机森林方法、小样本分类算法 3DCSN 和 CNN-HIS 以及跨域的 DCFSL+SVM 和 DCFSL+KNN, 方法, 各类地物精度更为均衡, OA、AA 和 Kappa 系数均能达到最优。

本文方法的主要优势在于: 一方面, 能满足源域多场景分布的实际情况, 使模型在目标域数据集标记样本数量较少时, 充分学习具有相似解译标准的源域数据集或者是其他标准数据集的特征信息, 提升模型的分类性能。另一方面, 基于自注意力机制和深度残差卷积构建的 3D 特征提取器能将特征映射到光谱-空间维度, 使提取的特征兼具局部和全局信息, 增强网络的泛化性能, 在高精度的湿地精细分类中更具实用价值。

参考文献(References)

- Bahdanau D, Cho K and Bengio Y. 2014. Neural machine translation by jointly learning to align and translate//Proceedings of the 3rd International Conference on Learning Representations. San Diego: [s.l.]
- Cao J Z, Li Y W, Zhang K and Van Gool L. 2021. Video super-resolution transformer. arXiv:2106.06847 [DOI: 10.48550/arXiv.2106.

- 06847]
- Cao Z Y, Li X R, Jiang J F and Zhao L Y. 2020. 3D convolutional siamese network for few-shot hyperspectral classification. *Journal of Applied Remote Sensing*, 14(4): 048504 [DOI: 10.1117/1.JRS.14.048504]
- Chen N X, Watanabe S, Villalba J, Żelasko P and Dehak N. 2021. Non-autoregressive transformer for speech recognition. *IEEE Signal Processing Letters*, 28: 121-125 [DOI: 10.1109/LSP.2020.3044547]
- Cho K, Van Merriënboer B, Gulcehre C, Bahdanau D, Bougares F, Schwenk H and Bengio Y. 2014. Learning phrase representations using RNN encoder-decoder for statistical machine translation//*Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. Doha: ACL [DOI: 10.3115/v1/D14-1179]
- Dai Z H, Liu H X, Le Q V and Tan M X. 2021. CoAtNet: marrying convolution and attention for all data sizes//*Proceedings of the 35th Conference on Neural Information Processing Systems*. [s.l.]: [s.n.]: 3965-3977
- Deng C, Liu X L, Li C and Tao D C. 2018. Active multi-kernel domain adaptation for hyperspectral image classification. *Pattern Recognition*, 77: 306-315 [DOI: 10.1016/j.patcog.2017.10.007]
- Deng J, Dong W, Socher R, Li L J, Li K and Li F F. 2009. ImageNet: a large-scale hierarchical image database//*Proceedings of 2009 IEEE Conference on Computer Vision and Pattern Recognition*. Miami: IEEE [DOI: 10.1109/CVPR.2009.5206848]
- Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X H, Unterthiner T, Dehghani M, Minderer M, Heigold G and Gelly S, Uszkoreit J and Housby N. 2021. An image is worth 16x16 words: transformers for image recognition at scale//*Proceedings of the 9th International Conference on Learning Representations*. [s.l.]: OpenReview.net
- Fu B L, Liu M, He H C, Lan F W, He X, Liu L L, Huang L K, Fan D L, Zhao M and Jia Z L. 2021. Comparison of optimized object-based rf-dt algorithm and segnet algorithm for classifying karst wetland vegetation communities using ultra-high spatial resolution uav data. *International Journal of Applied Earth Observation and Geoinformation*, 104: 102553 [DOI: 10.1016/j.jag.2021.102553]
- Gao K L, Liu B, Yu X C, Qin J C, Zhang P Q and Tan X. 2020. Deep relation network for hyperspectral image few-shot classification. *Remote Sensing*, 12(6): 923 [DOI: 10.3390/rs12060923]
- Gong J Y and Ji S P. 2017. From photogrammetry to computer vision. *Geomatics and Information Science of Wuhan University*, 42(11): 1518-1522, 1615 (龚健雅, 季顺平. 2017. 从摄影测量到计算机视觉. *武汉大学学报(信息科学版)*, 42(11): 1518-1522, 615) [DOI: 10.13203/j.whugis20170283]
- Gong R, Dai D X, Chen Y H, Li W and Van Gool L. 2021. mDALU: multi-source domain adaptation and label unification with partial datasets//*Proceedings of 2021 IEEE/CVF International Conference on Computer Vision*. Montreal: IEEE [DOI: 10.1109/ICCV48922.2021.00875]
- Gu Y X, Lan X, Fu B Y and Qin X L. 2023. Object detection algorithm for remote sensing images based on geometric adaptation and global perception. *Journal of Computer Applications*, 43(3): 916-922 (顾勇翔, 蓝鑫, 伏博毅, 秦小林. 2023. 基于几何适应与全局感知的遥感图像目标检测算法. *计算机应用*, 43(3): 916-922) [DOI: 10.11772/j.issn.1001-9081.2022010071]
- Guo H J, Cai Y P, Yang Z F, Zhu Z C and Ouyang Y R. 2021. Dynamic simulation of coastal wetlands for Guangdong-Hong Kong-Macao Greater Bay area based on multi-temporal Landsat images and FLUS model. *Ecological Indicators*, 125: 107559 [DOI: 10.1016/j.ecolind.2021.107559]
- Gxokwe S, Dube T and Mazvimavi D. 2022. Leveraging Google Earth Engine platform to characterize and map small seasonal wetlands in the semi-arid environments of South Africa. *Science of the Total Environment*, 803: 150139 [DOI: 10.1016/j.scitotenv.2021.150139]
- Hu Q, Wolcott W, Neale C, Zhou Y Z, Drahota J, Varner D, Bishop A, LaGrange T, Zhang L G and Tang Z H. 2021. Utilizing unsupervised learning, multi-view imaging, and CNN-based attention facilitates cost-effective wetland mapping. *Remote Sensing of Environment*, 267: 112757 [DOI: 10.1016/j.rse.2021.112757]
- Jiao L C, Liang M M, Chen H, Yang S Y, Liu H Y and Cao X H. 2017. Deep fully convolutional network-based spatial distribution prediction for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(10): 5585-5599 [DOI: 10.1109/TGRS.2017.2710079]
- Li Z K, Liu M, Chen Y S, Xu Y M, Li W and Du Q. 2022. Deep cross-domain few-shot learning for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 60: 5501618 [DOI: 10.1109/TGRS.2021.3057066]
- Liu B, Yu X C, Yu A Z, Zhang P Q, Wan G and Wang R R. 2019. Deep few-shot learning for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 57(4): 2290-2304 [DOI: 10.1109/TGRS.2018.2872830]
- Liu W. 2020. Domain Adaptation for the High Resolution Remote Sensing Image Classification. Harbin: Harbin Institute of Technology (刘玮. 2020. 面向高分辨率遥感图像分类的域适应算法研究. 哈尔滨: 哈尔滨工业大学) [DOI: 10.27061/d.cnki.ghgdu.2020.004928]
- Mei S H, Ji J Y, Hou J H, Li X and Du Q. 2017. Learning sensor-specific spatial-spectral features of hyperspectral images via convolutional neural networks. *IEEE Transactions on Geoscience and Remote Sensing*, 55(8): 4520-4533 [DOI: 10.1109/TGRS.2017.2693346]
- Meng X R. 2019. Study on Remote Sensing Finer Classification of Freshwater Wetland Based on Deep Learning. Harbin: Harbin Normal University (孟祥锐. 2019. 基于深度学习的淡水湿地遥感精细分类研究. 哈尔滨: 哈尔滨师范大学) [DOI: 10.27064/d.cnki.ghasu.2019.000087]
- Mo L J, Cao Y, Hu Y M, Liu M and Xiao D. 2012. Object-oriented classification for satellite remote sensing of wetlands: a case study in southern Hangzhou bay area. *Wetland Science*, 10(2): 206-213 (莫利江, 曹宇, 胡远满, 刘森, 夏栋. 2012. 面向对象的湿地景观遥感分类——以杭州湾南岸地区为例. *湿地科学*, 10(2): 206-213) [DOI: 10.13248/j.cnki.wetlandsci.2012.02.019]

- Ning X G, Chang W T, Wang H, Zhang H C and Zhu Q D. 2022. Extraction of marsh wetland in Heilongjiang Basin based on GEE and multi-source remote sensing data. *National Remote Sensing Bulletin*, 26(2): 386-396 (宁晓刚, 常文涛, 王浩, 张翰超, 朱乾德. 2022. 联合GEE与多源遥感数据的黑龙江流域沼泽湿地信息提取. *遥感学报*, 26(2): 386-396) [DOI: 10.11834/jrs.20200033]
- Othman E, Bazi Y, Melgani F, Alhichri H, Alajlan N and Zuair M. 2017. Domain adaptation network for cross-scene classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(8): 4441-4456 [DOI: 10.1109/TGRS.2017.2692281]
- Rao M B, Tang P and Zhang Z. 2019. Spatial - spectral relation network for hyperspectral image classification with limited training samples. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(12): 5086-5100 [DOI: 10.1109/JSTARS.2019.2957047]
- Shen J, Qu Y R, Zhang W N and Yu Y. 2018. Wasserstein distance guided representation learning for domain adaptation//*Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence and Thirtieth Innovative Applications of Artificial Intelligence Conference and Eighth AAAI Symposium on Educational Advances in Artificial Intelligence*. New Orleans: AAAI Press
- Simonyan K and Zisserman A. 2015. Very deep convolutional networks for large-scale image recognition//*Proceedings of the 3rd International Conference on Learning Representations*. San Diego: [s.n.]
- Stähl N and Weimann L. 2022. Identifying wetland areas in historical maps using deep convolutional neural networks. *Ecological Informatics*, 68: 101557 [DOI: 10.1016/j.ecoinf.2022.101557]
- Sutskever I, Vinyals O and Le Q V. 2014. Sequence to sequence learning with neural networks//*Proceedings of the 27th International Conference on Neural Information Processing Systems*. Montreal: MIT Press
- Tuia D, Persello C and Bruzzone L. 2016. Domain adaptation for the classification of remote sensing data: An overview of recent advances. *IEEE Geoscience and Remote Sensing Magazine*, 4(2): 41-57 [DOI: 10.1109/MGRS.2016.2548504]
- Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez A N, Kaiser Ł and Polosukhin I. 2017. Attention is all you need//*Proceedings of the 31st International Conference on Neural Information Processing Systems*. Long Beach: Curran Associates Inc
- Wang G L, Fan B, Xiang S M and Pan C H. 2017. Aggregating rich hierarchical features for scene classification in remote sensing imagery. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 10(9): 4104-4115 [DOI: 10.1109/JSTARS.2017.2705419]
- Wang Z M, Du B, Shi Q and Tu W P. 2019. Domain adaptation with discriminative distribution and manifold embedding for hyperspectral image classification. *IEEE Geoscience and Remote Sensing Letters*, 16(7): 1155-1159 [DOI: 10.1109/LGRS.2018.2889967]
- Yang H L and Crawford M M. 2016. Domain adaptation with preservation of manifold geometry for hyperspectral image classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 9(2): 543-555 [DOI: 10.1109/JSTARS.2015.2449738]
- Yang J X, Zhao Y Q and Chan J C W. 2017. Learning and transferring deep joint spectral - spatial features for hyperspectral classification. *IEEE Transactions on Geoscience Remote Sensing*, 55(8): 4729-4742 [DOI: 10.1109/TGRS.2017.2698503]
- Yang L X, Zhang R Y, Li L D and Xie X H. 2021. SimAM: a simple, parameter-free attention module for convolutional neural networks//*Proceedings of the 38th International Conference on Machine Learning*. [s.l.]: PMLR
- Yu S Q, Jia S, and Xu C Y. 2017. Convolutional neural networks for hyperspectral image classification. *Neurocomputing*, 219: 88-98 [DOI: 10.1016/j.neucom.2016.09.010]
- Zhang K Y. 2019. Remote Sensing Mapping and Evolution Analysis of Coastal Beach Based on Time Series Image Analysis of Google Earth Engine Platform. Shenzhen: Shenzhen University (张康永. 2019. 基于Google Earth Engine平台时序影像分析的滨海滩涂遥感制图及演变分析. 深圳: 深圳大学)
- Zhao S C, Wang G Z, Zhang S H, Gu Y, Li Y X, Song Z C, Xu P F, Hu R B, Chai H and Keutzer K. 2020. Multi-source distilling domain adaptation//*Proceedings of the Thirty-Fourth AAAI Conference on Artificial Intelligence, AAAI 2020, The Thirty-Second Innovative Applications of Artificial Intelligence Conference, IAAI 2020, The Tenth AAAI Symposium on Educational Advances in Artificial Intelligence*. New York: AAAI Press [DOI: 10.1609/aaai.v34i07.6997]

Wetland classification based on Sentinel-2 and 3D multisource domain self-attention model

LOU Anjun¹, HE Zhi^{1,2}, XIAO Man¹, LI Xinyuan¹

1. School of Geography and Planning, Sun Yat-sen University, Guangzhou, 510275, China;

2. Guangdong Provincial Laboratory of Marine Science and Engineering (Zhuhai), Zhuhai 519082, China

Abstract: Accurate wetland classification methods can quickly grasp the spatial-temporal variation characteristics of wetlands and play an

important role in wetland research. Considering the limitation of the existing wetland classification method based on few-shot learning to the use of target or single-source domain dataset, this paper proposes a 3D multisource domain self-attention few-shot learning (3D-MDAFSL) model. First, combining the advantages of convolution and attention mechanism, a 3D feature extractor based on self-attention mechanism and deep residual convolution is designed. Then, the conditional adversarial domain adaptation strategy is used to achieve multisource domain distribution alignment, and few-shot learning is performed separately in each domain. Finally, the features extracted by the trained model are imputed to the K-nearest neighbor classifier to obtain classification results. Results show that compared with the framework without feature extraction, the 3D feature extractor improves the overall accuracy by approximately 6.79%. When using multisource domain datasets, the overall accuracy of the 3D-MDAFSL model for the Sentinel-2 wetland dataset in Zhongshan City can reach 93.52%, which is a significant improvement compared with the existing algorithms. The 3D-MDAFSL model proposed in this paper has good application value in the high-precision extraction and classification of wetland features.

Key words: remote sensing, few-shot, wetland classification, multi-source domain adaption, self-attention

Supported by National Key Research and Development Program of China(No. 2020YFA0714103); National Nature Science Foundation of China (No. 42271325); Innovation Group Project of Southern Marine Science and Engineering Guangdong Laboratory (Zhuhai) (No. 311021018); Guangdong Basic and Applied Basic Research Foundation (No. 2019A1515011877); Guangzhou Science and Technology Planning Project (No. 202002030240); National Key Laboratory of Science and Technology on Automatic Target Recognition (No. WDZC20205500205)