



中国科学院大学
University of Chinese Academy of Sciences

博士学位论文

基于注意力网络的高光谱图像分类研究

作者姓名： 杨凯

指导教师： 卢孝强 研究员 中国科学院西安光学精密机械研究所

鱼卫星 研究员 中国科学院西安光学精密机械研究所

学位类别： 工学博士

学科专业： 信号与信息处理

培养单位： 中国科学院西安光学精密机械研究所

2023 年 6 月

**Research on Hyperspectral Image Classification Based on
Attention Networks**

**A dissertation submitted to
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Doctor of Philosophy
in Signal and Information Processing**

By

YANG Kai

Supervisor: Professor LU Xiaoqiang

Professor YU Weixing

**Xi'an Institute of Optics & Precision Mechanics,
Chinese Academy of Sciences**

June 2023

摘要

高光谱遥感技术是一种获取地球表面信息的被动遥感技术，通过在卫星、飞机、无人机等载体上搭载高光谱相机，可以获得包含地物空间信息和丰富光谱信息的高光谱图像。高光谱图像分类一直以来是遥感领域中备受关注的任务。近年来，随着深度学习的发展，基于深度神经网络的方法逐渐在高光谱图像分类任务中占据主导地位。然而，在当前遥感高光谱图像分类中依然存在几方面的问题。首先，基于卷积神经网络的特征提取过程中对图像旋转操作的鲁棒性不强，特征容易随着图像旋转发生改变；其次，基于 Transformer 的深度神经网络在处理序列化图像时对一系列的图像块忽略了局部区域对于类别信息的判别性差异，存在冗余信息；最后，Transformer 网络在处理高光谱图像时仍遵循类似常规可见光图像的方式，没有充分利用高光谱图像中的光谱信息。针对上述问题，本论文结合注意力机制在深度神经网络中的潜力开展了一系列的研究，具体包括以下三方面。

(1) 基于交叉注意力的卷积神经网络。目前卷积神经网络需要利用二维或三维卷积为提取空间-光谱特征。然而，这些卷积操作对图像旋转很敏感，这可能导致最近基于卷积神经网络的方法对图像旋转的鲁棒性不强。为此，本文提出基于交叉注意力的卷积神经网络，在该网络中设计了交叉空间注意力模块，用于生成与旋转无关的图像特征。针对高光谱图像丰富的光谱信息，设计了交叉光谱注意力模块，用于网络在特征提取的过程中抑制光谱波段中的冗余信息，聚焦与分类任务相关的关键光谱信息。在多个遥感高光谱图像分类数据集上的实验验证了本文所提出的交叉空间注意力模块和交叉光谱注意力模块的有效性。

(2) 基于局部注意力选择的 Transformer 网络。现有 Transformer 网络在应用于图像任务中，需要将图像序列化，转换成一系列的图像块。在将这些图像块输入网络中时，没有考虑这些局部图像块对于分类过程中的判别性差异，难以抑制其中的冗余信息。针对这一问题，本文提出了基于局部注意力选择的 Transformer 网络，在该网络中设计了局部选择模块，能够对序列化的图像块以注意力选择的方式进行筛选，辨别出与类别信息相关性较高，具有判别性的图像区域，抑制类别相关性弱的冗余区域。通过在大量遥感图像数据集上的实验验证，表明本文所提出的基于局部注意力选择的 Transformer 网络能够有效学习大尺度图像直接的全局特征关系，在分类任务上具有优异的性能，达到了领域内的先进水平。

(3) 基于注意力引导的双分支网络。Transformer 网络具有其强大的全局关联能力，在图像分析中取得了一定的成果。然而在面对高光谱图像分类任务时，

采用常规图像预处理手段会导致光谱信息的损失，无法保留完整的光谱-空间信息。针对这一问题，本文提出了基于注意力引导的双分支网络。该网络结合了卷积神经网络与 Transformer 网络在特征提取中各自的优势，同时挖掘大尺寸复杂遥感图像光谱与空间信息。在网络中，由浅到深地不同尺度下设计了多层合注意力引导机制，用卷积特征指导 Transformer 的自注意力模块关注图像光谱波段中的关键细节。在高光谱图像分类数据集上的大量实验验证了基于注意力引导的双分支网络的有效性，表明该网络在分类精度方面有着卓越的性能表现，达到了领域内的先进水平。

关键词：高光谱图像，卷积神经网络，注意力机制，深度学习，遥感地物分类

Abstract

Hyperspectral remote sensing technology is a passive remote sensing technology that obtains information on the earth's surface. Hyperspectral images can be captured by hyperspectral cameras on various platforms such as satellites, aircrafts, and drones. Hyperspectral image classification has always been an important task and has attracted much attention in the field of remote sensing. In recent years, with the development of deep learning, methods based on deep neural networks have gradually dominated hyperspectral image classification. However, there are still several unsolved problems in hyperspectral classification. Firstly, the feature extraction process based on the Convolutional Neural Network (CNN) is not robust to the image rotation, and the features would change with the image rotation. Secondly, deep neural networks based on Transformers ignore the discriminative differences in local regions for category information when processing serialized images, resulting in redundant information. Thirdly, when processing hyperspectral images, Transformer networks still follow a similar approach to conventional visible light images and do not fully utilize the spectral information present in hyperspectral images. Aiming at the above problems, this dissertation conducts a series of research on the potential of the attention mechanism in deep neural networks, including the following three aspects.

(1) Cross-Attention Spectral–Spatial Network. In current methods based on convolutional neural networks, 2D or 3D convolution inevitably becomes the basic operation for extracting spatial or spectral-spatial features. However, these convolutional operations are sensitive to image rotation. The extracted features would probably change as the input image rotates. To this end, a Cross-Attention Spectral–Spatial Network (CASSN) is proposed in this dissertation. In the CASSN, a cross-spatial attention component is proposed to generate rotation-invariant image features. For the rich spectral information of hyperspectral images, a cross-spectral attention component is proposed to suppress redundant information in spectral bands during the feature extraction process and focus on key spectral information related to classification tasks. Experiments on multiple remote sensing hyperspectral classification datasets verified the effectiveness of the proposed cross-spatial attention component and cross-spectral attention component.

(2) Local Selection Vision Transformer. In the past mainstream remote sensing classification methods based on convolutional neural networks, it is necessary to stack multiple convolutional layers to increase the receptive field to extract global features and improve the discriminative expression of the network. However, multiple convolutional layers would introduce a large number of additional parameters. Considering that the Vision Transformer (ViT) has shown powerful performance in modeling global sample relationships, Local Selection Vision Transformer (LSViT) network is proposed in this dissertation. A local selection module is proposed in this network, which introduces attention mechanism to add different attention weights to

serialized image patches. As a consequence, the patches from image regions with high correlations to image category information are selected. Those regions with weak correlations with category information are suppressed in features. Through the experimental verification on a large number of remote sensing image data sets, it shows that the proposed LSViT is able to effectively learn the global feature relationship of large-scale images. The performance of LSViT is comparable with state-of-the-art methods.

(3) Multi-Level Attention based Hybrid Network. Transformer has achieved excellent achievements in image analysis thanks to its powerful global sample correlation ability. However, restricted by its network input form, the image has to be transferred into a series of image patches. In large-scale remote sensing images, this division of image patches makes it difficult to effectively extract features in terms of small-scale land cover. Considering the advantage of convolutional neural network in local information extraction, a Multi-Level Attention based Hybrid Network (MAHN) is proposed in this dissertation. The MAHN combines the respective advantages of convolutional neural network and Transformer in feature extraction, and simultaneously mines local-global information of large-scale complex remote sensing images. At the same time, a multi-level attention mechanism is introduced at different scales from shallow to deep, and convolutional features are used to guide Transformer's self-attention module to focus on key details in the image area. A large number of experiments on the hyperspectral image classification data sets have verified the effectiveness of the MAHN, showing that the network has achieved state-of-the-art performance in classification accuracy.

Key Words: Hyperspectral Image, Convolutional Neural Network, Attention Mechanism, Deep Learning, Remote Sensing Land Cover Classification

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 研究现状与发展趋势.....	3
1.2.1 高光谱图像分类.....	3
1.2.2 注意力机制.....	5
1.3 本文主要工作.....	7
1.3.1 研究目标.....	7
1.3.2 研究内容.....	7
1.3.3 创新之处.....	9
1.3.4 本文章节安排.....	9
第 2 章 主流神经网络简介	11
2.1 卷积神经网络.....	11
2.1.1 卷积的基本原理.....	12
2.1.2 典型的卷积神经网络模型.....	14
2.2 Transformer 网络.....	16
2.2.1 Transformer 的基本原理.....	16
2.2.2 典型的 Transformer 网络模型.....	17
2.3 本章小结.....	18
第 3 章 基于交叉注意力 CNN 的遥感图像分类.....	19
3.1 引言.....	19
3.2 研究方法.....	21
3.2.1 网络设计.....	21
3.2.2 交叉光谱注意力模块.....	22
3.2.3 光谱特征提取模块.....	25
3.2.4 交叉空间注意力模块.....	25
3.3 实验验证.....	26
3.3.1 数据集及评价指标.....	26
3.3.2 实验设置.....	28
3.3.3 实验结果与分析.....	28
3.4 本章小结.....	39
第 4 章 基于局部注意力选择 Transformer 的遥感图像分类	41
4.1 引言.....	41
4.2 研究方法.....	43
4.2.1 视觉 Transformer.....	43

4.2.2 局部选择模块.....	45
4.2.3 损失函数.....	46
4.3 实验验证.....	46
4.3.1 数据集与评价指标.....	46
4.3.2 实验设置.....	48
4.3.3 实验结果与分析.....	49
4.4 本章小结.....	54
第 5 章 基于注意力引导双分支网络的遥感图像分类	55
5.1 引言.....	55
5.2 研究方法.....	57
5.2.1 卷积神经网络特征提取分支.....	57
5.2.2 Transformer 特征提取分支.....	58
5.2.3 多层次注意力引导机制.....	58
5.3 实验验证.....	59
5.3.1 数据集与评价指标.....	59
5.3.2 实验设置.....	61
5.3.3 实验结果与分析.....	62
5.4 本章小结.....	68
第 6 章 总结与展望	71
6.1 总结.....	71
6.2 展望.....	72
参考文献.....	73

图目录

图 1-1 高光谱图像示例	2
图 1-2 高光谱图像分类得到的类别图	3
图 1-3 基于注意力网络的高光谱图像分类研究整体框架	8
图 2-1 全连接网络示意图	11
图 2-2 简单的卷积神经网络示例	12
图 2-3 卷积操作示意图	13
图 2-4 最大池化操作示意图	14
图 2-5 Transformer 结构示意图	17
图 3-1 成像透视图的改变导致图像空间旋转	23
图 3-2 交叉注意力卷积神经网络的总体结构	24
图 3-3 PU 上各类别平均光谱（蓝线）和平均频带权重（灰条）	32
图 3-4 在 PU 数据集上与其他算法的可视化对比	35
图 3-5 在 IP 数据集上与其他算法的可视化对比	37
图 3-6 在 Salinas 数据集上与其他算法的可视化对比	39
图 4-1 遥感图像样例	43
图 4-2 LSViT 的网络结构	45
图 4-3 AID 数据集示例	49
图 4-4 NWPU-RESISC45 数据集示例	50
图 5-1 基于注意力引导的双分支网络的总体结构	59
图 5-2 PU 数据集中的 Ground truth 和对比算法的分类图	66
图 5-3 在 HR-L 数据集上与其他算法的可视化对比	68
图 5-4 在 Salinas 数据集上与其他算法的可视化对比	70

表目录

表 3-1 交叉注意力卷积神经网络的详细结构	25
表 3-2 PU 数据集中训练和测试使用的像素数量	28
表 3-3 IP 数据集中训练和测试使用的像素数量	29
表 3-4 Salinas 数据集中训练和测试使用的像素数量	29
表 3-5 PU 数据集上不同类型光谱注意力模块的总体精度(%)	31
表 3-6 在 PU 数据集上对交叉注意力卷积神经网络的消融研究	33
表 3-7 每类的精度, 不同方法在 PU 数据集上的分类结果	34
表 3-8 每类的精度, 不同方法在 IP 数据集上的分类结果	36
表 3-9 每类的精度, 不同方法在 Salinas 数据集上的分类结果	38
表 3-10 不同高光谱图像块尺寸对分类精度的影响	39
表 3-11 每个类别训练样本数对分类精度的影响	40
表 3-12 不同方法训练测试时间(秒)	41
表 4-1 不同图像块划分比较结果	51
表 4-2 不同步长比较结果	52
表 4-3 局部选择模块的影响结果	52
表 4-4 与卷积神经网络模型对比结果	52
表 4-5 在 AID 数据集与最先进方法进行比较	53
表 4-6 在 NWPU-RESISC45 数据集与最先进方法进行比较	54
表 5-1 PU 数据集中训练和测试所用的样本数量	62
表 5-2 HR-L 数据集中训练和测试所用的样本数量	62
表 5-3 Salinas 数据集中训练和测试所用的样本数量	63
表 5-4 PU 数据集上不同融合方式的总体精度(%)	64
表 5-5 不同高光谱图像切片尺寸的 OAs (%)	65
表 5-6 每类的精度, 不同方法在 PU 数据集上的分类结果	65
表 5-7 每类的精度, 不同方法在 HR-L 数据集上的分类结果	67
表 5-8 每类的精度, 不同方法在 Salinas 数据集上的分类结果	69

第1章 绪论

当今，遥感图像已经成为研究地物分布、环境变化以及自然资源等领域中不可或缺的工具。在多种多样的遥感图像中，高光谱图像凭借其丰富的光谱信息对地面目标的组成分析具有较强的判别力。相比于可见光图像，高光谱图像可以提供更丰富的光谱信息，使得地物识别与分类更具有准确性和可靠性。然而，高光谱遥感数据的处理和分析也面临着一系列的挑战。本文针对当前遥感高光谱图像分类中存在的若干问题展开了研究。本章首先阐述遥感高光谱图像分类的研究背景与意义，然后对现有的高光谱图像分类方法进行回顾、归纳与总结，然后概括本论文的研究目标、研究内容以及创新之处，最后对本文剩余章节的安排进行介绍。

1.1 研究背景和意义

遥感技术是指使用从遥远的卫星、航空器或地面传感器等装置中获取的数据，对地球表面进行观测、测量和分析的技术。这些数据包括各种形式的图像、数字高程模型等等。随着遥感技术的发展，它已经在多个领域产生了深远的影响和广泛的应用。在地球科学领域，遥感技术可以提供全球尺度的地表信息，帮助人们研究气候变化、土地利用变化、生物多样性等全球性问题。在城市规划和管理领域，遥感技术可以提供城市扩展和人口增长的趋势信息，帮助城市规划者做出决策。在农业领域，遥感技术可以提供作物生长的情况，以及土地的水分和养分含量等信息，帮助农民制定决策并提高农作物的产量。在林业领域，遥感技术可以提供森林的生长情况、种类和面积等信息，帮助森林资源管理者做出保护和管理森林的决策。除了以上领域外，遥感技术还在灾害监测和管理、资源勘探和开发、环境保护和监测、国家安全等方面起到重要的作用。在这过程中，遥感影像是数据的主要载体。通过不同类型的传感器，可以通过航空器、卫星等平台获取各种不同类型的遥感影像。不同类型的遥感影像具有不同的特点和应用领域，包括高光谱图像，红外图像，高分辨率可见光图像，全色图像，合成孔径雷达图像等等。

在这些不同的图像类型中，高光谱图像在面对地物材质与成分分析相关的任务中具有较为广泛的应用。高光谱图像可以提供更丰富的光谱信息，具有较好的波长分辨率、波段连续性以及非常广阔的波段范围。图 1-1 中展示了典型的高光谱图像样例，可以看到，高光谱图像的与常规的三通道可见光图像不同，光谱通道数量可以达到几十甚至上百。这其中的光谱信息能够根据材料、质地实现对地物成分的精确分析，确地区分不同地物类型，在地质勘探、植被覆盖

分析、生态环境检测、土壤水分、矿物探测等领域有着广泛的应用。伴随着大量高光谱图像的获取，如何高效、精准地利用这些数据进行自动化、智能化分析识别具有重要的意义，是一直以来研究学者们密切关注的目标。




图 1-1 高光谱图像示例

Figure 1-1 Examples of hyperspectral images

遥感高光谱图像分析任务中，高光谱图像分类任务是较为重要且基础的图像分析任务。高光谱图像分类一般是指对高光谱图像中的像素根据光谱信息进行识别与分析，判断每个像素对应的实际场景中的地物内容，根据真实地物信息给每个像素分配一个类别标签，最终得到类别图，如图 1-2 所示。高光谱图像分类能够对图像中的包含的地物进行全面，精准的分析。得益于图像中丰富的光谱信息，相比于常见的可见光图像，通过光谱信息可以对外表相近但材质不同的地物进行精准区分，具有很高的应用价值。

由于神经网络在模式识别，计算机视觉领域的迅速发展，遥感数据分类作为图像分析任务，也在识别精度方面取得了巨大的飞跃。这些应用主要基于在计算机视觉领域中开发的模型，主要针对常见可见光光学图像设计，默认图像包含三个数据通道。然而高光谱图像与标准光学图像有很大的差异，导致机器视觉领域的深度学习模型不能直接迁移到高光谱图像中。首先，高光谱图像包含大量连续的光谱波段，图像通道数量可能达到几十甚至上百。其次，相比于可见光图像，高光谱图像的空间分辨率通常较低，这导致在处理高光谱数据时需要考虑空间邻域的信息。此外，高光谱数据集的规模通常很大，但是由于空间分辨率低，样本数目较少，这使得在处理高光谱数据时常面临标注样本稀缺的问题。相应地，需要开发新的深度学习技术，以充分利用高光谱数据的优势，并解决空间分辨率低和样本数量少的问题。因此，开发能够处理高光谱数据的深度学习模型，提升高光谱图像分类的准确率与运算效率是当前遥感

图像分类领域面临的挑战和需要解决的问题。本论文针对高光谱图像分类需求，研究基于注意力机制的深度神经网络。




图 1-2 高光谱图像分类得到的类别图

Figure 1-2 Class maps generated by hyperspectral image classification

1.2 研究现状与发展趋势

1.2.1 高光谱图像分类

早期的高光谱分类工作主要关注光谱信息的提取。在这一时期，主要应用的是传统机器学习方法^[1]。基于深度学习方法进行高光谱分类最直接的方式是将深度全连接网络（Fully Connected network, FC）与标准分类器相结合。常见的分类器有支持量机（Support Vector Machine, SVM）和随机森林（Random Forest, RF）。基于类似的原理，根据不同的需求改变网络的类型，如增加网络上深度、增加多样化的特征提取方式等方法可以进一步提升方法的性能。2000年之后的许多方法^[2,3]采用了这样的思路进行网络设计。这一时期的网络设计以一维卷积神经网络为主^[4]。由于需要处理的数据是一维光谱信息，可以被看做一维数据序列，因此循环神经网络（Recurrent Neural Network, RNN）也可以被用于高光谱图像分析。循环神经网络使用暂存信息来建立数据前后数据关联，通常用于处理前后相关联的数据序列。Mou 等人^[5]采用了循环神经网络对高光谱数据进行分类，利用循环神经网络的特性来对光谱信息中的长距离和短距离数据关联进行建模。Wu 等人^[6]采用了类似的方式来使用循环神经网络处理高光谱图像像素中包含的光谱信息。该方法中提出了用于半监督学习的伪标记生成

发方法。Wu 等人^[7]则提出了一种同时使用循环神经网络和卷积神经网络的方法，用循环卷积单元来处理滤波后的特征。

在后来的高光谱分类任务研究中，学者们开始逐渐重视图像空间信息的提取，研究空间光谱联合的分类方法。在这些方法中，主要是基于卷积神经网络。在一般的图像分类任务中，卷积神经网络往往位于网络的前半部分，用于进行特征提取与表示学习，后半部分则是全连接网络构成的分类器，用于完成类别预测。在这样的设计中，网络中滤波核的数量与输入图像的通道数量正相关。因此将计算机视觉领域常用的卷积神经网络迁移到高光谱图像上比较常见的做法是直接缩减高光谱图像的维度。Makantasis 等人^[8]使用主成分分析（Principal Component Analysis, PCA）将高光谱数据投影到三通道张量中，然后采用标准的二维卷积神经网络进行分类。该架构交替使用卷积层和降维操作（通过 PCA 或直接下采样）进行特征提取，然后采用多层感知器即全连接网络作为分类器。Slavkovikj 等人^[9]提出了另一种类似的方案，将高光谱的空间维度压缩，保留光谱维度来将三维数据压缩为二维图像，然后采用传统卷积神经网络对该图像进行处理。这类方法的主要缺点是将高光谱图像强行压缩成类似二维图像的数据形式以适应常规卷积，难以避免地会带来不小的信息损失，难以保留高光谱图像中重要的光谱信息。为了解决这个问题，有一些学者^[10,11]并提出了另一种处理方式。他们没有将高光谱数据立方体作为一个整体来处理，而是引入了两个卷积神经网络，其中一个一维卷积神经网络沿光谱维度提取光谱特征，另一个二维卷积神经网络以常规的方式学习空间特征。然后将两个模型的特征连接起来并提供给分类器，从而完成空间-光谱分类。

在下一个阶段，学者们为了充分利用光谱信息，开始研究直接对高光谱数据立方体进行处理的深度神经网络，设计端到端的深度学习框架。为了应对光谱信息的降维问题，一些工作尝试设计了交替进行空间卷积核光谱卷积的卷积神经网络，从而逐渐减小特征图的尺寸。例如，Hamida^[12]等人提出了同时考虑像素空间和光谱近邻信息的卷积神经网络，该网络能够同时将像素附近的空间和光谱邻域像素作为网络的输入数据。卷积核的尺寸跟随网络的数据需求进行了适应性的调整。最终，两个全连接层在网络的最后被用于像素分类。这样的网络设计使其能够以学习的方式，在同时考虑空间信息和光谱信息的情况下生成特征图。基于类似的思想，Luo 等人^[13]提出了空间-光谱卷积层用于在网络的输入阶段进行光谱数据的降维。这种降维与主成分分析类似。在后续更深的网络层中，与传统的卷积神经网络类似。

上述空间-光谱方法在处理高光谱和空间和光谱信息方面取得了一定的效果，但仍需要一些复杂的设计以完成网络训练。在这方面，有学者做出了进一步的改善。Li 等人^[14]采用三维卷积神经网络直接处理高光谱数据立方体，采用三维卷积操作在数据的三个维度上同时实现卷积操作。相比于之前的二维与一维卷

积的组合,直接使用三维卷积能够在一定程度上提升高光谱分类的精度。在此之后,有许多学者提出了多样的三维卷积神经网络来处理高光谱数据,并引入了计算机视觉领域广泛应用的技术,例如半监督方法^[15]和多尺度特征提取^[16]。Chen 等人^[17]的研究则表明在高光谱分类任务中,三维卷积神经网络相比于二维卷积神经网络能够取得更优秀的性能。

1.2.2 注意力机制

注意力机制是深度学习领域中的一个重要研究方向,近年来在自然语言处理、计算机视觉、语音识别等领域中得到了广泛应用。注意力机制的概念最早出现在人类认知科学领域,用于解释人类在执行任务时的注意分配过程^[18]。而在深度学习领域中,注意力机制被定义为一种针对输入数据中的关键信息进行有针对性选择的机制。在自然语言处理中,通过注意力机制可以更好地处理长文本信息。在计算机视觉领域中,注意力机制可以帮助模型更好地关注关键区域,在图像分类、目标检测、语义分割等领域取得了良好的性能。

近年来,对于注意力机制的研究也在不断深入,注意力机制在深度神经网络的特征提取中发挥着越来越重要的作用。在图像处理领域,注意力机制大致可以分为四个阶段。第一个阶段的方法周期性地预测重要区域,并通过策略性梯度进行端到端的更新。Mnih 等人^[19]提出一种循环神经网络(Recurrent Neural Network, RNN)处理图像,自适应选择一系列区域,并通过高分辨率技术处理所选区域,从而提取重要信息。Xu 等人^[20]提出了硬注意力和软注意力两种机制,提高了图像标题生成过程的可解释性,也提高了网络的表达能力;第二个阶段的主要特点是预测判别性输入特征。Jaderberg 等人^[21]提出了空间变换网络(Spatial Transformer Network, STN),用于学习特征的不变性,使网络更关注于最重要的区域。Dai 等人^[22]提出了可形变卷积(Deformable ConvNets, DCN),DCN 对几何变换具有不变性,可以使网络自适应地选择重要的区域,从而提高卷积网络的感受野;第三个阶段的方法以通道注意力和空间注意力为代表。Hu 等人^[23]提出通道注意力模块(Squeeze-and-Excitation, SE),该模块引入了全局平均池化,然后用全连接层捕获图像维度的信息。SE 着重强调通道的作用,无法获取复杂的全局信息。Park 等人^[24]提出了瓶颈注意力模块(Bottleneck Attention Module, BAM),利用空洞卷积扩大空间注意力的感受野,并利用瓶颈式的网络结构减少计算量。进一步地,Woo 等人^[25]提出了卷积块注意力机制(Convolutional Block Attention, CBAM),同时包含了空间上的和图像通道中的注意力机制,并将通道注意力和空间注意力解耦从而提高计算效率。Wang 等人^[26]提出高效通道注意力(Efficient Channel Attention, ECA)机制,只考虑每个通道与其相邻的通道之间的关系,从而减低了模型的复杂度。第四个阶段以Transformer^[27]的自注意力机制为核心。Dosovitskiy 等人^[28]提出了视觉

Transformer (Vision Transformer, ViT), 这是第一个用于视觉领域的 Transformer 网络。该网络首先将图像分为多个图像块, 然后将图像块映射为特征输入到 ViT 模型中。继 ViT 后, 许多研究致力于将 Transformer 引入到图像处理领域中, 如 IPT^[29]、PVT^[30]、Swin Transformer^[31]等。Zhou 等人^[32]提出建立跨注意力头的信息交互, 用于重新生成注意力映射以增加不同网络层的多样性。Wang 等人^[33]结合了 K 近邻注意力以利用图像块的局部特征并通过仅考虑相似度最高的一部分注意力权重来抑制冗余信息。Refiner^[34]在高维空间中探索了注意力扩展的可能性, 并用卷积操作来强化注意力图的局部结构特性。不同于现有的基于 token 的注意力计算方法, Ali 等人^[35]提出了新的基于特征通道的注意力计算方式, 能够提高对高分辨率图像的处理效率。

近年来, 遥感领域的深度学习研究也越来越受到关注。注意力机制作为深度学习中的重要组成部分, 也被广泛应用于遥感领域的图像处理中, 并取得了显著的效果提升。Wang 等人^[36]将注意力机制引入卷积神经网络并设计了注意力循环卷积网络 (Attention Recurrent Convolutional Network, ARCNet) 用于场景分类。它能够捕获图像中的关键区域并舍弃非关键信息; Zhang 等人^[37]提出了一种轻量化但效果显著的卷积神经网络, 将扩张卷积和通道注意力引入 MobileNetV2^[38]用于场景分类任务; Yu 等人^[37]设计了一种用于场景分类的注意力生成对抗网络, 通过增强判别器的表示能力来实现更好的场景分类性能。在高光谱图像分类任务中, 注意力机制也得到广泛应用。Fang 等人^[39]提出一种新的端到端的三维密集卷积网络, 该网络具有频谱级注意机制 (Spectral-wise Attention Mechanism, MSDN-SA), 用于高光谱分类。Haut 等人^[40]提出了一种新的注意力驱动的高光谱分类网络, 通过引入双数据路径注意模块作为基本构建模块, 同时考虑自底向上和自顶向下的可视化因素, 提高网络的特征提取能力; Mou 等人^[41]设计了一个光谱注意力模块, 在光谱信息中通过门控方式施加不同的注意力权重引导网络关注判别性的光谱信息。Zhu 等人^[42]研究光谱与空间信息中的注意力机制, 设计了残差谱-空注意力 (Residual Spectral-Spatial Attention, RSSAN) 机制, 分别在光谱和空间维度上选择有用的特征, 提高高光谱分类效果; He 等人^[43]引入了一种来自变压器的双向编码器表示, 致力于捕获全局依赖关系。Hong 等人^[44]提出了 SpectralFormer, 通过按像素或按图像块输入, 旨在从附近的高光谱波段捕获光谱本地序列知识。Zhong 等人^[45]提出光谱-空间 Transformer 网络, 其包含一个空间注意力模块和光谱关联模块, 空间注意力模块的目的是通过所有输入特征通道与空间核权重的聚合来连接局部区域, 光谱关联模块则通过对对应掩码特征映射的所有空间位置进行整合来实现。

1.3 本文主要工作

1.3.1 研究目标

本围绕如何基于注意力机制实现选择性特征提取开展研究,结合卷积神经网络与 Transformer 两种深度神经网络两种关键技术对注意力机制的原理与有效性进行探索与验证。现有的方法中,主要面临三方面的问题。首先,图像特征提取的过程中对图像的旋转操作鲁棒性不足,在输入图像发生旋转时容易对特征提取造成影响。其次,现有 Transformer 网络处理图像数据时忽视局部注意力,对输入的图像块的判别能力较弱,难以有效辨别图像中的局部判别性区域。最后,Transformer 网络在提取高光谱图像特征时对光谱信息的挖掘能力不足,难以有效提取光谱-空间信息。针对上述问题,本文包含以下三方面的研究目标:

(1) 提出基于交叉注意力卷积神经网络。该网络期望分别通过单像素特征提取与图像块特征提取相结合的方式抑制图像旋转对特征提取带来的影响。与此同时,从空间信息和光谱信息两个方向研究注意力机制对特征提取的影响,通过注意力权重引导网络从空间与光谱两个维度同时关注与图像中的关键区域。

(2) 提出基于局部注意力选择的 Transformer 网络。该网络期望利用 Transformer 的全局样本关系的提取能力,研究图像不同区域间关联对特征提取的影响。进一步地,在网络中提出局部选择模块,引导特征提取过程关注具有判别性的图像区域,去除冗余信息带来的干扰,提高网络的特征提取能力与判别性。

(3) 提出基于注意力引导的双分支网络。利用卷积神经网络在光谱维度上的特征提取能力指导 Transformer 对高光谱图像中的光谱信息进行挖掘,提取基于多层级注意力的光谱-空间特征。研究局部空间信息对自注意力模块特征提取效果的影响,在提取全局特征的同时加强多个层级下局部空间信息的特征学习,提高网络对小尺度图像区域的特征提取能力。

1.3.2 研究内容

本论文围绕如何利用注意力机制增强遥感图像分类中深度神经网络的特征提取能力展开研究,针对现阶段领域内存在的三个问题开展了三方面的研究,如图 1-3 所示。

具体来说,本论文的研究内容包含以下三部分:

(1) 基于交叉注意力的卷积神经网络

近年来,卷积神经网络逐渐成为遥感高光谱图像光谱和空间信息挖掘的主要技术手段。但在目前基于卷积神经网络的方法中,二维或三维卷积不可避免地成为提取空间或光谱空间特征的基本操作。然而,这些卷积操作对图像旋转很敏感,这可能导致基于卷积神经网络的方法对图像旋转的鲁棒性不强。本论

文提出一种交叉注意卷积神经网络来缓解图像旋转带来的特征不稳定问题。首先提出一种交叉光谱关注模块，利用像素的局部和全局光谱产生频带权值，抑制冗余频带；其次利用光谱特征提取模块来捕获光谱特征。然后在待分类像素的指导下，提出交叉空间注意力模块，从高光谱图像块生成光谱空间特征。




图 1-3 基于注意力网络的高光谱图像分类研究整体框架

Figure 1-3 The overall framework of research on hyperspectral image classification based on attention mechanism

(2) 基于局部注意力选择的 Transformer 网络

在当前基于 Transformer 的遥感分类方法中，需要首先将图像序列化，转换成一系列的图像块输入网络。在此过程中，网络对每个图像块不具备筛选与判别能力。然而图像不同空间区域包含的信息量是不同的，某些区域可能包含更复杂的信息，对样本类别有着更大的信息量与更强的判别性。为了解决这一问题，为此，本文提出了基于局部注意力选择的 Transformer 网络，将输入图像分割成一系列图像块序列后进行位置编码，引入一个分类向量一同输入 Transformer 的编码器。为了学习到局部区域的判别性特征，在最后一层 Transformer 输入前设计了局部选择模块，通过注意力机制选择具有判别性的图像元素作为输入，得到最后用于分类的特征输出。

(3) 基于注意力引导的双分支网络

Transformer 网络得益于其强大的全局样本关联能力，在各种图像分析任务中取得了一定的成果。然而在高光谱图像分类中，由于和常规可见光图像数据特性的差异，在数据处理时难以保留丰富的光谱信息，造成特征中的关键信息损失，无法保留完整的光谱-空间信息。为此，本文提出基于注意力引导的双分支网络。该网络结合了卷积神经网络与 Transformer 网络各自的优势，采用卷积

神经网络分支挖掘光谱特征，并通过多层级的注意力引导来指导 Transformer 网络分支学习光谱-空间特征，从而提高网络对不同尺度高光谱图像的适应能力，有效提升分类精度。

1.3.3 创新之处

本文研究基于注意力机制的遥感高光谱图像分类，针对当前领域内存在的一系列问题，结合注意力机制在深度神经网络中的优势提出了一系列的算法，有效提升了分类精度，对领域内的发展起到了一定的促进作用。本文的创新之处可具体总结为以下几个方面。

(1) 针对现有高光谱图像分类方法对图像空间旋转的鲁棒性不足的问题，提出了交叉注意力卷积神经网络。其中包含交叉光谱注意力模块和交叉空间注意力模块。交叉光谱注意力模块能够抑制输入像素和输入高光谱图像块中包含的光谱冗余成分。交叉空间注意力模块代替二维卷积和三维卷积，生成旋转不变的光谱空间特征。所提出的交叉注意力卷积神经网络通过利用光谱和空间信息之间的交叉关系，可以更准确地捕捉地物的特征信息。

(2) 针对 Transformer 网络忽略局部注意力，对输入的图像块序列判别能力弱，不能抑制冗余信息的问题，提出了局部选择 Transformer 网络。该网络将图像转换成一系列的图像块序列，充分利用 Transformer 对样本间前后关联与全局特征的强大捕获能力提取图像的全局特征。提出了局部选择模块对图像块序列利用注意力机制进行筛选，抑制冗余信息带来的干扰，提高网络的辨别性。该网络能够在图像中自动选择包含判别性信息的注意力区域，从而更好地应对包含大范围地物的复杂图像。

(3) 针对基于 Transformer 的深度网络难以有效提取高光谱图像中光谱-空间信息的问题，提出了基于注意力引导的双分支网络。该网络结合了卷积神经网络与 Transformer 网络在特征提取中各自的优势，通过卷积神经网络分支挖掘光谱信息，通过 Transformer 网络分支提取全局空间信息，在两个网络分支中引入多层级注意力引导机制，由浅到深地在多个网络层级用卷积层提取到的光谱信息指导 Transformer 网络分支，从而实现光谱-空间特征提取。

1.3.4 本文章节安排

本文总共包含 6 个章节，每个章节的内容安排如下：

第 1 章为绪论，阐述本论文课题的研究背景，整理了当前领域内遥感高光谱图像分类的主要发展，对现有工作进行了归纳总结，分析了发展趋势。然后对研究目标和研究内容进行了阐述，概括了主要创新之处。最后给出了论文剩余部分的章节安排。

第 2 章简要介绍了当前主流的深度神经网络，包括卷积神经网络与

Transformer 网络。对本文所涉及到的关键技术基本原理进行了介绍，回顾了常见的网络类型与网络结构。

第 3 章为基于交叉注意力的卷积神经网络。本章详细介绍了本文提出的基于交叉注意力的卷积神经网络原理与技术细节，并在高光谱分类数据集上进行了实验验证。

第 4 章为基于局部注意力选择的 Transformer 网络。本章详细介绍了基于局部注意力选择的 Transformer 网络的设计思路与方法细节，并在数据集上进行了实验验证。

第 5 章为基于注意力引导的双分支网络。本章详细介绍了基于注意力引导的双分支网络的原理与技术细节，并在遥感高光谱分类数据集上进行了实验验证。

第 6 章为总结与展望，总结了本文的研究成果，并总结了现有研究工作的不足，对未来的研究方向进行了展望。

第2章 主流神经网络简介

2.1 卷积神经网络

卷积神经网络是多年来最具代表性的深度学习模型之一，在计算机视觉等领域占据着主导地位，取得了辉煌的成就^[46]。基于卷积神经网络的各种算法大大改变了多个领域的信息处理方式，实现了跨越性的应用，例如人脸识别、自动驾驶、车牌识别、智慧医疗等等。

与传统的图像手工特征不同，卷积神经网络的特征提取不需要手动设计，而是通过训练的方式进行学习，通过一系列的卷积、池化层来提取图像中抽象的高层语义信息。与图 2-1 中的全连接（Fully Connected, FC）网络相比，卷积神经网络具有许多优点。首先，卷积神经网络的单元之间是局部连接，每个单元只和上一层网络中的邻近区域单元建立连接关系，而非所有单元，能够有效提取局部信息，同时大大降低参数量。其次，卷积神经网络可以实现网络层中部分区域的权重共享，减少需要训练的参数。另外，卷积神经网络中常见的池化层能够对特征图进行下采样，在有效保留特征关键信息的同时降低特征维度，进一步提高网络的特征提取能力，去除琐碎的特征来减少参数的数量。不同的网络层根据实际需求进行设计和组合，可以搭建各种复杂的深度网络，适用于图像分类、语义分割、目标检测等不同的任务，达到非常优异的性能。




图 2-1 全连接网络示意图

Figure 2-1 Example of a fully connected network

卷积神经网络中常见的基本单元有卷积层、池化层以及全连接层。其中，卷积层是卷积神经网络中最重要的组成部分。在卷积层中，输入的数据通过卷

卷积核在图像上滑动卷积的操作来生成特征图，对图像信息进行抽象概括。卷积核中的参数则通过网络的训练过程进行优化。卷积核通过在不同滑窗位置的据卷积操作能够捕获每一个滑窗位置图像之间像素的局部关系。这些抽象的关系通过堆叠一系列的卷积层被进一步压缩，在经过一系列的卷积与池化操作后最终可以得到抽象的包含高层语义信息的深度特征。这些深度特征可以被用于图像的分类，识别等智能化应用中。池化层用于减小特征图的大小，降低模型复杂度，在去除冗余信息的同时保留特征中的关键判别性信息。常见的池化操作有最大池化和平均池化。全连接层通常出现在卷积神经网络的最后阶段，用于调整特征的维度以适应后续下游任务的需要，将特征图转换成特定维度，生成分类或回归的结果。图 2-2 中是一个基本的浅层卷积神经网络的示例，该网络包含了卷积层，最大池化，与全连接层。




图 2-2 简单的卷积神经网络示例

Figure 2-2 A simple example of convolutional neural network

2.1.1 卷积的基本原理

(1) 卷积层

卷积层是卷积神经网络中最基本但同时也是最重要的层。它基本上对给定图像或对象生成的像素矩阵进行卷积或相乘，以生成给定图像的特征图。卷积操作是卷积神经网络中最核心的计算过程。卷积操作是一种局部感知机制，可以从局部区域提取特征信息，具有平移不变性。如图 2-3 所示，假设输入特征图为 $\mathbf{I}$ ，卷积核为 $\mathbf{K}$ ，输出特征图 $\mathbf{O}$ ，则卷积操作可以表示为：

$$\mathbf{O}_{i,j} = \sum_m \sum_n \mathbf{I}_{i+m,j+n} \mathbf{K}_{m,n} \tag{2-1}$$

其中， i,j 表示输出特征图的位置， m,n 表示卷积核的位置。在实际计算中，卷积核通常通过随机初始化进行学习。通过反向传播算法，卷积神经网络可以自动学习到最优的卷积核参数。




图 2-3 卷积操作示意图

Figure 2-3 Schematic diagram of the convolution operation

在卷积操作中，可以使用多个卷积核卷积，得到不同的特征图，作为差异性局部特征的提取结果。多通道卷积可以增加模型的复杂度和表达能力。在卷积操作中，步长也是一个重要的参数。步长是指卷积核在进行滑窗操作时每次移动的像素数量。通过改变步长的大小，可以对输出的特征图尺寸进行控制。步长越大得到的特征图尺寸越小，信息损失越多，抽象程度越高，同时也会在一定程度上降低运算量。过大的步长可能会导致信息的丢失，影响模型的准确性。卷积操作还可以通过填充来控制输出特征图的大小。填充是在输入特征图的边缘添加固定值的操作，可以在卷积操作时保留输入特征图的大小。常见的填充方式有零填充和反射填充等。填充操作可以增加特征图的大小，使得卷积层的输出大小与输入大小相同，提高了特征的表达能力。




图 2-4 最大池化操作示意图

Figure 2-4 The principle of max-pooling operation

(2) 池化层

池化操作能够有效地降低特征图的维度，同时保留其中的关键信息，对卷积神经网络有着重要的意义。同时，池化层还能够减少了模型的可学习特征数量，有助于缓解过拟合问题。池化允许卷积神经网络合并图像的所有不同维度，以便即使其形状倾斜或以不同角度存在，它也能成功识别给定对象。池化操作包含多种不同的类型，例如最大池化，平均池化，随机池化，以及空间池化金字塔。其中最常见的池化方式的是最大池化。最大池化从特征图的每个子矩阵

中获取最大值，并从中形成一个单独的矩阵，如图 2-4 所示。这样做可以确保可学习的特征在数量上保持有限，同时还保留任何图像的关键特征。

（3）网络优化

卷积神经网络的训练与优化方法与传统的神经网络类似，主要包括反向传播算法和梯度下降等方法。反向传播算法通过计算参数梯度，然后使用梯度下降寻找梯度下降最快的方向对参数进行更新。卷积神经网络中的参数包括卷积核的权重、偏置和全连接层的权重和偏置等。在训练过程中，通过前向和后向的误差传播更新参数，使得模型的预测结果与真实值更加接近。随机梯度下降（Stochastic Gradient Descent, SGD）是最常见的优化方法。除此之外，Adam 也是近年来常用的优化器。这些方法可以控制模型的学习速率、动量和自适应学习率等参数，以提高模型的收敛速度和泛化能力。

2.1.2 典型的卷积神经网络模型

（1）二维卷积神经网络

在图像分类任务方面，二维卷积神经网络获得了长足的发展。LeNet-5^[47]一般被认为是第一个用于手写数字分类的应用。从 AlexNet^[48]开始，基于卷积神经网络的分类方法开始迅速成为该领域内的主流方法。然后，Simonyan 和 Zisserman^[49]论证了网络深度的重要性，但是这一阶段的卷积神经网络一般不超过十层。后来，出现了更深的网络结构，如 VGGNets 和 GoogLeNet^[50]，显着提高了分类任务的准确性。He 等人^[51]提出了 SPP-Net，在网络中加入了金字塔池化层，使得不同尺寸的输入图像得到相同尺寸的输出。之后，He 等人^[52]提出了后来深度卷积神经网络的代表性工作，残差网络（ResNet）。该网络中引入了残差连接，大幅增加了网络的深度。Chen 等人^[53]通过分析 ResNet^[52]和 DenseNet^[54]的异同，提出了双路径网络（Dual Path Network, DPN）。DPN 不仅在个网络路径中共享相同的图像特征，而且通过双路径保证了结构特征提取的灵活性。Facebook 开源了 ResNeXt-101^[55]的源代码，并将 ResNeXt 的层数扩展到 101。

在目标检测方面，卷积神经网络的代表性工作分为两个流派，单阶段方法和两阶段方法。单阶段方法中，代表性网络模型是 YOLO（You Only Look Once）系列。Redmon 等^[56]提出了 YOLO v1，将目标检测看做回归问题，直接利用神经网络预测目标的边界框。YOLO v2^[57]提出了一种新的分类模型 darknet-19，19 表示该网络包含 19 个卷积层，每个卷积层后都使用批归一化操作增加模型的稳定性。在此之后，YOLO v3^[58]提出去除最大池化层和全连接层，改为使用 1×1 卷积， 3×3 卷积和调成连接。此外，YOLO v3 借用了特征金字塔的思想来实现多尺度特征融合。上述方法都利用锚边界框（anchor box）来确定目标的位置。它们的性能取决于锚边界框的选择，并引入了大量超参数。为此，Law 等人^[59]提出了 CornerNet，它摒弃了锚边界框的检测方式，直接预测目标的左上角和右

下角。两阶段目标检测方法中, Girshick 等人^[60]使用区域建议替代滑动窗口, 结合卷积神经网络进行自动化特征提取。然后 Girshick^[61]在 R-CNN^[60]的基础上进行改进, 加入感兴趣区域 (Region of Interest, ROI) 池化, 结合 SPP-Net^[51]的思路提出了 Fast R-CNN, 相比于 R-CNN 运行速度更快。但是, Fast R-CNN 仍然采用区域提议的模式搜索目标。进一步地, Ren 等人^[62]提出了 Faster R-CNN, 它增加了区域建议的选择以使其运算速度更快。Lin 等人^[63]将特征金字塔网络 (Feature Pyramid Network, FPN) 与 Faster R-CNN 相结合, 在误差传播过程中可以通过特征金字塔融合多尺度特征。

在图像语义分割方面, 全卷积网络 (Fully Convolutional Networks, FCN) 是代表性的予以分割卷积神经网络。Long 等人^[64]提出了全卷积的概念 首次将卷积神经网络应用于图像语义分割。Ronneberger 等人^[65]提出了具有多尺度特征的 U-Net, 成为继全卷积网络后的另一个语义分割代表性卷积神经网络, 并已广泛应用于医学图像分割。此外, 还有一些网络如 ENet^[66]、PSPNet^[67]等被用于针对不同的应用场景。在实例分割任务方面, He 等人^[68]提出了 mask-RCNN, 通过级联结构在两个任务之间共享卷积特征。考虑到实时性的需求, Bolya 等人^[69]基于 RetinaNet^[70]利用 ResNet-101 和特征金字塔融合多尺度特征。全景分割最早由 Kirillov 等人^[71]提出了全景分割的概念, 并设计了全景特征金字塔网络, 它将特征金字塔网络与 mask-RCNN 相结合用于生成全景语义分割的结果。Liu 等^[72]提出的 OANet 也是在 mask-RCNN 的基础上引入了 FPN, 将整个网络设计成了端到端的模式。

(2) 三维卷积神经网络

人体行为识别是三维卷积神经网络常用的领域。Cao 等^[73]利用三维卷积神经网络提取关节而不是全身的特征, 然后将这些特征输入线性支持向量机分类器进行分类。另一种方法^[74]是将二维图像卷积扩展到三维视频卷积以提取时空模式。Huang 等人设计了一种三维卷积神经网络结构来进行手语识别, 三维卷积层自动从视频流中提取不同的空间和时间特征, 输入到全连接层进行分类。此外, 还可以集成从三维和二维卷积神经网络中提取的特征。Huang 等人^[75]将三维卷积姿势流与二维卷积外观流融合在一起, 提供更具判别性的人类动作信息。

目标检测方面, Wu 等人^[76]提出了一种名为三维 ShapeNet 的生成式三维卷积神经网络, 可应用于可见光-深度 (RGB-D) 图像的目标检测。Maturana 和 Scherer^[77]提出了 VoxNet, 这是一种包含两个三维卷积层, 一个池化层和两个全连接层的三维卷积神经网络架构。Song 和 Xiao^[78]提出了一个三维区域建议网络来学习物体的几何特征, 并设计了一个联合物体识别网络, 融合了 VGGNet 和三维卷积神经网络的输出来学习三维联合边界框和对象分类。Zhou 和 Tuzel^[79]

出了一个用于基于点云的端到端三维检测网络 VoxelNet。VoxelNet 包含特征学习层、卷积中间层和区域建议网络。每个卷积中间层使用三维卷积层、批归一化层和激活函数来聚合体素特征。Pastor 等人^[80]设计了 TactNet3D，利用触觉特征来识别对象。

2.2 Transformer 网络

Transformer 是一种基于注意力机制的神经网络结构，它可以处理任意长度的文本序列，并且具有较好的并行性能。Transformer 可以有效地解决文本序列处理中的长期依赖问题，从而在翻译、语音识别、问答系统等自然语言处理任务中取得了优异的性能^[81]。近年来，随着视觉 Transformer 的出现，更是在机器视觉领域的目标检测，语义分割，图像分类等诸多任务中展现出了强大的能力。

2.2.1 Transformer 的基本原理

Transformer 的核心是自注意力机制，能够对输入序列中不同位置之间的相互作用进行建模，从中学习序列之间的依赖关系。相比传统的循环神经网络 RNN 和卷积神经网络等模型，Transformer 不需要维护状态或滑动窗口，可以并行计算，因此在处理长样本序列时具有更好的性能。具体来说，Transformer 通过对输入序列的每个位置进行一系列矩阵变换，得到一个新的特征向量。其中，每个位置的特征向量包含了该位置的语义信息以及与其他位置的交互信息。这些特征向量被输入到后续的全连接层中进行分类或回归等任务。自注意力机制是 Transformer 的关键技术，它能捕获输入序列中不同位置的信息，计算出每个位置与其他位置之间的注意力权重。在这个过程中，每个位置可以同时参与计算其他位置的注意力权重，从而使得 Transformer 可以学习到不同位置之间的相互作用。具体来说，自注意力机制包含三个部分：查询矩阵（query matrix）、键矩阵（key matrix）和数值矩阵（value matrix）。对于输入序列中的每个位置，可以根据其特征向量计算出一个查询矩阵、一个键矩阵和一个数值矩阵。然后，可以计算出该位置与其他位置之间的注意力权重，进而计算出加权后的数值向量，这个向量就是该位置的自注意力表示。通过自注意力机制，Transformer 可以根据输入序列中不同位置之间的信息，计算出每个位置的自注意力表示，从而捕捉序列中不同位置之间的依赖关系。

Transformer 的整体结构由编码器和解码器两部分组成，如图 2-5 所示。编码器和解码器都是由多个相同的网络层构成，其中每个网络层都包含了多头自注意力模块和前馈网络结构。




图 2-5 Transformer 结构示意图

Figure 2-5 Schematic diagram of the Transformer structure

多头自注意力模块允许模型同时关注输入序列中不同位置之间的不同信息，能够提高模型的表达能力。多头注意力机制的作用在于，通过不同的投影方式，让模型能够同时关注输入序列中不同位置之间的不同方面，比如在机器翻译任务中，可以同时关注源语言和目标语言的语义表示。前馈网络模块是 Transformer 中的另一个核心组件，它将多头注意力矩阵作为输入，经过线性变换和激活函数的组合实现非线性变换。前馈网络的作用在于，通过非线性变换，增强模型的表达能力和适应性。

Transformer 的整体结构主要包含编码器和解码器。输入序列首先通过编码器转化成特征表示，然后通过解码器转换成目标序列。编码器和解码器都由一系列相同的网络单元构成。编码器的每个网络单元中有一个多头自注意力模块和前馈网络模块。而解码器除此之外还包含一个多头注意力机制，用于将编码器的输出作为查询矩阵，编码器最后一层的多头注意力矩阵作为键矩阵和数值矩阵，用于获取编码器中的信息，从而生成目标序列。

2.2.2 典型的 Transformer 网络模型

(1) 视觉 Transformer

视觉 Transformer (Vision Transformer, ViT) ^[28] 是一个仅由 Transformer 构成的网络，该网络直接采用图像块序列作为输入，能够将 Transformer 网络用于图像分类任务。为了处理二维图像，图像通过空间上的裁切被转换成为一系列扁平的二维图像块。类似于 Transformer 双向编码表示 (Bidirectional Encoder

Representation from Transformers, BERT) 的类别标记, 输入的图像块序列被进行了序列嵌入编码。进一步地, 网络中还给图像块的编码中增加一维位置编码增强位置信息的作用。一般情况下, 视觉 Transformer 采用预训练-微调的策略进行部署。即先用模型在与当前任务相关性较弱, 但数据规模非常大的数据集上进行训练, 也称预训练。然后在此基础上保留模型的参数, 继续在数据量小的目标任务数据集上训练, 也称行微调。训练数据集为中等规模的图像数据集时, 视觉 Transformer 的准确率相比于性能较强的卷积神经网络如 ResNet 稍低。这是由于 Transformer 缺乏卷积神经网络的一些内在归纳偏差纠正能力, 当训练数据量不足时泛化性能交叉。当以足够的规模进行预训练时, 视觉 Transformer 能够取得非常优异的结果。Touvron 等人^[82]通过仅在 ImageNet 数据库上进行训练, 提出了一种具有竞争力的无卷积操作的 Transformer 网络, 称为数据高效图像 Transformer (Data-Efficient Image Transformer, DeiT)。在此基础上, 还提出了 DeiT 的变种, DeiT-B, 在常见大型图像数据集上达到了非常高的分类精度。

(2) 视觉 Transformer 的变体

遵循视觉 Transformer 的模式, 有学者们提出了一系列基于视觉 Transformer 的其他 Transformer 网络增强其性能。原始的视觉 Transformer 擅长捕捉图像块之间的长距离依赖关系, 但由于二维图像块被简单线性映射直接编码成向量, 忽视了局部特征的提取。为此, 有研究人员着重提升 Transformer 对局部信息的建模能力。Han 等人^[83]进一步将图像块划分为多个亚图像块, 并引入了一种新的嵌套 Transformer (transformer-in-transformer) 架构, 该架构设计了内部 Transformer 模块来模拟亚图像块和外部 Transformer 模块之间的关系, 从而实现图像块直接的信息交互。Chu 等人^[84]和 Lin 等人^[85]逐层交替执行局部和全局注意力机制。Liu 等人^[31]提出了 Swin Transformers, 在一个滑窗的窗口内加入了局部注意力机制, 并提出了一个用于跨窗口连接的移位窗口分区方法, 用来关联不同窗口间图像的特征。Huang 等人^[86]提出了 Shuffle Transformer 进一步利用空间上的乱序操作而不是移位窗口分区来建立不同图像窗口之间的连接。RegionViT^[87]从图像生成区域位置编码和局部位置编码, 局部位置编码通过区域位置编码的注意力权重接收全局信息。除了局部注意力之外, 其他一些工作还提出通过本地特征聚合来增强本地信息, 例如 Yuan 等人提出的 T2T^[88]。上述工作表明了图像局部-全局信息交换对于视觉 Transformer 的重要意义。

2.3 本章小结

本章介绍了论文中采用的相关技术基础, 对包括卷积神经网络和 Transformer 网络在内的当前主流的深度神经网络进行了介绍。阐述了这两种深度神经网络的基本原理, 为后文的研究提供了理论基础。

第3章 基于交叉注意力 CNN 的遥感图像分类

高光谱图像 (Hyperspectral Image, HSI) 分类的目的是对高光谱像元进行分类。近年来, 许多卷积神经网络被设计用来探索人机交互的光谱和空间信息来进行分类。在目前基于卷积神经网络的方法中, 二维或三维卷积不可避免地成为提取空间或光谱空间特征的基本操作。然而, 二维和三维卷积对图像旋转很敏感, 这可能导致最近基于卷积神经网络的方法对高光谱旋转的鲁棒性不强。本章提出了一种交叉注意力卷积神经网络 (Corss Attention Spectral Spatial Network, CASSN) 来缓解图像旋转带来的特征不稳定问题。首先, 提出了一种交叉光谱关注模块, 利用像素的局部和全局光谱产生频带权值, 抑制冗余频带; 其次, 利用光谱特征提取模块来捕获光谱特征。然后, 在待分类像素的指导下, 提出交叉空间注意力, 从高光谱图像块 (HSI patch) 生成光谱空间特征。最后, 将光谱空间特征输入 softmax 分类器进行分类。本章首先对交叉注意力卷积神经网络的研究背景进行了简要介绍, 然后详细解释了该网络的技术细节。最后在多个遥感高光谱数据集上进行了实验验证。

3.1 引言

高光谱成像仪器可以从观测到的遥感场景^[89,90]中采集数百个连续的电磁光谱波段。高光谱图像丰富的光谱可以揭示物体^[91,92]的内在物理化学性质, 有利于区分遥感场景中包含的不同物质。高光谱图像分类是指识别出像元^[93]的地物类别, 有助于灾害监测、城市规划、智能农业^[94-96]等应用。

高光谱图像一般被视为三维的数据立方体, 其中包括一维的光谱信息和二维空间信息, 这两者都为高光谱图像分类^[97]提供了有价值的线索。为了探索用于高光谱图像分类的一维光谱和二维空间信息, 最近的工作建立在丰富的卷积神经网络, 其性能优于以往手工制作的基于特征的方法^[98,99]。根据深度网络的结构特点, 目前基于卷积神经网络的方法可以概括为像素级方法、区域级方法和图像-区域联合方法。像素级方法将高光谱图像作为一组像素, 直接以像素为输入, 充分挖掘其一维光谱, 识别出相应的地物类别^[100,101]。在像素级方法中, 1-D CNN^[102,103]展现出了强大的光谱特征提取功能。由于像素级方法只在光谱域中探索像素的光谱, 这些方法对空间域^[104]的高光谱图像旋转具有鲁棒性。但是, 像素级方法忽略高光谱图像^[105]中包含的二维空间信息。

区域级方法旨在利用高光谱图像的二维空间信息来提高分类性能^[106,107]。为了利用二维空间信息, 区域级方法通常基于空间平滑性先验^[99]假设相邻像素具有相同的类别。高光谱图像块是从原高光谱图像中裁剪出来的, 作为区域级方法的输入。其次, 许多设计好的二维卷积神经网络和三维卷积神经网络对高光

谱图像分类^[40,108]显示了强大的空间特征提取能力。一般来说，区域级方法将高光谱像元分类问题转化为高光谱图像块分类问题^[109]，将高光谱图像块的类别等同于中心像元^[97]的类别。而区域级方法主要是利用整个高光谱图像块^[39,110]的空间特征，不能充分探索高光谱图像块中中心像素（指待分类像素）的一维光谱。此外，高光谱图像块中会存在不同类别的像元，这会削弱空间特征的辨别能力^[111]。

图像-区域联合方法试图同时探索待分类像素的一维光谱和高光谱图像分类^[104,112]的高光谱图像块的二维空间信息。不同于像素级方法和区域级方法是单分支网络，图像-区域联合方法是双分支网络。一个分支以待分类像素为输入提取光谱特征，另一个分支以高光谱图像块为输入提取空间特征^[113]。然后，将光谱特征和空间特征进行聚合，进行高光谱图像分类。

无论是区域级方法还是图像-区域联合方法，往往都需要利用二维或三维卷积从图像中提取空间特征或光谱特征。在特征提取的过程中，通常将二维或三维卷积中核的空间大小设置为 3×3 ，以利用高光谱图像块^[100]的空间信息。然而，含有 3 个核的二维或三维卷积对图像旋转^[114]不具有鲁棒性，这将导致最近的区域级方法和图像-区域联合方法对高光谱图像旋转^[115]不具有鲁棒性。由于遥感高光谱成像过程中独特的鸟眼视角，捕获的高光谱图像容易发生^[116]旋转。如图 3-1 所示，在旋转后的图像中，土地覆被可以出现在任何方向上。所捕获的高光谱图像的旋转变异性使得高光谱图像块易于旋转，从而导致区域级方法和图像-区域联合方法性能下降。

针对以往的区域级方法和图像-区域联合方法对高光谱图像旋转的鲁棒性不足的问题，本章提出了交叉注意力卷积神经网络。交叉注意力卷积神经网络的结构由交叉光谱注意力（Cross-Spectral Attention, CEA）模块、光谱特征提取（Spectral Feature Extraction, SFE）模块、交叉空间注意力（Cross-Spatial Attention, CAA）模块和分类模块组成。首先，提出交叉光谱注意力模块，对高光谱图像的像素和图像块中的冗余信息同时进行滤除。利用输入像元光谱的局部信息和全局信息来得到注意力权重，然后利用注意力权重同时对输入像元和输入高光谱图像块的光谱波段重要性进行重新标定。其次，设计光谱特征提取模块从重新校准的像素和高光谱图像块中获取光谱维度的特征。由于像元和高光谱图像块都包含丰富的光谱波段，因此需要提取光谱特征来充分利用这些光谱波段。然后，提出交叉空间注意力模块代替卷积操作，生成旋转不变的光谱空间特征。提出的交叉空间注意力模块首先捕捉输入高光谱图像块中邻近像素与输入像素之间的相关性。然后，利用相关性对输入高光谱图像块中的相邻像素进行聚集，生成旋转不变的光谱空间特征。最后，将光谱空间特征输入到 softmax 分类器中进行分类。三个公共数据集证明了交叉注意力卷积神经网络的有效性。




图 3-1 成像透视图的改变导致图像空间旋转

Figure 3-1 Changes of imaging perspectives can easily cause the spatial rotation of the captured HSIs.

本章的主要贡献可总结为以下几方面^[17]。

(1) 提出了一个交叉注意力卷积神经网络来缓解高光谱图像的旋转问题。提出的交叉注意力卷积神经网络包含一个像素分支和一个空间分支，以充分探索高光谱图像的一维光谱和二维空间信息进行分类。

(2) 提出了一种交叉光谱注意力模块来抑制冗余频带。该方法基于输入像素生成频带权值，避免了其他类别像素的干扰。然后，利用频带权同时对输入像素和高光谱图像块的频带进行重新校准。

(3) 提出了一种用于提取具有旋转不变性特征的交叉空间注意力模块。该模型能够自适应地将相邻像元的光谱特征聚合到光谱空间特征中，在特征中保留空间-光谱信息。

3.2 研究方法

3.2.1 网络设计

令 $H \in \mathbb{R}^{M \times N \times B}$ 代表原始的高光谱图像，其中 $M \times N$ 为高光谱图像的空间尺寸， B 为波段数目。高光谱图像分类的目的是获得高光谱图像中像素的类别。在提出的交叉注意力卷积神经网络中，首先从高光谱图像中分割出需要分类的像素 $p_i \in \mathbb{R}^{1 \times 1 \times B}$ 以提供光谱，然后从高光谱图像中裁剪出高光谱图像块 $H_i \in \mathbb{R}^{q \times q \times B}$ 以提供空间信息，其中 $q \times q$ 为高光谱图像块 H_i 的空间大小。像素 p_i 唯一对应高光谱图像块 H_i ，而高光谱图像块 H_i 的中心像素是 p_i 。像素 p_i 和高光谱图像块 H_i 都被用来当做交叉注意力卷积神经网络的高光谱图像分类的输入。




图 3-2 交叉注意力卷积神经网络的总体结构

Figure 3-2 The Overall structure of CASSN

交叉注意力卷积神经网络的整体结构如图 3-2 所示。提出的交叉注意力卷积神经网络是一个双分支网络，其中一个分支是以像素 p_i 为输入的像素分支，另一个分支是以高光谱图像块 H_i 为输入的空间分支。不同于以往的两分支像素-区域联合方法中两个分支独立提取特征^[113]，本章提出的交叉注意力卷积神经网络中像素分支和空间分支相互作用生成光谱空间特征。

提出的交叉注意力卷积神经网络由四个主要模块组成：交叉光谱注意力模块、光谱特征提取模块、交叉空间注意力模块和分类模块。其中交叉光谱注意力模块能够有效减少光谱波段中的噪声与冗余信息。与以往基于高光谱图像块 H_i 中整个相邻像素的光谱来降低高光谱图像块 H_i 的冗余光谱信息的方法不同，交叉光谱注意力模块利用像素 p_i 的光谱来同时抑制像素 p_i 和高光谱图像块 H_i 中包含的冗余光谱带。同时抑制包含在像素 p_i 和高光谱图像块 H_i 中的冗余频段。光谱特征提取模块的目的是在光谱维上提取特征。光谱特征提取模块包含两个子网络，一个子网络用于从像素 p_i 中提取光谱特征，另一个子网络用于从高光谱图像块 H_i 中提取光谱特征。交叉空间注意力模块旨在以像素 p_i 的光谱特征为指导，聚合高光谱图像块 H_i 中相邻像素的光谱特征，生成光谱空间特征。分类部分的目的是根据得到的光谱空间特征推断出像素 p_i 的类别。采用交叉熵损失作为交叉注意力卷积神经网络的损失函数进行训练。列出了交叉注意力卷积神经网络的网络结构，下面详细介绍一下交叉光谱注意力模块、光谱特征提取模块和交叉空间注意力模块。

3.2.2 交叉光谱注意力模块

高光谱图像包含丰富的光谱波段，对于识别像素[118,119]类别至关重要。最近的研究表明，不同的光谱波段对高光谱图像分类任务[120,121]有不同的贡献。因此，突出信息频带或抑制冗余频带可以显著提高高光谱图像分类[41]的结果。

表 3-1 交叉注意力卷积神经网络的详细结构

Table 3-1 Accuracy (%) of Subtle Expression Recognition on LSEMSW

	像素分支		空间分支
输入	像素 p_i		高光谱图像块 H_i
交叉空间注意力	层：一维卷积，sigmoid 输入： p_i 输出： W_i^{local}	层：全连接，sigmoid 输入： p_i 输出： W_i^{global}	层：Band-Wise Product 输入： W_i ， H_i 输出： $\overline{H}_i$
	层：Hadamard Product 输入： W_i^{local} ， W_i^{global} 输出： W_i		
	层：Band-Wise Product 输入： W_i ， p_i 输出：		
光谱特征提取	层： 1×1 二维卷积，ReLU 输入： $\overline{p}_i$ 输出： Conv-Sep-1		层： 1×1 二维卷积，ReLU 输入： $\overline{H}_i$ 输出： Conv-Spa-1
	层： 1×1 二维卷积，ReLU $\overline{p}_i$ 输入： Conv-Sep-1 输出： Conv-Sep-2		层： 1×1 二维卷积，ReLU 输入： Conv-Spa-1 输出： Conv-Sep-2
	层： 1×1 二维卷积，ReLU 输入： Conv-Sep-2 输出： $.F_{\text{pixel}}$		层： 1×1 二维卷积，ReLU 输入： Conv-Spa-2 输出： F_{patch}
交叉空间注意力	层： 1×1 二维卷积，ReLU 输入： F_{pixel} 输出： $\overline{F}_{\text{pixel}}$		层： 1×1 二维卷积，ReLU 输入： F_{patch} 输出： $\overline{F}_{\text{patch}}$
	层：Product 输入： $\overline{F}_{\text{pixel}}$ ， $\overline{F}_{\text{patch}}$ 输出： R		
	层：Normalization 输入： R 输出： $\overline{R}$		
分类	层：Softmax 分类器 输入： $F_{\text{spe-spa}}$ 输出： 预测类别		

为了以任务驱动的方式突出信息谱带，抑制冗余谱带，许多研究工作构建了各种光谱注意模块，可嵌入深度网络进行端到端训练^[39,42,107]。光谱注意模块的主要目的是生成波段权重 $W_i \in \mathbb{R}^B$ ，重新校准各波段的重要性。以往的方法通

常是基于输入高光谱图像块 H_i 中的整个相邻像素生成波段权值 W_i ，以抑制高光谱图像块 H_i ^[42,122,123] 的冗余光谱波段。然而，当输入高光谱图像块 H_i 位于地表覆盖区域边缘 ^[107,111] 附近时，高光谱图像块 H_i 通常包含其他类别的像元。由于不同类别的像素具有不同的冗余光谱波段 ^[41]，其他类别的像素会对波段权重 W_i 产生干扰。

本章提出了一个交叉光谱注意力模块来充分探索输入像素 p_i 来生成带权 W_i 。然后，利用波段权重 W_i 同时对像素 p_i 和高光谱图像块 H_i 的光谱波段进行重新标定。提出的交叉光谱注意力模块仅使用像素 p_i 来生成波段权值 W_i ，可以有效避免高光谱图像块 H_i 中其他类别像素的干扰。

在该方法中，利用像素 p_i 中的局部信息和全局信息来生成带权 W_i 。由于高光谱图像是随电磁信号进行密集采样得到的，因此频谱中的局部相邻波段 ^[118] 是高度相关的。为了研究光谱的局部相邻带相关性，我们采用了 sigmoid 激活的一维卷积运算生成本地带宽权重 W_i^{local} 。令 $W_i^{\text{local}}(j)$ 表示 W_i^{local} 的第 j 个元素。 $W_i^{\text{local}}(j)$ 的值表示像素 p_i 中第 j 个波段的重要性。由 m 个局部邻域得到 $W_i^{\text{local}}(j)$ ， $W_i^{\text{local}}(j)$ 的表达式如下：

$$W_i^{\text{local}}(j) = \varphi \left(\sum_{k=1}^m \theta_l(k) p_{i,j}(k) \right) \quad (3-1)$$

其中 $p_{i,j}(k)$ 代表像素 p_i 中第 j 个波段的第 k 个局部相邻波段。的第 k 个局部相邻波段， m 是局部相邻波段的总数。 φ 是 sigmoid 激活函数， $\theta_l \in \mathbb{R}^m$ 是一维卷积的权重，偏差省略不计。根据经验， m 的值被设定为 7。激活的全连接层被用来探索像素的全局光谱。探索像素 p_i 的全局频谱以生成全局频带权重 $W_i^{\text{global}} \in \mathbb{R}^B$ 。 W_i^{global} 的表述是如下：

$$W_i^{\text{global}} = \varphi(\theta_g p_i) \quad (3-2)$$

其中 $\theta_g \in \mathbb{R}^{B \times B}$ 是这个全连接层的权重，偏差省略不计。 $W_i(j)$ 的值表示基于全局频谱的像素 p_i 中第 j 个波段的重要性。当光谱的局部信息和全局信息都认为像素 p_i 中的第 j 个波段对分类很重要时，像素 p_i 中的这个第 j 个波段就是信息波段；否则，就是多余的波段。像素 p_i 中第 j 个波段的最终重要性 $W_i(j)$ 由 $W_i^{\text{local}}(j)$ 和 $W_i^{\text{global}}(j)$ 共同决定。

$$W_i(j) = W_i^{\text{local}}(j) W_i^{\text{global}}(j) \quad (3-3)$$

最后，利用频带权重 W_i 同时校准不同波段在像素 p_i 和 图像块 H_i 中的重要性：

$$\bar{p}_i = W_i \otimes p_i \quad (3-4)$$

$$\bar{H}_i = W_i \otimes H_i \quad (3-5)$$

其中, $\bar{p}_i \in \mathbb{R}^B$ 是重新校准的像素, $\bar{H}_i \in \mathbb{R}^{q \times q \times B}$ 是重新校准的高光谱图像块。 $\otimes$ 是频带乘法。那么, 重新校准的像素 $\bar{p}_i$ 和重新校准的高光谱图像块 $\bar{H}_i$ 被送入光谱特征提取模块以获得光谱特征。

3.2.3 光谱特征提取模块

光谱特征提取模块被设计用来提取光谱维度的特征。由于高光谱图像块 H_i 是由各种相邻的像素组成的, 所以高光谱图像块也应该被送入光谱特征提取模块。如图 3-2 所示, 光谱特征提取模块由两个子网络组成。一个子网络从像素分支中重新校准的像素 $\bar{p}_i$ 中提取光谱特征 $F_{\text{pixel}} \in \mathbb{R}^{1 \times 1 \times C}$, 另一个子网络提取光谱 $F_{\text{patch}} \in \mathbb{R}^{q \times q \times C}$, 其中 C 是通道数。由于这两个子网络都专注于从光谱中提取特征, 因此在训练和测试中, 这些子网络的结构和权重参数被设定为共享的。

$$F_{\text{pixel}} = \text{SFE}(\bar{p}_i) \quad (3-6)$$

$$F_{\text{patch}} = \text{SFE}(\bar{H}_i) \quad (3-7)$$

式中 $\text{SFE}(\cdot)$ 为设计的光谱特征提取模块。在本章中, 光谱特征提取模块中的子网络是由 3 个二维卷积层串联而成, 其中核的空间大小为 1×1 , 核的数量为 64。

3.2.4 交叉空间注意力模块

最近的工作也设计了很多空间注意模块, 旨在捕捉高光谱图像块 H_i 中的注意区域。在以往的工作中, 空间注意模块往往需要进一步结合 3×3 二维或三维卷积来提取光谱空间特征注意区域^[42,124]。然而, 3×3 二维和三维卷积对图像旋转^[114]很敏感, 这将导致最近的方法对高光谱图像旋转^[115]也很敏感。

与以往基于像素级和像素-区域联合的方法不同, 这些方法仍然利用二维或三维卷积来提取空间或光谱空间特征, 本章基于像素 p_i 的光谱特征 F_{pixel} 和高光谱图像块 H_i 的光谱特征 F_{patch} , 提出了一种替代二维和三维卷积的光谱空间特征提取交叉空间注意力模块。

提出的交叉空间注意力模块旨在充分利用在高光谱图像块 H_i 中的相邻像素和像素 p_i 之间的相关性来产生光谱空间特征。首先, 利用具有 1×1 内核的二维卷积将 F_{pixel} 和 F_{patch} 转换成 $\bar{F}_{\text{pixel}} \in \mathbb{R}^{1 \times 1 \times C_a}$ 和 $\bar{F}_{\text{patch}} \in \mathbb{R}^{q \times q \times C_a}$, 其中 C_a 是通道数。其次, 为了便于计算高光谱图像块 H_i 中的相邻像素与像素 p_i 之间的相关性, $\bar{F}_{\text{pixel}}$ 的大小被重塑为 $\mathbb{R}^{1 \times C_a}$, 而 $\bar{F}_{\text{patch}}$ 的大小被重塑为 $\mathbb{R}^{q^2 \times C_a}$ 。像素 p_i 与高光谱图像

块 H_i 中相邻像素之间的相关度 $R \in \mathbb{R}^{1 \times q^2}$ 可以利用以下公式进行计算：

$$R = \bar{F}_{\text{pixel}} \bar{F}_{\text{patch}}^T \circ \quad (3-8)$$

然后，利用 softmax 对相关系数 R 进行归一化，生成光谱空间特征：

$$\bar{R} = \frac{e^{R(i)}}{\sum_{j=1}^{q^2} e^{R(j)}} \circ \quad (3-9)$$

最后，光谱空间特征 $F_{\text{spe-spa}} \in \mathbb{R}^{1 \times C_a}$ 是由高光谱图像中的相邻像素汇总得到的。通过对高光谱图像中的相邻像素进行汇总得到图像块中的相邻像素，以归一化的相关度 $\bar{R}$ ：

$$F_{\text{spe-spa}} = \bar{R} \bar{F}_{\text{patch}} \circ \quad (3-10)$$

在交叉空间注意力模块之后，将光谱空间特征 $F_{\text{spe-spa}}$ 输入 softmax 分类器，得到类别。

3.3 实验验证

3.3.1 数据集及评价指标

数据集及评价指标为了展示交叉注意力卷积神经网络的性能，我们使用三个公共数据集 Pavia University (PU) 数据集、Indian Pines (IP) 数据集和 Salinas 数据集进行实验。

表 3-2 PU 数据集中训练和测试使用的像素数量

Table 3-2 Number of training pixels and testing pixels on the PU dataset

类别	类别名	训练像素个数	测试像素个数
1	Asphalt	100	6531
2	Meadows	100	18549
3	Gravel	100	1999
4	Trees	100	2964
5	Painted metal sheets	100	1245
6	Bare Soil	100	4929
7	Bitumen	100	1230
8	Self-blocking bricks	100	3582
9	Shadows	100	847

PU 数据集的光谱图像通过反射光学系统成像光谱仪 (Reflective Optics System Imaging Spectrometer, ROSIS) 获得。PU 数据集的高光谱图像空间尺寸

为 610×340 像素，每个像素光谱通道数量为 103。光谱波长范围为 $430 \sim 860 \text{ nm}$ 。这个数据集包括九中地物类别。表 3-2 给出了本章在 PU 数据集上使用的训练/测试样本的数量。

IP 数据集由印第安纳州西北部上空的机载可见光红外成像光谱仪 (Airborne Visible Infrared Imaging Spectrometer, AVIRIS) 获得。IP 数据集由 220 个波段的 145×145 个高光谱像素组成。这个数据集中有 20 个噪声波段。光谱波长范围为 $0.4 \sim 2.5 \mu\text{m}$ 。这个数据集包含 16 类地物，其中大部分是作物。训练/测试样本的数量见表 3-3。

表 3-3 IP 数据集中训练和测试使用的像素数量

Table 3-3 Number of training pixels and testing pixels on the IP dataset

类别	类别名	训练像素个数	测试像素个数
1	Alfalfa	5	41
2	Corn-notill	143	1285
3	Corn-mintill	83	747
4	Corn	24	213
5	Grass-pasture	49	434
6	Grass-trees	73	657
7	Grass-pasture-mowed	3	25
8	Hay-windrowed	48	430
9	Oats	2	18
10	Soybean-notill	98	874
11	Soybean-mintill	246	2209
12	Soybean-clean	60	533
13	Wheat	21	184
14	Woods	127	1138
15	Buildings-grass-trees	39	347
16	Stone-steel-towers	10	83

Salinas 数据集也由 AVIRIS 仪器收集。数据集包含 512×217 个像素，每个像素有 224 个波段。在这个数据集中也有 20 个噪声波段。Salinas 数据集包括 16 类地物。训练/测试样本的数量列于表 3-4。

为了定量评价交叉注意力卷积神经网络的分类性能，本章采用整体分类精度 (OA)、平均分类精度 (AA)、kappa 系数、各分类下的准确率作为评价指标^[11]。此外，为了定性地衡量交叉注意力卷积神经网络的性能，本章还给出了各个方法分类结果对应的类别图 (class map)。

表 3-4 Salinas 数据集中训练和测试使用的像素数量
Table 3-4 Number of training pixels and testing pixels on the Salinas dataset

类别	类别名	训练像素个数	测试像素个数
1	Brocoli green weeds 1	100	1909
2	Brocoli green weeds 2	100	3626
3	Fallow	100	1876
4	Fallow rough plow	100	1294
5	Fallow mooth	100	2578
6	Stubble	100	3859
7	Celery	100	3479
8	Grapes untrained	100	11171
9	Soil vineyard develop	100	6103
10	Corn senesced green weeds	100	3178
11	Lettuce romaine 4wk	100	968
12	Lettuce romaine 5wk	100	1827
13	Lettuce romaine 6wk	100	816
14	Lettuce romaine 7wk	100	970
15	Vinyard untrained	100	7168
16	Vinyard vertical trellis	100	1707

3.3.2 实验设置

本节主要介绍高光谱图像的数据预处理和各种方法的超参数设置。首先，遵循文献^[41]，利用最小-最大比例，将高光谱图像中每个波段的值归一到 $[0, 1]$ 的范围。然后，以训练/测试像素为中心的高光谱图像块被从归一化的高光谱图像中裁剪出来。高光谱图像中的每个像素都有一个相应的高光谱图像块，实验中所有方法的图像块空间大小为 9×9 。为了评估交叉注意力卷积神经网络的泛化性能和比较高光谱图像旋转的方法，每个裁剪的高光谱图像块被随机旋转 0° 、 90° 、 280° 或 270° 进行训练和测试。

在实验中，交叉注意力卷积神经网络的迭代历时和批量大小分别被设定为 200 和 100。交叉注意力卷积神经网络的学习率被初始化为 0.01，然后每 20 个迭代历时除以 2。所比较的方法采用了与原始文献中相同的设置。

3.3.3 实验结果与分析

(1) 交叉光谱注意力模块的有效性验证

本节主要研究交叉光谱注意力模块的有效性。最近，许多光谱注意力方法^[39,41,42,107,123]被提出用来抑制冗余光谱波段用于高光谱图像分类。这些地形图通常基于高光谱图像块的整个相邻像元生成波段权值，以重新校准光谱波段的重

要性。然而，高光谱图像块中的整个像素可能属于不同的类别，而不仅仅是中心像素^[11]的类别。由于不同类别的像素通常有不同的冗余频带^[41]，因此高光谱图像块中的其他类别的像素会对波段权值产生干扰。本章提出了一种交叉光谱注意力模块，基于待分类像素直接生成波段权值，可以有效减少高光谱图像块中与类别无关信息的影响。此外，还探索了像素光谱的局部信息和全局信息来生成波段权值。然后，利用生成的波段权值同时校准像素和高光谱图像块中波段的重要性。

本章主要研究交叉光谱注意模块的有效性并在 PU 数据集上进行实验。由于交叉光谱注意模块直接影响到像元和高光谱图像块中光谱波段的重要性，为了充分研究交叉光谱注意模块是否能够提高像元和高光谱图像块的分辨力，我们在实验中不引入任何特征提取模块。首先，以一个基础实验为参考，验证实验结果的性能。在基本实验中，无光谱注意力模块。原始像素和高光谱图像块分别直接被送入一个 softmax 分类器进行高光谱图像分类。其次，采用文献^[41]中提出的光谱注意模块（Spectral Attention Module, SAM）作为比较。光谱注意模块被用来生成基于高光谱图像块中整个相邻的频带权重，以分别重新校准像素和高光谱图像块中频带的重要性。第三，交叉光谱关注中的局部波段权重被用来重新校准像素和高光谱图像块中波段的重要性。第四，交叉光谱关注中的全局频带权重被用来重新校准像素和高光谱图像块中频带的重要性。最后，交叉光谱注意被用来重新校准像素和高光谱图像块中的波段的重要性。这些经过重新校准的像素被直接送入 softmax 分类器进行高光谱图像分类。这些经过重新校准的高光谱图像块首先被送入全局池层进行降维，然后被送入 softmax 分类器进行高光谱图像分类。

表 3-5 PU 数据集上不同类型光谱注意力模块的总体精度(%)

Table 3-5 OA (%) of different kinds of spectral attention components on the PU database

Components	像素	图像块
Basic Experiment	75.84	85.99
SAM ^[41]	83.80	87.31
Local Band Weight	77.66	87.18
Global Band Weight	86.07	93.77
Cross Spectral Attention	86.36	94.18

实验结果见表 3-5。将“基本实验”的结果与其他实验相比较，可以发现，光谱关注确实可以提高像素和高光谱图像块的辨别能力。光谱注意模块在高光谱图像块中探索整个像素以产生频带权重。由光谱注意模块重新校准的高光谱图

像块达到了 87.31% 的准确率。由光谱注意模块重新校准的像素达到了 83.80% 的精度，这比由提议的交叉光谱关注重新校准的像素的精度低 2.56%。这表明由光谱注意模块生成的频带权重不能完全评估像素中不同频带的重要性。由提议的交叉光谱关注重新校准的高光谱图像块达到了 94.18% 的精度，比由光谱注意模块重新校准的高光谱图像块的精度高 6.87%。这表明高光谱图像块中的其他类别的像素确实干扰了频带权重，而提出的交叉光谱关注可以有效地缓解这一问题。本地频带权重和全局频带权重的表现表明，频谱的本地和全局信息对于生成有效的频带权重都很重要。

图 3-3 进一步直观地显示了通过交叉光谱关注学到的波段权重，以显示交叉注意力卷积神经网络的有效性。如图 3-3 所示，不同频段的频带权重值是不同的，这表明学习到的频带权重可以有效地突出信息频段进行分类。此外，具有相似频谱的类别（如“Asphalt”，“Gravel”，“Bitumen”，“Self-Blocking Bricks”）的学习频带权重也是相似的。学习到的频带权重可以提供线索来区分这些相似的频谱。




图 3-3 PU 上各类别平均光谱（蓝线）和平均频带权重（灰条）

Figure 3-3 Average spectrums (blue line) and average band weights (gray bar) in each category on the PU database

(2) 消融实验

提出的交叉注意力卷积神经网络包含三个关键部分：交叉光谱注意（Cross Spectral Attention, CEA）部分，光谱特征提取（Spectral Feature Extraction, SFE）部分和交叉空间注意（Aross Spatial Attention, CAA）部分。在PU数据集上研究了这些模块的性能。分类结果列于表 3-6。CEA-SFE-Net 代表不含 CAA 的 CASSN。CEA-CAA-Net 代表不含 SFE 的 CASSN。SFE-CAA-Net 代表不含 CEA 的 CASSN。CEA-Net 表示不含 SFE 和 CAA 的 CASSN。SFE-Net 表示不含 CEA 和 CAA 的 CASSN。CAA-Net 表示没有 CEA 和 SFE 的 CASSN。Pixel-Patch 表示直接利用像素和高光谱图像块进行高光谱图像分类。在 CEA-SFE-Net、CEA-Net、SFE-Net 和 Pixel-Patch 中，利用全局平均池来降低空间分支的特征维度，并利用连接操作来整合像素分支的特征和空间分支的特征。然后，利用 softmax 分类器来获得类别。如表 3-6 所示，这三个部分对于提高交叉注意力卷积神经网络的性能至关重要。

表 3-6 在 PU 数据集上对交叉注意力卷积神经网络的消融研究

Table 3-6 Ablation studies of CASSN on the PU database

	CEA	SFE	CAA	OA (%)
CASSN	√	√	√	97.58
CEA-SFE-Net	√	√		96.47
CEA-CAA-Net	√		√	96.04
SFE-CAA-Net		√	√	96.23
CEA-Net	√			94.38
SFE-Net		√		95.16
CAA-Net			√	95.81
Pixel-Patch				87.98

(3) 与其他方法的对比实验

为了表明交叉注意力卷积神经网络在领域内的性能水平，分别在 PU、IP 和 Salinas 数据集上与其他现有方法进行比较。本章选用了一系列基于深度学习的最新方法用于对比，包括 1-DCNN^[4]，2-DCNN^[17]，可变形高光谱图像分类网络（Deformable HSI Classification Network, DCCNet）^[22]，挤压多偏差网络（Squeeze Multibias Network, SMBN）^[125]，光谱注意网络（Spectral Attention Network, SpecAN）^[41]，光谱空间注意网络（Spectral-Spatial Attention Network, SSAN）^[111]，迷你图卷积网络（Minibatch Graph Convolutional Network,

miniGCN)^[126]和图融合网络 (Graph Fusion Network, GFNet)^[127]。此外, 还采用了传统的基于特征提取的方法, 即正交总变异成分分析 (Orthogonal Total Variation Component Analysis, OTVCA)^[128]作为比较。下面介绍交叉注意力卷积神经网络在 PU、IP 和 Salinas 数据集上的详细结果。

1) PU 数据集

首先, 利用 PU 数据集对交叉注意力卷积神经网络的性能进行评价, 并对不同方法进行比较。定量实验结果如表 3-7 所示。1-DCNN 是一种像素化的方法, 在不同的类别中获得不同的精度。在涂金属板和阴影类别, 1-DCNN 显示优越的性能, 达到 99.28%和 99.88%的准确性。这说明多个类别像素的光谱分辨力都很强, 在进行高光谱图像分类时, 需要充分探索待分类像素的光谱。

表 3-7 每类的精度, 不同方法在 PU 数据集上的分类结果

Table 3-7 Accuracy in each category, OA, AA, and Kappa of different methods on the PU database

类别	OTVCA	1-D CNN	2-D CNN	DHCNet	SMBN	SpecAN	SSAN	miniGCN	GFNet	CASSN
1	97.37	73.39	91.26	92.41	92.77	95.25	94.15	71.43	93.37	99.10
2	95.09	79.56	88.38	93.59	94.51	95.27	94.57	94.79	96.52	96.56
3	90.80	79.54	79.29	88.99	84.84	90.60	92.65	83.29	85.28	98.85
4	97.50	93.35	98.18	97.57	98.11	98.28	97.87	92.07	97.54	99.49
5	99.84	99.28	100.00	99.84	100.00	100.00	100.00	99.20	100.00	99.84
6	97.59	75.63	84.13	97.10	96.25	98.15	93.79	77.26	95.47	98.11
7	95.20	92.44	87.32	95.04	91.95	96.02	98.54	96.26	92.86	99.92
8	94.78	82.08	75.63	93.44	90.37	94.61	96.45	74.62	89.90	94.92
9	99.88	99.88	99.65	100.00	99.88	100.00	99.88	100.00	100.00	100.00
OA	95.92	80.70	88.04	94.23	94.08	95.80	95.10	86.90	94.92	97.58
AA	96.45	86.13	89.31	95.33	94.30	96.46	96.43	87.66	94.55	98.53
Kappa	94.60	75.06	84.29	92.38	92.16	94.44	93.51	82.56	93.28	96.79

当引入高光谱图像块的空间信息时, 许多类别的对比方法的精度都得到了提高, 说明空间信息与光谱特征是互补的, 可以有效地提高分类结果。然而, 2-DCNN 和 SMBN 在沥青类上的精度低于 1-DCNN。这说明有必要设计一种更合适的空间特征提取模块。SpecAN、SSAN 和交叉注意力卷积神经网络是基于

注意力的方法，能够提取有效的空间特征，在沥青类上表现出比 1-DCNN 更好的性能。该方法能有效抑制冗余频带，并能提取对高光谱图像旋转具有鲁棒性的判别光谱空间特征。由于交叉光谱注意力模块和交叉空间注意力模块的有效性，所提出的交叉注意力卷积神经网络优于所有其他对比方法。

PU 数据集上的伪彩色图像、ground truth 图像、训练像素和视觉分类图如图 3-4 所示。由于 1-DCNN 不能有效地探索空间信息，所以 1-DCNN 的分类图有很大的噪声。从 DHCNet、SMBN、SpecAN 和 SSAN 的分类图可以看出，误分类像元主要分布在各个地物区域的边缘附近。这些方法性能不佳的原因有两个：一方面，由于高光谱图像块中存在不同类别的像素，会干扰波段权值的生成。另一方面，在区域边缘附近，高光谱图像块可能在各个方向上都有等高线，这也是由于高光谱图像旋转造成的问题。二维和三维卷积无法从这些高光谱图像块中提取鲁棒的特征。交叉注意力卷积神经网络的分类图相对平滑，在各个地表覆盖区域的边缘附近都有较好的分类结果，可以说明交叉注意力卷积神经网络的有效性。




图 3-4 在 PU 数据集上与其他算法的可视化对比

Figure 3-4 False color image, ground truth, training pixels, and classification maps of CASSN and compared methods on the PU database

2) IP 数据集

在 IP 数据集上进一步评估交叉注意力卷积神经网络的性能。表 3-8 报告了 IP 数据集的定量性能。在“Alfalfa”，“Grass-Pasture-Mowed”，和“Oats”类中，

训练像素的数量非常少，这使得高光谱图像分类具有挑战性。1-DCNN 在 “Alfalfa,” “Grass-Pasture-Mowed,” 和 “Oats” 中分别达到 65.85%、40.00% 和 50.00%。2-D CNN、SMBN 和 SSAN 在 “Alfalfa,” “Grass-Pasture-Mowed,” 和 “Oats” 类的性能远远弱于 1-DCNN。这说明训练样本太少会使 2-DCNN、SMBN 和 SSAN 难以学习有效的空间特征。在 IP 数据集的大多数类别中，提出的交叉注意力卷积神经网络优于对比方法。

表 3-8 每类的精度，不同方法在 IP 数据集上的分类结果

Table 3-8 Accuracy in each category, OA, AA, and Kappa of different methods on the IP database

类别	OTVCA	1-D CNN	2-D CNN	DHCNet	SMBN	SpecAN	SSAN	miniGCN	GFNet	CASSN
1	90.24	65.85	24.39	34.15	51.22	85.61	39.02	24.39	100.00	100.00
2	95.10	72.45	70.43	90.82	88.87	88.48	91.21	58.83	896.39	93.23
3	92.37	61.58	81.53	85.54	78.05	89.83	91.03	58.90	82.43	92.37
4	77.46	60.09	84.45	84.98	73.24	75.59	78.40	47.42	82.14	93.90
5	94.70	88.48	77.88	93.09	90.09	94.70	96.31	89.63	92.86	98.16
6	99.09	95.13	95.59	96.35	95.89	97.72	98.63	95.74	98.80	99.24
7	72.00	40.00	32.00	96.00	24.00	96.00	32.00	4.00	50.00	100.00
8	99.77	97.91	98.14	99.77	93.26	99.07	100.00	97.44	100.00	99.30
9	66.67	50.00	28.89	44.44	22.22	66.67	22.22	0.00	100.00	88.89
10	90.16	67.36	70.71	86.96	78.26	87.99	89.02	80.82	83.75	93.59
11	97.37	80.31	89.45	93.38	96.60	97.06	94.88	61.61	87.71	98.14
12	90.43	69.61	53.47	82.47	77.11	85.74	79.92	66.04	94.34	94.18
13	97.28	91.85	98.91	97.28	91.30	96.20	99.46	95.11	100.00	98.81
14	98.07	94.90	93.06	98.59	96.75	99.03	96.75	88.48	97.67	99.74
15	76.66	60.52	65.71	85.30	87.90	90.20	89.34	42.07	71.88	97.41
16	96.36	93.98	96.39	91.57	95.18	93.39	98.80	95.18	88.89	98.80
OA	94.35	78.82	81.76	92.23	89.13	93.10	92.42	70.38	89.76	96.55
AA	89.61	74.38	73.25	85.25	77.50	89.11	81.06	62.25	88.55	96.62
Kappa	93.54	75.73	79.13	91.13	87.55	92.141	91.34	66.60	88.30	96.07

图 3-5 显示了 IP 数据集上的伪彩色图像、ground truth 图像、训练像素和视

觉分类图。比较的方法在 IP 数据集的区域边缘附近仍然表现不佳。1-DCNN 的分类图并不光滑。在 IP 数据集中, 几种地物的区域形状 (“Alfalfa”, “Grass-Pasture-Mowed”, 和 “Oats”) 都很窄。对比方法在这些狭窄的地物中表现不佳。虽然交叉注意力卷积神经网络的分类图是平滑的, 但被交叉注意力卷积神经网络误分类的像素也主要集中在区域边缘。这表明对区域边缘附近的像素进行分类是非常具有挑战性的。如何有效利用高光谱图像所包含的空间信息, 还有待进一步研究。




图 3-5 在 IP 数据集上与其他算法的可视化对比

Figure 3-5 False color image, ground truth, training pixels, and classification maps of CASSN and compared methods on the PU database

3) Salinas 数据集

进一步利用 Salinas 数据集来演示交叉注意力卷积神经网络的性能。表 3-9 报告了关于 Salinas 数据集的定量实验结果。Salinas 数据集主要包括不同的作物。由于几种作物的光谱差异很大, 只有利用光谱才能区分几种作物。1-DCNN 对 8 类地物的分类准确率超过 99%, 这 8 类中包含例如 “Fallow” 和 “Lettuce Romaine 5wk” 难度较高的类别。在 Salinas 数据集中, 由于引入了空间信息, DHCNet、SMBN、SpecAN 和 SSAN 在每一类地物上的表现都优于 1-DCNN。所提出的交叉注意力卷积神经网络在 12 种地物类型上优于其他对比方法。

图 3-6 展示了 Salinas 数据集上的伪彩色图像、ground truth 图像、训练像素和视觉分类图。在 “Grapes Untrained” 类别的边缘, 对比方法显示出较差的性能。1-DCNN 在 “Grapes Untrained” 和 “Vinyard Untrained” 类别中的分类图含有大量的噪声。由于 “Grapes Untrained” 和 “Vinyard Untrained” 两类像素的光谱非常相似, 本章提出的交叉注意力卷积神经网络和对比方法很容易混淆这

两类像素。

表 3-9 每类的精度，不同方法在 Salinas 数据集上的分类结果

Table 3-9 Accuracy in each category, OA, AA, and Kappa of different methods on the Salinas database

类别	OTVCA	1-D CNN	2-D CNN	DHCNet	SMBN	SpecAN	SSAN	miniGCN	GFNet	CASSN
1	99.58	98.59	99.47	99.63	99.53	99.95	99.74	98.95	100.00	100.00
2	98.76	99.61	97.74	99.92	99.67	99.31	99.72	99.83	100.00	99.94
3	99.41	99.47	98.93	98.19	97.97	100.00	99.52	99.57	100.00	99.52
4	99.61	99.69	95.83	99.77	99.30	99.46	99.30	99.69	99.31	99.85
5	97.44	97.83	98.76	99.30	98.29	98.33	98.76	98.18	100.00	98.91
6	99.48	99.79	99.48	99.87	99.61	99.97	100.00	99.84	100.00	99.97
7	97.93	99.57	99.31	99.31	99.48	99.80	99.83	99.91	100.00	99.97
8	88.29	73.82	72.36	83.62	86.23	83.33	98.11	79.67	87.39	91.04
9	98.30	99.00	93.64	99.43	94.99	99.44	99.92	99.95	99.84	99.97
10	91.76	91.25	95.12	96.98	94.68	98.40	96.85	92.89	98.76	99.40
11	97.93	96.28	97.83	100.00	98.97	99.07	99.28	96.90	100.00	99.28
12	100.00	99.95	98.25	99.23	99.84	99.67	100.00	99.59	100.00	100.00
13	98.65	99.51	100.00	99.75	99.63	99.75	99.75	99.14	100.00	100.00
14	98.97	94.74	98.76	99.90	99.38	99.76	99.90	93.30	99.04	99.90
15	95.88	71.04	87.05	91.16	82.23	88.66	86.70	68.04	85.51	92.41
16	98.83	93.91	95.78	97.72	98.18	98.48	96.95	98.42	100.00	99.59
OA	95.70	89.21	90.61	94.77	93.37	94.50	94.99	90.45	95.40	96.91
AA	97.55	94.63	95.54	97.74	96.75	97.71	97.72	95.27	98.12	98.73
Kappa	95.21	87.98	89.57	94.18	92.61	93.88	94.42	89.35	94.89	96.55

从图 3-6 的结果可以看出，利用交叉注意力卷积神经网络的光谱空间特征并不能有效区分这两者类别。如何设计一种具有分辨力的空间特征提取器来区分这两类特征，仍需进一步研究。如图 3-6 所示，本章的交叉注意力卷积神经网络对比方法具有更平滑的分类图。




图 3-6 在 Salinas 数据集上与其他算法的可视化对比

Figure 3-6 False color image, ground truth, training pixels, and classification maps of CASSN and compared methods on the PU database

(4) 图像块大小的影响

大尺寸的高光谱图像块将引入更多的空间信息，这可能会影响交叉注意力卷积神经网络的性能。本小节探讨了不同大小高光谱图像块的交叉注意力卷积神经网络的性能。表 3-10 中报告了具有 5×5 至 13×13 个高光谱图像块的交叉注意力卷积神经网络的 OA。如表 3-10 所示，当使用大尺寸的高光谱图像块进行分类时，提议的交叉注意力卷积神经网络将有更好的结果。在 PU 和 IP 数据集中，当高光谱图像块的尺寸超过 9×9 时，大尺寸带来的性能改善率逐渐下降。

表 3-10 不同高光谱图像块尺寸对分类精度的影响

Table 3-10 OAs(%) of CASSN with different sizes of HSI patches

	5×5	7×7	9×9	11×11	13×13
PU	96.16	96.82	97.58	97.61	97.70
IP	95.83	96.28	96.55	96.52	96.62
Salinas	94.19	95.90	96.91	97.41	97.89

（5）训练样本数量的影响

在遥感领域，获取大量的有标注训练样本需要非常高的人力成本。我们进一步研究交叉注意力卷积神经网络在不同数量的训练样本下的性能。由于 IP 数据集中不同类别的样本数量 IP 数据集中不同类别的样本是不平衡的，而几个类别的样本数量只有 20 多个，IP 数据集不便于进行不同样本量的实验。实验是在 PU 和 Salinas 数据集上进行的。每个类别的训练样本数分别设置为 10、25、50、75、100、150、200 个进行实验。表 3-11 中列出了不同训练样本数的交叉注意力卷积神经网络的 OA。由于所提出的交叉注意力卷积神经网络不是专门为小样本问题设计的，当训练样本数为 10 时，所提出的交叉注意力卷积神经网络的性能大大下降。随着样本数的增加，交叉注意力卷积神经网络的性能明显提高。在未来，我们将研究新的轻量级卷积神经网络来处理小样本问题。

表 3-11 每个类别训练样本数对分类精度的影响

Table 3-11 OAs (%) of CASSN with different numbers of training samples in each category

	10	25	50	75	100	150	200
PU	72.75	86.92	92.58	95.67	97.58	98.59	98.79
Salinas	85.60	91.66	95.64	95.93	96.91	97.40	98.22

（6）计算成本

交叉注意力卷积神经网络的权重参数和 FLOPs 数量与数据集中的波段和地物类别的数量有关。由于 IP 数据集和 Salinas 数据集的波段和地物类别的数量多于 PU 数据集，交叉注意力卷积神经网络在 IP 数据集和 Salinas 数据集上的权重参数和 FLOPs 的数量多于 Pavia 大学的数据集。在 PU 数据集、IP 数据集和 Salinas 数据集中，交叉注意力卷积神经网络的权重参数分别为 49467、102682 和 104970。在 PU 数据集、IP 数据集和 Salinas 数据集中，交叉注意力卷积神经网络的 FLOPs 数量分别约为 3.20M、4.48M 和 4.53M。

表 3-12 中报告了不同方法的时间成本。在本章中，所有神经网络方法都是用 TensorFlow 重新实现的，并在配备 Intel Core i7-5930K、64G 内存和 NVIDIA Titan X 的工作站上运行。交叉注意力卷积神经网络的训练和测试时间与 2D-CNN 和 SpecAN 接近。所提出的交叉光谱注意和交叉空间注意模块是基于简单的卷积操作，并没有明显增加时间成本。提出的交叉注意力卷积神经网络不仅具有良好的分类性能，而且耗时较少。

表 3-12 不同方法训练测试时间（秒）
Table 3-12 Training and testing time (seconds) of each method

	PU		IP		Salinas	
	训练	测试	训练	测试	训练	测试
OTVCA	182.71	1.47	27.95	0.23	131.80	0.81
1D-CNN	35.23	3.51	70.81	1.47	109.61	8.30
2D-CNN	40.85	4.04	75.74	1.67	122.56	9.51
DHCNet	80.21	9.34	121.80	2.62	192.32	14.44
SMBN	67.82	5.37	107.54	1.86	167.21	11.15
SpecAN	47.48	4.41	83.17	1.68	133.30	9.89
SSAN	326.74	23.08	738.43	10.63	1160.25	59.06
miniGCN	241.84	11.92	82.49	8.36	476.74	19.07
GFNet	273.05	12.57	214.37	9.06	522.14	22.95
CAASN	53.22	4.35	88.33	1.72	141.25	9.82

3.4 本章小结

本章提出了一种交叉注意力卷积神经网络，以缓解以往方法对高光谱图像旋转的鲁棒性不足的问题。首先，提出了一种交叉光谱注意力，充分挖掘像素内光谱的局部信息和全局信息，同时重新校准像素内波段和高光谱图像块的重要性。其次，设计了光谱特征提取对像素和高光谱图像块进行光谱维度的特征提取。最后，提出了一种融合像元特征和高光谱图像块特征的光谱空间特征提取方法，该方法对高光谱图像旋转具有鲁棒性。提出的交叉注意力卷积神经网络在三个公共数据集上的性能优于对比方法，达到了领域内的先进水平。

第4章 基于局部注意力选择 Transformer 的遥感图像分类

4.1 引言

伴随着 Transformer 网络的快速发展,在图像特征提取与全局样本特征表示方面逐渐展现出了巨大的潜力。然而,由于遥感图像和常见图像存在尺度,内容上的差异,直接使用计算机视觉领域的方法可能面临一些问题。具体来说,遥感图像往往是俯视角拍摄,随着视角变化地物和目标视觉特性可能发生较大的变化。另一方面,遥感图像往往尺度较大,一张图像中包含的地物信息可能非常复杂,目标类型众多,对模型的特征提取能力有着更高的要求。为了探索 Transformer 网络在高光谱遥感图像分类的可能性,本章首先在遥感场景分类任务上对 Transformer 网络的特征提取能力进行研究。

遥感场景分类的目的是给一张未知类别的遥感图像分配一个语义标签,它是遥感图像解译中一个基础且重要的任务。遥感场景分类在许多领域发挥着重要的作用,如目标检测^[129],图像检索^[130],视觉问答^[131]等。遥感场景分类与自然图像分类一样,大致过程为首先提取图像特征,然后再进行分类。由于前景结构和空间背景的复杂性,要想对遥感图像进行准确的分类,其重点是如何提取到具有判别性的特征。




图 4-1 遥感图像样例

Figure 4-1 Remote sensing image examples

由于遥感场景范围大,背景复杂,遥感图像中的判别区域通常占比小或是被复杂背景所包围,通常很难准确识别出判别性区域。图4-1为遥感图像示例,在图4-1中展示了6种常见的遥感场景,其中包括篮球场、机场、教堂、湖泊、油罐以及体育场。其中,篮球场判别性区域部分被树遮挡;飞机目标小,场景大;以及教堂的背景复杂,这都增加了分类难度。为了解决这一问题,研究人员提出了一些基于卷积神经网络的方法来学习全局-局部特征以提高对判别区域的区分能力^[132,133]。过去的方法常常通过融合不同层次特征来学习全局-局部特征;引入注意力机制关注局部判别性区域,或是采用两个分支分别提取全局-局部特征。Wang 等人^[134]设计了一种自适应的高维特征通道降维方法。然后,引入多层特征融合模块对特征进行有效融合。Ji 等人^[135]提出了一种利用注意力网络对遥感场景图像的多尺度判别区域进行局部化,并结合分类网络从局部区域学习到的特征的方法。Chen 等人^[136]提出了一种局部-全局互学习的遥感场景分类方法,利用互学习方法使得局部分支和全局分支相互学习,相互促进。然而,卷积神经网络通常使用带有局部感受野的滤波器,主要利用图像的局域性,很难捕捉到远距离依赖。

除了卷积神经网络,另一种深度学习模型——Transformer 也逐渐流行起来。起初 Transformer 针对自然语言处理进行设计,将一个句子作为一个整体来处理,直接建立整个句子各个成分直接的关系,不会丢失或遗忘过去距离较远的单词中包含的信息。此外,多头注意力和位置嵌入都提供了不同单词之间的关系信息。鉴于 Transformer 在自然语言处理中的强大表现,研究人员开始尝试将其用于图像分类任务中。Dosovitskiy 等人^[28]提出了视觉 Transformer (Vision Transformer, ViT),ViT 将图像划分为不同的图像块,并将这些图像块排列成序列并进行位置编码输入到 Transformer 中。Chen 等人^[137]提出一个双分支 Transformer,将不同大小的图像块结合起来,以产生更具判别性的图像特征。Liu 等人^[138]在 ViT 的基础上加入了滑窗的思想,提出了 Swin-Transformer。ViT 在 ImageNet 上取得了非常有竞争力的结果,受到了广泛关注并已成功应用于各个领域,如图像分割^[31],目标检测^[139],目标追踪^[140]等。

Transformer 能够学习到上下文关系,并且其含有的多头注意力机制可以捕获图像中重要区域,在捕捉局部和全局特征方面有着强大能力。因此,ViT 模型也已被研究用于场景分类以获取更具判别性的高分辨率遥感图像的特征。Bazi 等人^[141]将预训练的 ViT 模型与数据增强和网络修剪相结合,以提高分类性能。Zhang 等人^[142]设计了一个结合卷积神经网络和 ViT 的网络结构用于遥感场景分类。因此,本文提出了一个基于局部注意力选择的 Transformer (Local Selection ViT, LSViT) 网络,将 ViT 用于遥感场景分类,另外,为了进一步提取判别性特征,在最后一个 Transformer 输入前,引入局部选择模块^[139]。其主要过程为:首先将图片划分为不同图像块,对这些图像块进行位置编码,同时

加入一个**分类向量**。并输入 Transformer 的编码器。在最后一个 Transformer 输入前，**将前面每一层的注意力权重融合，以此选择包含判别性区域的 Token 作为最后一层的输入**，忽略冗余信息。**同时将分类向量与选择的部分 Token 连接以此保留全局信息**。最后通过分类器进行输出。

本文的主要贡献如下：

- (1) 提出了一个局部注意力选择的 Transformer 网络应用于遥感场景分类，**利用 Transformer 提取图像特征，学习图像上下文之间的关系**。
- (2) **采用局部选择模块，选择具有辨别性的 Token**，去除冗余信息带来的干扰，提高网络辨别性。
- (3) 通过实验结果证明，该方法在两个 AID 数据集以及 NWPU 数据集上取得了有竞争力的结果。

4.2 研究方法

LSViT 的网络结构如图 4-2 所示，**其主要使用 ViT 提取图像特征**。图 4-2 左边为网络整体框架，**图像以分割后形成的图像块形式输入到线性映射层中**，而 Transformer 编码器的输入包括**图像块嵌入和位置编码**。为了增强对局部判别区域特征表达力，**将 ViT 中编码器的倒数第二层修改为局部选择模块**。局部选择模块用于**选择与图像块相对应的标记**，并且只使用**这些被选择的标记作为最后 Transformer 层的输入**。图 4-2 中间为 Transformer 层内部结构，图 4-2 右边为自注意力计算流程，具体内容将在后面小节中介绍。在这一节中，**首先介绍了本文用到的预处理方法以及 ViT 的网络结构**。然后，详细描述了用到的局部选择模块。最后介绍损失函数。




图 4-2 LSViT 的网络结构
Figure 4-2 Network structure of LSViT

4.2.1 视觉 Transformer

ViT 能够通过多头注意力提取序列之间的长依赖关系，能充分挖掘图像之间

的上下文信息，因此本文采用 ViT 提取特征。

在图片被输入至 ViT 层之前，首先将其分割成图像块序列。在 ViT 中，采用原始的分割方法将直接图像分割成不重叠的小块，没有任何的预处理。当分割判别区域时，这容易损害局部相邻结构。为了缓解这一问题，本文使用滑动窗口生成重叠图像块^[138]，利用滑动窗口的思想，使得上下和左右向量的两个图像块之间都有一个重叠部分。具体来说，输入图像的大小为 $W \times H$ ，每个图像块大小为 S ，滑动窗口的步长为 L 。故输入图像将会分割为 N 个图像块。

$$N = N_H * N_W = \left\lfloor \frac{H-S+L}{L} \right\rfloor * \left\lfloor \frac{W-S+L}{L} \right\rfloor \quad (4-1)$$

因此两个相邻的图像块共享一个重叠的区域： $(S-L)*S$ 。这样可以保存更多局部区域。

将得到的图像块进行向量化，每张图片可以表示成向量 $[x_1, x_2, \dots, x_N]$ 。使用线性投影将上述向量映射的一个 D 维嵌入空间并加入一个可学习的位置嵌入。为了便于分类，嵌入的图像块必须与一个可学习的分类嵌入向量 x_{class} 连接，则输入为：

$$\mathbf{z}_0 = [x_{class}, x_p^1 \mathbf{E}, x_p^2 \mathbf{E}, \dots, x_p^N \mathbf{E}] + \mathbf{E}_{pos} \quad (4-2)$$

其中， $\mathbf{E} \in \mathbb{R}^{(S^2 \times C) \times D}$ 为图像块嵌入投影， $\mathbf{E}_{pos} \in \mathbb{R}^{N \times D}$ 表示位置嵌入。

将包含 $N+1$ 个 Token 的 $\mathbf{z}_0$ 输入 ViT 的编码器，编码器主要由 L 个相同的层组成，每一层主要包含两个主要的子组件：多头注意力（Multiheaded Self-Attention, MSA）和多层感知机（Multilayer Perception, MLP）。MSA 与 MLP 都使用跳跃连接，并在之前都有一个层归一化（Layer Norm, LN）。MSA 是编码器中的核心模块，自注意（Self-Attention, SA）头通过计算查询（Query, Q）-键（Key, K）-值（Value, V）的缩放点积来学习注意力的权重。对于输入序列中的元素，通过将元素与三个学习过的矩阵 U_{QKV} 相乘，产生三个值：Q, K, V。为了确定序列上某个元素与其他元素之间的相关性，计算该元素的 Q 向量与其他元素的 K 向量之间的点积。计算结果表示图像块在序列中的相对重要性。然后将点积的结果进行缩放，并输入到 Softmax。SA 块所进行的缩放点积运算与标准的点积运算类似，但它加入了 D_K 的维数作为缩放因子。最后，将每个图像块嵌入的向量值乘以 Softmax 的输出，得到注意力得分较高的图像块：

$$[Q, K, V] = z U_{QKV}, \quad U_{QKV} \in \mathbb{R}^{d \times 3D_K} \quad (4-3)$$

$$A = \text{softmax} \left(\frac{QK^T}{\sqrt{D_K}} \right), \quad A \in \mathbb{R}^{n \times n} \quad (4-4)$$

$$\text{SA}(z) = A.V \quad (4-5)$$

MSA 块使用前面的操作分别计算多个头部的点积注意力，使用多个值进行

Q , K , V 运算。将所有注意力头的结果连接在一起, 然后通过一个具有可学习权重 $\mathbf{W}$ 的前馈层投影到所需的维度:

$$\text{MSA}(z) = \text{Concat}(\text{SA}_1(z); \text{SA}_2(z); \dots; \text{SA}_h(z)) \mathbf{W}, \quad \mathbf{W} \in \mathbb{R}^{h \cdot D_K \times D} \quad (4-6)$$

MLP 由两个全连接层以及中间加上 GeLU 组成。则 Transformer 的编码器中的主要过程为:

$$z'_l = \text{MSA}(\text{LN}(z_{l-1})) + z_{l-1}, \quad l = 1 \dots L \quad (4-7)$$

$$z_l = \text{MLP}(\text{LN}(z'_l)) + z'_l, \quad l = 1 \dots L \quad (4-8)$$

其中, z_l 表示编码后的特征。在编码器的最后一层, 取 $\mathbf{z}_L^0$ 中的第一个 Token 作为图像的全局特征表达, 并将其传递给分类器用于预测标签。

4.2.2 局部选择模块

考虑到遥感场景范围大, 背景复杂等因素, 通常使得遥感图像包含大量类别无关区域以及少量类别判别区域。关注这些有判别性的局部区域更有助于分类。因此, 引入局部选择模块来捕获局部信息以此增加网络的判别力。

由于最后输出的全部 Token 过多地包含了全局的信息, 而判别信息只包含在部分 Token 里。因此在编码器最后一层 L 层输入之前, 选择包含更多具有判别性特征的 Token 作为输入, 而忽略掉包含冗余信息的 Token。具体操作为:

第 $L-1$ 层输出的隐藏特征为 $z_{L-1} = [z_{L-1}^0; z_{L-1}^1, z_{L-1}^2, \dots, z_{L-1}^N]$, 之前某层的注意力权重可以表示为:

$$\mathbf{a}_l = [a_l^0, a_l^1, a_l^2, \dots, a_l^K] \quad l \in 1, 2, \dots, L-1 \quad (4-9)$$

其中, K 为多头自注意力中自注意力头的个数。

每个自注意力头的权重为:

$$a_l^i = [a_l^{i_0}, a_l^{i_1}, a_l^{i_2}, \dots, a_l^{i_N}] \quad i \in 0, 1, \dots, K-1 \quad (4-10)$$

当输入到编码器较高层时, 网络得到的单层注意力权重并不一定能代表原始输入 Token 的重要性。因为经过多层运算后, 此时得到的高层 Token 的可识别性不足^[143]。因此, 将前面各层的注意力权重融合, 即将所有层得到的注意力权重相乘, 得到:

$$\mathbf{a}_{final}^i = \prod_{l=1}^{L-1} \mathbf{a}_l \quad (4-11)$$

由于 $\mathbf{a}_{final}$ 整合了从低层到高层的注意力权重, 捕获了信息如何从输入层传

播到更高层，与单层原始注意权值 a_{L-1} 相比，它更有助于选取包含鉴别区域的 Token。因此从 $\mathbf{a}_{final}$ 中权重最大中的 h 个不同的注意力头中选择最大值 $Max_1, Max_2, \dots, Max_h$ ，并提取其索引得到 z_{L-1} 中相应的 h 个得分最高的 Token。最后，将得到的 Token 和分类的 Token 进行连接，作为下一个模块的输入序列：

$$z_{local} = [z_{L-1}^0; z_{L-1}^{Max_1}, z_{L-1}^{Max_2}, \dots, z_{L-1}^{Max_h}] \quad (4-12)$$

通过连接分类的 Token， z_{local} 保留了全局信息。同时也让更具有判别性的 Token 作为最后一层的输入，忽略包含背景的 Token，使得模型更加关注判别区域，从而提升网络的性能。

4.2.3 损失函数

将 z_{local} 输入编码器最后一层 L 层，则最后一层输出为：

$$z'_L = \text{MSA}(\text{LN}(z_{local})) + z_{local} \quad (4-13)$$

$$z_L = \text{MLP}(\text{LN}(z'_L)) + z'_L \quad (4-14)$$

与 ViT 相同，分类仍采用最后一层输出的第一个 Token 进行分类。分类损失采用交叉熵损失：

$$y' = \text{LN}(z_L^0) \quad (4-15)$$

$$q = \text{softmax}(\mathbf{W}y' + \mathbf{b}) \quad (4-16)$$

$$\mathcal{L}_c = -\sum y^T \log(q) \quad (4-17)$$

其中， $q \in \mathbb{R}^N$ 是预测得分向量， N 是数据集的类别数， $\{\mathbf{W}, \mathbf{b}\}$ 是全连接层的权重和偏差。 y 表示 Ground Truth 标签的 One-hot 向量。

4.3 实验验证

4.3.1 数据集与评价指标

为了验证本章所提出的网络的有效性，需要在数据集上进行实验。本章选用了遥感领域常用的分类数据集 AID 数据集和 NWPU-RESISC45 数据集。

其中 AID 数据集中的图像来自于 Google Earth，其中共有 30 个场景类别，每个类别中的场景图像数量为 300 张左右。每张图像像素数量为 600×600 ，空间分辨率为 0.5~8m。图 4-3 展示了 AID 数据集部分类别的典型图像样例，包括机场，棒球场，桥梁，沙漠，森林，山脉，公园，学校，储存罐。为了与在实验中与其他方法进行公平对比，在所有方法在 AID 数据集上的实验中都采用了两种训练-测试策略：第一种是随机选择 20% 的样本用于训练，其余 80% 用于测试；第二种是随机选择 50% 样本用于训练，其余 50% 用于测试。

NWPU-RESISC45 数据集中的图像来源与 AID 相同，是 Google Earth。相比

于 ADI, NWPU-RESISC45 具有更大的数据规模。该数据集中有更多的场景类别, 类别数量达到了 45 个。每个类别的图像数量约为 700, 空间分辨率为 0.2~30m。每张图像的尺寸为 256x256 像素。NWPU-RESISC45 数据集是当前应用最广泛的分类数据集之一, 因为它包含了丰富的场景类别和大量的样本数据, 同时也被广泛应用于分类方法的评价和比较。



图 4-3 AID 数据集示例

Figure 4-3 Examples of AID dataset

图 4-4 展示了 NWPU-RESISC45 数据集部分类别的示例, 包括飞机, 机场, 海滩, 云层, 高尔夫球场, 港口, 岛屿, 宫殿和船只。为了与在实验中与其他方法进行公平对比, 在所有方法在 NWPU-RESISC45 数据集上的实验中都采用了两种训练-测试策略: 第一种是随机选择 10% 的样本用于训练, 其余 90% 用于测试; 第二种是随机选择 20% 样本用于训练, 其余 80% 用于测试。训练和测试

的过程中将所有输入图像大小统一调整为 224×224 像素。为了提高模型的泛化能力，在训练中加入了数据增强操作。具体来说，数据增强手段包含随机 30° 旋转，水平翻转以及垂直翻转。实验的评价指标为总体精度（Overall Accuracy, OA）。



图 4-4 NWPU-RESISC45 数据集示例

Figure 4-4 Examples of NWPU-RESISC45 dataset

4.3.2 实验设置

实验基于 Python 编程语言实现，采用 PyTorch 深度学习框架进行网络搭建。实验平台中主要运算设备为 4 个 12GB 英伟达 GeForce Titan X GPU。将输入图像分割为大小为 16×16 的图像块，设置滑动窗口的步长为 14。网络的 backbone 模型为在 ImageNet21k 上预训练的官方 ViT-B₁₆ 模型。由于 GPU 的限制，Batch 的大小设置为 8。优化器采用随机梯度下降（Stochastic Gradient Descent, SGD）

优化器，动量为 0.9。学习率初始化为 0.03，采用余弦退火策略作为优化器的调度器。

4.3.3 实验结果与分析

(1) 消融实验

消融实验在 20%划分的 AID 数据集上进行，为了对比实验的公平性，在用不同策略评估提出方法时，其他设置与实现细节中的设置保持一致。

1) 图像块划分对比

在对图像块进行划分时，本文采用了滑动窗口的方式以获取重叠的图像块，这样能避免丢失部分信息，为了验证该方法的有效性，本文探索了获取重叠图像块与非重叠图像块对实验结果的影响，如表 4-1 所示。采用重叠的图像块之后分类效果得到了提升，且增加的训练时间几乎可以忽略。

表 4-1 不同图像块划分比较结果

Table 4-1 Comparison results of different Patch divisions

图像块划分方式	OA/%	训练用时/min
非重叠	95.21	59.82
有重叠	95.33	62.91

2) 滑动窗口步长的影响

LSViT 在对图像块进行划分时，采用了滑动窗口的方法划分出包含重叠区域的图像块。本文探索了当滑动步长为 8, 10, 12, 14 以及 16（即非重叠）时对网络的影响。实验结果如表 4-2 所示，当选择滑动步长为 14 时，LSViT 达到最佳性能。当滑动步长很小时，相邻的图像块之间存在大量的重复像素，每两个相邻 token 之间的相似性大大增加，可能会对全局样本之间的特征关系度量造成一定的干扰，因此在步长从 8 增加至 14 时，分类精度逐渐提升。而当滑动步长等于窗口尺寸，即非重叠的情况下，可能会存在图像中相邻的不同地物刚好被两个窗口分割开的情况，对空间信息的提取造成影响，因此步长从 14 增加至 16 时，出现了精度下降的情况。

3) 局部选择模块的影响

为了使网络能提取判别性特征，本文采用局部选择模块来挑选出含有判别性区域的 Token，抛弃一些无用区域。为了验证局部选择模块的有效性，将提出的 LSViT 与 ViT 进行对比，此时 ViT 的图像块选择方式为重叠方法。实验结果见表 4-3，由实验结果可得，使用局部选择模块的效果更好。

表 4-2 不同步长比较结果

Table 4-2 Comparison results of different step sizes

Step size	OA/%
8	94.73
10	94.9
12	95.12
14	95.33
16	95.21

表 4-3 局部选择模块的影响结果

Table 4-3 Impact results of local selection module

Method	OA/%
ViT+ Overlapping	95.01
LSViT	95.33

4) 与卷积神经网络的结果对比

为了探索使用 ViT 作为 backbone 的有效性, 本文将 ViT 以及提出的 LSViT 与一些常用卷积神经网络模型进行对比, 实验结果如表 4-4 所示。结果表明, 相比于卷积神经网络模型, ViT 在遥感场景分类中表现出更强大的性能, 而提出的 LSViT 相比于 ViT 获得更高的分类结果。

(2) 与其他方法的对比实验

为了验证提出方法的有效性, 表中列出了一些先进的基于卷积神经网络的方法, 并在 AID 和 NWPU RESISC45 这两个相对大规模的数据集上与本文提出的 LSViT 进行了比较。对比方法包括以下几种:

1) 门控双向网络 (Gated Bidirectional Network, GBNet) [96]。

该网络是一个端到端的图像分类网络。首先对每个卷积函数的性能进行定量分析, 然后检验卷积函数的性能, 提出双向门控操作以在多个卷积层中进行分层聚合操作。同时采用了自上而下方向和自下而上的两种方向的卷积特征聚合方式来生成语义辅助特征和表观辅助特征。

表 4-4 与卷积神经网络模型对比结果
Table 4-4 Comparison results with CNN model

方法	OA/%
VGG16	88.18
GoogleNet	92.88
ResNet-18	92.96
ResNet-50	93.24
ViT	94.90
LSViT	95.33

2) 改进的双线性卷积神经网络 (Improved bilinear CNN, IBCNN) 网络^[144]。该网络中提出了一种联合池化方法来抑制高维双线性特征, 并将其嵌入到双线性卷积神经网络架构中进行端到端优化。与常规双线性卷积神经网络模型相比, IBCNN 模型采用一种联合池化方法来减少超高维双线性池化特征, 进一步提高了特征的判别能力。

3) 自适应通道降维多特征融合网络 (Multilevel Feature Fusion Networks with Adaptive Channel Dimensionality Reduction, ACR-MLFF)^[134]。该网络是一种自适应的高维特征通道降维网络, 它利用深度卷积神经网络的多层次特征, 提出自适应通道降维模块来解决由卷积通道维引起的信息丢失问题。它包含一个用于降维的主干分支和两个用于增强通道注意力和补充语义信息的侧分支, 分别实现了自适应性通过顶部分支的通道注意力计算对特征进行重新加权。还提出了多层特征融合模块, 将多级和自适应通道缩减功能集成在一起, 对特征进行有效融合。

4) 自注意力深度特征融合方法 (Self-Attention-Based Deep Feature Fusion, SAFF)^[145]。该方法以聚合深层特征并强调遥感场景图像的复杂对象的权重进行分类。使用预训练的卷积神经网络进行多层特征提取, 然后提出了一种非参数自注意力层用于空间和通道加权, 增强特征中空间信息的权重, 在特征中更注重提取出现频率较低的样本的权重, 从而提取更具判别性的特征。最后, 将聚合后的特征输入支持向量机进行分类。

5) 注意力网络定位方法^[135]。该方法是一种利用注意力网络来提取多尺度判别性区域的分类方法, 同时在网络中结合了局部区域特征提取。该网络主要由三个子网络组成, 这些子网络分别在不同尺度的区域上进行训练。为了学习判别性更强的特征, 最后提出了特征融合模块将三个子网络提取的特征进行有效融合。

表 4-5 在 AID 数据集与最先进方法进行比较
Table 4-5 Comparison with state-of-the-art methods in the AID dataset

方法	主干网络	AID 数据集 (OA/%)	
		20%训练样本	50%训练样本
GBNet ^[96]	VGG16	92.20±0.23	95.48±0.12
IB-CNN ^[144]	MobileNet-V2	94.23±0.16	96.57±0.28
ACR-MLFF ^[134]	ResNet-50	92.73±0.12	95.06±0.33
SAFF ^[145]	VGG-VD16	90.25±0.29	93.83±0.28
Ji et.al. +VGG-VD16 ^[135]	VGG-VD16	94.75±0.23	96.93±0.16
ResNet50+ EAM ^[146]	ResNet50	93.64±0.25	96.62±0.13
CNN-GCN ^[147]	VGG16	94.93±0.31	96.89±0.10
SKAL ^[148]	ResNet18	94.38±0.10	96.76±0.20
LSViT	ViT	95.33±0.05	97.55±0.12

6) 基于增强注意模块 (Enhanced Attention Module, EAM) 的网络^[146]。该网络中采用了增强的通道注意力和增强的空间注意力, 用于提高卷积神经网络的抽象表示和特征提取能力。

7) 卷积-图卷积网络 CNN-GCN^[147]。该网络结合了全局的视觉特征和对象位置特征的双分支网络架构, 能够有效提高特征的表示能力。该网络基于卷积神经网络从整个场景图像中提取外观视觉特征然后检测地面的目标并构建拓扑图, 基于图卷积网络学习目标之间的空间位置特征。

8) 结构关键区域定位方法 (Structured Key Area Localization, SKAL)^[148]。该网络通过全局-局部双分支网络架构实现图像特征的多尺度表示。该架构有全局流和局部流两个分支, 可以从图像中最关键的判别性区域分别提取全局特征和局部特征。为了仅使用图像级标签来定位整个图像中的关键区域, 提出了结

构化关键区域定位 (SKAL) 的弱监督关键区域检测方法, 将两个网络分支进行合并。

表 4-6 在 NWPU-RESISC45 数据集与最先进方法进行比较

Table 4-6 Comparison with state-of-the-art methods in the NWPU-RESISC45 dataset

方法	主干网络	NWPU-RESISC45 数据集 (OA/%)	
		10% 训练样本	20% 训练样本
IB-CNN ^[144]	MobileNet-V2	90.49±0.17	93.33±0.21
ACR-MLFF ^[134]	ResNet-50	90.01±0.33	92.45±0.20
SAFF ^[145]	VGG-VD16	84.38±0.19	87.86±0.14
Ji et.al. +VGG-VD16 ^[135]	VGG-VD16	91.08±0.24	93.49±0.17
ResNet50+ EAM ^[146]	ResNet50	90.89±0.15	93.51±0.12
CNN-GCN ^[147]	VGG16	90.75±0.21	90.92±0.24
SKAL ^[148]	ResNet18	90.04±0.15	92.79±0.11
LSViT	ViT	92.41±0.15	94.25±0.25

上述方法中, 第一, 第二和第三种方法属于特征融合方法, 将不同特征提取方式得到的特征进行融合从而增强网络的特征提取能力以及特征的判别性。第四、五、六种方法属于基于注意力机制的方法, 采用不同的方式在网络中加入注意力机制, 用于指导网络进行有选择性的特征提取, 抑制任务无关的图像信息。第七和第八种方法则属于双分支网络方法, 不同分支学习不同类型的特征。

从表 4-5 中可以看出, 对于 AID 数据集, 当训练数据为 20% 时, LSViT 取得的总体精度为 95.33 ± 0.05 , 当训练数据为 50% 时的总体精度为 97.55 ± 0.12 。相较于其他以卷积神经网络为主干网络的方法, 性能得到了一定程度的提升。根

据表 4-6 可以发现, 对于 NWPU-RESISC45 数据集, 当训练数据为 10% 时, LSViT 取得的总体精度为 92.41 ± 0.15 , 当训练数据为 20% 时的总体精度为 94.25 ± 0.25 , 同样在性能上有一定提升。LSViT 在使用不同比例的训练数据时, 性能差异并不大, 证明 LSViT 受到训练数据量的影响较小, 在不同训练数据量下均能保持其性能优势, 可以很好地满足实际应用需求。证实了 ViT 可以很好地应用于遥感场景分类网络, 以及使用局部选择模块能够增加网络的判别力, 从而提高分类精度。

4.4 本章小结

鉴于 ViT 在图像处理任务上取得的成功, 本文提出了一个用于遥感场景分类的 LSViT 方法, 它使用 ViT 提取图像特征。同时考虑到遥感图像中往往含有大量类别无关区域以及类别判别区域, 将 ViT 的编码器中的倒数第二层修改为局部选择模块。通过局部选择模块选择含有判别性区域的 Token 作为最后一层的输入, 丢弃包含无用区域的 Token, 以此增加网络的判别力。通过大量实验证明, ViT 也能成功地应用于遥感场景分类并取得了较于卷积神经网络更好的效果, 同时引入局部选择模块能更好地识别判别区域。在未来, 我们将研究一些轻量型的 Transformer 用于遥感场景分类, 使其能更好地投入实际应用。

第5章 基于注意力引导双分支网络的遥感图像分类

5.1 引言

高光谱图像是一种多波段的遥感图像，其特点是可以获取物体在多个波段下的反射或辐射信息，对比于传统的可见光图像，高光谱图像每个像素中都有丰富的光谱信息，每个像素点所对应的光谱曲线可展开成高维的光谱特征向量，因此高光谱图像能够提供更为细致和全面的图像信息。相比于其他类型的遥感图像，高光谱图像具有很多优势。首先，高光谱图像可以提供更多的物质信息，这使得它们在很多领域得到广泛应用。例如，高光谱图像可以用来探测矿物质，鉴别植被种类，检测地面覆盖情况等。高光谱图像还可以用于城市规划、环境监测、气象预测等领域，提供更为有效的数据支撑。此外，高光谱图像还具有比较好的抗噪性能，能够有效地避免图像受到环境噪声等因素的影响。

高光谱分类任务是高光谱图像处理中的一个重要任务，其目标是将高光谱图像中的每个像素点分类到相应的类别中。高光谱分类任务的难点在于如何有效地提取高维度的光谱特征和建立有效的分类模型。高光谱分类任务通常采用机器学习算法来完成，包括传统的支持向量机、随机森林、神经网络等，以及近年来发展起来的深度学习方法。一些基于深度学习的方法在高光谱图像分类中取得了很好的表现，例如基于卷积神经网络的分类方法、基于图卷积神经网络的分类方法以及基于生成对抗网络的分类方法等。

近年有一些研究工作将 Transformer 特征提取架构应用于高光谱分类任务中。Transformer 网络相较于传统的深度模型具有更好的建模能力，可以更好地捕捉高光谱数据中的特征。Transformer 网络还可以通过多头自注意力机制来进行特征的交互和整合，使得模型能够捕捉不同特征之间的关系，从而进一步提升了高光谱分类的性能。Qing 等人^[149]提出了一个端到端的自注意力 Transformer (Self-Attention Transformer, STA) 模型。该模型使用光谱注意机制提取高光谱图像的光谱，并采用自注意力机制 (Self-Attention) 提取空间特征。Hong 等人^[144]提出了一个名为 SpectralFormer 的新骨干网络，将高光谱像素和高光谱像素块作为输入，从相邻波段学习成组的光谱特征，并设计了一个跳层连接来减少学习过程中的信息丢失。Xue 等人^[150]提出了一种用于高光谱分类的具有空间区域恢复的局部 Transformer 网络 (Local Transformer with Spatial Partition Restore Network, SPRLT-Net)，SPRLT-Net 利用动态注意力权重适应高光谱图像空间像素的固有变化，并有效捕捉全局上下文相关性。

最近有学者将卷积神经网络与 Transformer 结构结合进行高光谱分类。He 等人^[150]提出了一个空间-光谱 Transformer (Spatial-Spectral Transformer, SST) 分

类框架。该方法采用改进的卷积神经网络来提取空间特征,采用具有密集连接的 Transformer (Dense Transformer) 来捕捉连续的光谱关系,并使用多层感知器来完成最终分类任务。Sun 等人^[151]提出了一种光谱-空间特征标记化 Transformer (Spectral-Spatial Feature Tokenization Transformer, SSFTT) 高光谱分类方法,将转换后的光谱及空间卷积特征输入到 Transformer 中进行特征学习。Yang 等人^[152]提出了一个高光谱图像 Transformer (Hyperspectral Image Transformer, HiT) 分类网络,通过在 Transformer 中加入卷积操作来捕捉细小的光谱差异并在网络中传递局部空间背景信息。Yang 等人^[153]提出了一种基于卷积和 Transformer 融合的高光谱分类网络,其中卷积和变压器在串联和并联机制中融合来增强高光谱特征提取性能。Mei 等人^[154]提出了组感知层次 Transformer (Group-Aware Hierarchical Transformer, GAHT) 高光谱图像分类算法。该方法结构以分层的形式构建,利用成组像素嵌入 (Grouped Pixel Embedding, GPE) 获取高光谱图像的光谱通道内的局部关系,利用以上改进提升了高光谱分类性能。Yu 等人^[155]提出一种多级光谱-空间 Transformer 网络 (Multilevel Spectral-Spatial Transformer Network, MSTNet) 用于高光谱图像分类。该方法分别利用位置嵌入 (Positional Embedding, PE) 和 Transformer 编码器 (Transformer Encoder, TE) 来整合空间信息以及学习特征表达。Bai 等人^[152]为了解决高光谱分类中复杂背景干扰的问题,提出了一种多分支 Transformer 结构,利用 Transformer 的全局感受野来整合全局空间位置信息。另外,设计了一个掩码预测模型进行对高光谱像素的分类以学习更具判别性的特征。

卷积神经网络和 Transformer 结构的结合可以充分发挥它们各自的优势,实现更高效、更精确的高光谱分类。卷积神经网络擅长提取局部特征和空间信息,而 Transformer 则擅长捕捉长距离的语义关系和全局信息。一方面,卷积神经网络能够有效地提取高光谱图像中的空间和频谱信息,将不同波段的特征进行融合,从而产生更为丰富的特征表示。另一方面,Transformer 能够捕捉像素之间的长距离依赖性,可以更好地学习像素之间的全局关系,进一步提高特征表示的表达能力。结合这两个模型,可以使用卷积神经网络提取高光谱图像的局部特征,并将其输入 Transformer 网络中进行进一步处理,以捕获全局信息。在进行高光谱图像分类任务时,这种结合的方法可以提高分类准确性,同时减少过拟合问题,使得模型更加稳定可靠。但是现有相关研究在两种特征学习模型间的联动上多数采用串联或者并联的方式进行,并不能有效地在整个过程中保持信息交互。为了解决这一问题,本章提出了基于注意力引导的双分支网络,用于高光谱分类。该网络有效结合了卷积神经网络和 Transformer 结构的优势。卷积神经网络对于数据的局部特征有很好的提取能力,而 Transformer 结构则可以考虑到序列中每个元素的全局信息,使得模型更好地捕捉序列中不同位置之间的关系。该方法引入了交叉注意力机制将卷积神经网络和 Transformer 结构进行

联合自注意力计算,使得模型可以同时考虑到局部和全局的特征信息,从而提高模型的分类准确率。

本章的主要贡献可以总结为以下方面:

(1) 提出基于基于注意力引导的双分支网络。该网络结合了卷积神经网络与 Transformer 网络在特征提取中各自的优势,同时挖掘大尺寸复杂遥感高光谱图像局部与全局信息。

(2) 提出了多层次注意力引导机制,将卷积神经网络和 Transformer 结构之间的特征进行关联,在多个特征层级上计算联合注意力权重,使得模型可以同时考虑到局部和全局的特征信息,从而提高模型的分类准确率。

5.2 研究方法

本章提出的基于注意力引导的双分支网络框架如图 5-1 所示。该网络以高光谱图像块序列作为输入来探索高光谱图像的空间光谱信息。Transformer 结构中的多头注意力机制被用于计算全局空间谱特征的内部相关性。该网络融合了卷积神经网络和 Transformer 结构的优点,即卷积神经网络具有良好的局部特征提取能力,而 Transformer 结构则能够全面考虑序列中每个元素的全局信息,从而更好地捕捉序列中不同位置之间的关系。该方法引入了多层次注意力引导机制,将卷积神经网络和 Transformer 结构进行多层次注意力权重计算。




图 5-1 基于注意力引导的双分支网络的总体结构

Figure 5-1 Overall structure of a hyperspectral classification method based on the cross-attention fusion of convolutional neural network and Transformer

$H \in \mathbb{R}^{M \times N \times B}$ 代表原始的高光谱图像,其中 $M \times N$ 为高光谱图像的空间尺寸, B 为高光谱图像的波段数目。高光谱图像分类的目的是通过特征学习和分类器最终得到高光谱图像中像素的地物类别。在本章提出的基于注意力引导的双分支网络框架中,从高光谱图像中裁剪出图像块 $P_i \in \mathbb{R}^{a \times a \times B}$ 作为包含空间信息的输入分别进入卷积神经网络以及 Transformer 结构两个分支进行特征学习,其中 $a \times a$ 为高光谱图像块 P_i 的空间尺寸。

5.2.1 卷积神经网络特征提取分支

卷积神经网络特征提取分支由一个谱-空注意力模块和三个卷积神经网络模

块构成。高光谱图像块 P_i 输入至卷积神经网络特征提取分支后，首先进入光谱-空间注意力模块，光谱-空间注意力模块由光谱注意力及空间注意力串联而成，采用根据高光谱卷积块注意力模块（Convolutional Block Attention Module, CBAM）结构^[25,42]，其计算过程可描述为：

$$f_{spe} = \text{SpeA}(P_i) \otimes P_i \quad (5-1)$$

$$f_{spa} = \text{SpaA}(h_{spe}) \otimes f_{spe} \quad (5-2)$$

其中， $\text{SpeA}(\cdot)$ 表示光谱注意力计算过程， h_{spe} 表示光谱注意力输出特征， $\text{SpaA}(\cdot)$ 表示空间注意力计算过程， h_{spa} 为光谱注意力输出特征。

h_{spa} 作为输入进入后续三个卷积神经网络模块，其计算过程可表示为：

$$f_{\text{conv}}^{(l)} = \begin{cases} \text{Conv}(f_{spa}; W^{(1)}) & l = 1 \\ \text{Conv}(f_{\text{conv}}^{(l-1)}; W^{(l)}) & l = 2, 3 \end{cases} \quad (5-3)$$

5.2.2 Transformer 特征提取分支

Transformer 特征提取分支由一个线性投影模块和三个 Transformer 编码器构成。三个 Transformer 编码器中多头交叉自注意力（Multi-Head Cross Self-Attention, MCSA）模块的头部个数分别为 8、4 和 2。

Transformer 编码器中的主要计算过程为：

$$\tilde{h}^{(l)} = \text{MCSA}\left(\text{LN}\left(h^{(l-1)}\right)\right) + h^{(l-1)} \quad (5-4)$$

$$h^{(l)} = \text{MLP}\left(\text{LN}\left(\tilde{h}^{(l)}\right)\right) + \tilde{h}^{(l)} \quad (5-5)$$

其中， $l=1 \dots L$ ， $h^{(l)}$ 表示经过 l 层 Transformer 编码后得到的特征， $\text{LN}(\cdot)$ 表示层归一化计算， $\text{MCSA}(\cdot)$ 代表多头交叉自注意力运算， MLP 表示多层感知机中的映射。在编码器的最后一层，最终 Transformer 编码器输出 $h^{(L)}$ 的第一个标记用于表示高光谱图像的语义信息，并将其传递给分类器用于预测标签。

多头交叉自注意力模块使用分别计算多个头部的交叉自注意力 CroSA_p ，将所有 Z 个交叉注意力头的结果连接在一起。具体然后通过一个具有可学习权重 $\mathbf{W}_{\text{MSA}}$ 的线性投影层投影到相应维度：

$$\text{MCSA} = \text{Concat}\left(\text{CroSA}_p^{(1)}, \text{CroSA}_p^{(2)}, \dots, \text{CroSA}_p^{(Z)}\right) \mathbf{W}_{\text{MSA}} \quad (5-6)$$

其中， $\text{CroSA}_p^{(z)}$ 表示第 z 个交叉自注意力头的输出， $z=1, 2, \dots, Z$ 。交叉自注意力头中的具体运算将在下一小节进行详细介绍。

5.2.3 多层次注意力引导机制

Transformer 结构特征提取能力出色的关键就是采用了多头自注意力模块。本章设计了将卷积神经网络与 Transformer 特征提取联合的交叉自注意力机制。

Transformer 模块中原始自注意力机制有效地捕获了特征序列之间的相关性。为了学习多个映射，并通过三个可学习权重 W 矩阵将标记线性映射形成三维不变矩阵，包括查询 (Query, Q)、键 (Key, K) 和值 (Value, V)。注意力得分是使用所有的 Q 和 K 来计算的，得分的权重是使用 Softmax 激活函数进行计算获得。原始自注意力机制在 Transformer 编码器中自注意力头 (Self-Attention Head) 中计算过程的表述如下：

$$SA_p^{(z)} = \text{softmax} \left(\frac{h_q^{(z)} (h_v^{(z)})^T}{\sqrt{d_k}} \right) h_v^{(z)} \quad (5-7)$$

其中， $SA_p^{(z)}$ 代表第 z 个头部上的自注意力计算。

本章将卷积神经网络与 Transformer 结构在特征提取过程进行联动，将与 Transformer 结构对应层数的 f_{conv} 按照头部个数在通道维等分拆为 Z 个特征 ($f_{\text{conv}}^{(1)}, f_{\text{conv}}^{(2)}, \dots, f_{\text{conv}}^{(Z)}$) 用以代替 $h_q^{(z)}$ 计算卷积神经网络与 Transformer 结构的交叉自注意力 (替代项的选择在消融实验中进行了分析)，其计算过程可表示为：

$$\text{CroSA}_p^{(z)} = \text{softmax} \left(\frac{f_{\text{conv}}^{(z)} (h_v^{(z)})^T}{\sqrt{d_k}} \right) h_v^{(z)} \quad (5-8)$$

5.3 实验验证

5.3.1 数据集与评价指标

数据集及评价指标为了展示所提方法的性能，我们使用三个公共数据集 Pavia University (PU) 数据集、HyRANK-Loukia (HR-L) 数据集和 Salinas 数据集进行实验。

PU 数据集图像空间尺寸为 610×340 像素，每个像素有 103 个光谱波段。覆盖的光谱波长范围为 $430 \sim 860 \text{ nm}$ 。这个数据集包括九类地物。表 5-1 列出了训练/测试样本的数量。

HR-L 数据集由美国国家航空航天局地球观测一号 (EO-1) 卫星上的 Hyperion 传感器获得。该数据集由 249×945 个像素组成，每个像素有 176 个波段。这个数据集包括 14 中地物类别。表 5-2 列出了训练/测试样本的数量。

Salinas 数据集也由 AVIRIS 仪器收集。数据集包含 512×217 个像素，每个像素有 224 个波段。在这个数据集中也有 20 个噪声波段。Salinas 数据集包括 16 类农田相关的第五类别。训练/测试样本的数量如表 5-3 所示。

表 5-1 PU 数据集中训练和测试所用的样本数量

Table 5-1 Number of training pixels and testing pixels on the PU dataset

类别	类别名	训练像素个数	测试像素个数
1	Asphalt	132	6366
2	Meadows	373	17903
3	Gravel	42	2015
4	Trees	62	2941
5	Painted metal sheets	27	1291
6	Bare Soil	100	4828
7	Bitumen	27	1277
8	Self-blocking bricks	73	3535
9	Shadows	19	909

表 5-2 HR-L 数据集中训练和测试所用的样本数量

Table 5-2 Number of training pixels and testing pixels on the HR-L dataset

类别	类别名	训练像素个数	测试像素个数
1	Dense Urban Fabric	8	271
2	Mineral Extraction Sites	2	63
3	Non Irrigated Arable Land	17	509
4	Fruit Trees	3	74
5	Olive Groves	42	1317
6	Broad-leaved Forest	6	210
7	Coniferous Forest	15	470
8	Mixed Forest	32	1008
9	Dense Sclerophyllous Vegetation	114	3565
10	Sparce Sclerophyllous Vegetation	84	2635
11	Sparcely Vegetated Areas	12	380
12	Rocks and Sand	14	458
13	Water	42	1309
14	Coastal Water	14	424

为了定量评价所提方法的分类性能，本章采用整体分类精度（OA）、平均分类精度（AA）、kappa、各分类下的准确率作为评价指标^[11]。此外，为了定性地衡量所提方法的性能，本章还引入了类别图用于直观地展示分类结果。

表 5-3 Salinas 数据集中训练和测试所用的样本数量
Table 5-3 Number of training pixels and testing pixels on the Salinas dataset

类别	类别名	训练像素个数	测试像素个数
1	Brocoli green weeds 1	40	1929
2	Brocoli green weeds 2	74	3577
3	Fallow	40	1897
4	Fallow rough plow	28	1338
5	Fallow mooth	53	2571
6	Stubble	79	3801
7	Celery	71	3436
8	Grapes untrained	225	10820
9	Soil vineyard develop	124	5955
10	Corn senesced green weeds	65	3147
11	Lettuce romaine 4wk	22	1025
12	Lettuce romaine 5wk	39	1850
13	Lettuce romaine 6wk	19	879
14	Lettuce romaine 7wk	22	1027
15	Vinyard untrained	145	6977
16	Vinyard vertical trellis	36	1735

5.3.2 实验设置

本节主要介绍高光谱图像的数据预处理和各种方法的超参数设置。首先，遵循文献^[41]，利用最小-最大比例，将高光谱图像中每个波段的值归一到 $[0, 1]$ 的范围。然后，以训练/测试像素为中心的高光谱图像块被从归一化的高光谱图像中裁剪出来。高光谱图像中的每个像素都有一个相应的高光谱图像块，实验中所有方法的图像块空间大小为 7×7 。每个裁剪的高光谱图像块在训练过程中随机选择以下 5 中数据增强：垂直翻转、水平翻转、90 度、280 度以及 270 度旋转。

所有实验均在带有 NVIDIA Quadro RTX 6000 GPU 的 Ubuntu 系统下进行，代码基于 Pytorch 框架实现，在实验中，所提方法的迭代历时和批量大小分别被设定为 300 和 64。所提方法的学习率被初始化为 0.001，采用随机梯度下降（Stochastic Gradient Decent, SGD）方法优化，其中冲量和权重衰减分别为 0.9 和 0.0001。所比较的方法采用了与原始文献中相同的设置。

5.3.3 实验结果与分析

(1) 消融实验

1) 不同融合方式

本节探讨了不同交叉注意力对精度的影响并在 PU 数据集上进行实验，实验结果如表 5-4 所示。本节设置了四种交叉注意力，其中 Add 表示将 Transformer 和卷积神经网络提取的特征相加之后进行自注意力计算；Concat 表示将 Transformer 和卷积神经网络提取的特征拼接之后进行自注意力计算；将 Transformer 计算的特征作为交叉注意力的查询（Query，Q），卷积神经网络计算的特征作为键（Key，K）和值（Value，V）；将卷积神经网络计算的特征作为交叉注意力的 Q，Transformer 计算的特征作为 K 和 V。实验结果表明第四种交叉注意力能够达到更高的精度，这说明，Transformer 提取的特征更有利于高光谱分类。

表 5-4 PU 数据集上不同融合方式的总体精度(%)

Table 5-4 OA (%) of different kinds of fusion method on the PU database

Q	K	V	OA(%)
Add	Add	Add	97.01
Concat	Concat	Concat	97.21
Transformer	CNN	CNN	97.69
CNN	Transformer	Transformer	97.93

2) 图像块大小的影响

本节实验探究了不同图像块对精度的影响，实验结果如表 5-5 所示。在 PU 和 Salinas 数据集上，随着图像块的尺寸增加，输入的高光谱图像块引入了更多的空间信息，因此大尺寸的图像块的 OA 值更高，当图像块尺寸达到 11×11 时，OA 分别达到 98.13% 和 98.15%。在 HR-L 数据集上，当图像块尺寸为 7×7 时，OA 达到最高的 82.46%，这是由于 HR-L 数据集中的地物范围更小，因此使用大尺寸的图像块会误导分类任务，因此当图像块的尺寸大于 7×7 时，OA 指标会下降。为了方便，本章的所有实验均在 7×7 的图像块下进行。

(2) 与其他方法的对比实验

所提方法的性能分别在 PU、HRL 和 Salinas 数据集上进行了进一步评估。将所提方法与最近的基于神经网络方法被用来作为比较，包括深度特征融合网络 Deep Feature Fusion Network, DFFN)，多尺度三维深度卷积网络（Multi-scale 3D Deep Convolutional Neural Network, M3D-DCNN）^[16]，三维卷积神经网络（3D Convolutional Neural Network, 3D-CNN）^[12]，残差光谱空间注意力网络

(Residual Spectral-Spatial Attention Network, RSSAN)^[42], 注意力双向长短记忆网络 (Attention-Based Bidirectional Long Short-Term Memory Network, AB-LSTM)^[156], 光谱 Transformer (SpectralFormer, SF)^[44]下面介绍所提方法在 PU、HR-L 和 Salinas 数据集上的详细结果。

表 5-5 不同高光谱图像切片尺寸的 OAs (%)
Table 5-5 OAs(%) of with different sizes of HSI patches

	3×3	5×5	7×7	9×9	11×11
PU	94.89	96.96	97.93	97.89	98.13
HR-L	81.16	82.28	82.46	81.50	80.09
Salinas	92.47	94.44	96.04	97.54	98.15

表 5-6 每类的精度, 不同方法在 PU 数据集上的分类结果
Table 5-6 Accuracy in each category, OA, AA, and Kappa of different methods on the PU database

类别	M3D-DCNN	3D-CNN	DFFN	RSSAN	AB-LSTM	SF	Proposed
1	96.32	92.92	96.63	93.40	94.63	87.32	97.95
2	99.04	97.96	99.64	99.79	96.51	96.05	99.58
3	88.33	44.97	89.60	80.41	75.55	73.21	89.52
4	96.64	97.00	95.20	94.64	90.04	93.91	97.13
5	99.39	97.95	100.00	99.92	99.17	100.00	100.00
6	84.99	53.11	97.59	92.59	75.63	76.77	98.28
7	87.18	67.23	81.96	82.58	78.36	67.54	92.42
8	89.58	90.88	95.48	87.89	78.22	76.39	95.27
9	99.03	99.78	98.81	100.00	97.63	93.64	99.70
OA	95.10	87.71	97.21	95.08	90.24	88.65	97.93
AA	93.39	82.42	94.99	92.36	87.30	84.98	96.65
Kappa	93.46	83.34	96.29	96.45	86.95	84.89	97.25

1) PU 数据集

首先, 利用 PU 数据集对所提方法的性能进行评价, 并与不同方法进行比较。

对比实验结果如表 5-6 所示。实验结果表明所提方法优于其他方法，在 OA、AA 和 Kappa 三个指标上分别达到 97.93%，96.65%，97.25%。所提方法通过交叉注意力能够提取有效的空间特征，其融合了卷积神经网络提取的局部特征和 Transformer 提取的全局特征，不仅优于基于卷积神经网络的方法，同样也优于基于 Transformer 的方法，特别是在沥青、树、裸露土壤等类别。

PU 数据集上的 ground truth 和对比方法的视觉分类图如图 5-2 所示。从 M3D-CNN、3D-CNN、AB-LSTM 和 SF 的分类图结果可以看出，误分类像元主要集中于大范围的地物，即裸露的土地、牧场等；此外，DFFN、RSSAN、SF 在沥青道路的分类上相对较差。而所提方法通过交叉注意力机制融合了局部特征和全局特征，对大范围地物更加鲁棒，其分类图相对较为平滑，在各个地物区域都有良好的分类，也证明了所提方法的有效性。




图 5-2 PU 数据集集中的 Ground truth 和对比算法的分类图

Figure 5-2 Classification maps of ground truth and compared methods on the PU database

2) HR-L 数据集

在 HR-L 数据集上进一步评估所提方法的性能, 并与其他方法进行对比, 实验结果如表 5-7 所示。由于 HR-L 数据集上 “Dense Urban Fabric”, “Mineral Extraction Sites”, “Fruit Trees” 和 “Broad-leaved Forest” 类别的训练像素数较少, 因此 HR-L 数据集上的高光谱分类任务更具挑战性。所提方法在 “Mineral Extraction Sites”, “Mixed Forest” 和 “Sparcely Vegetated Areas” 等类别上显著优于其他方法, 这说明在训练像素数相对较少的情况下, 所提方法也能拥有较高分类准确性, OA、AA 和 Kappa 指标分别达到 82.46%, 76.97% 和 79.09%。

表 5-7 每类的精度, 不同方法在 HR-L 数据集上的分类结果

Table 5-7 Accuracy in each category, OA, AA, and Kappa of different methods on the HR-L database

类别	M3D-DCNN	3D-CNN	DFFN	RSSAN	AB-LSTM	SF	Proposed
1	47.23	33.58	74.91	51.29	46.86	60.89	65.68
2	71.43	76.19	73.02	79.37	73.02	85.71	92.06
3	82.12	83.30	84.48	87.23	86.64	60.31	88.61
4	43.24	12.16	12.16	18.92	0.00	5.41	43.24
5	84.05	77.68	85.42	88.38	81.09	63.86	88.88
6	55.24	36.67	32.86	32.86	1.43	20.48	49.14
7	61.49	43.19	48.30	61.91	42.77	33.62	58.26
8	54.17	64.19	65.08	66.17	70.93	65.18	71.09
9	87.18	84.40	86.37	87.24	83.62	80.67	82.60
10	81.37	73.55	77.08	78.63	81.44	67.32	81.24
11	63.95	43.95	61.84	60.79	54.74	57.63	67.63
12	94.76	92.36	94.32	89.96	88.21	93.23	89.17
13	100.00	100.00	100.00	100.00	100.00	100.00	100.00
14	100.00	100.00	100.00	100.00	100.00	100.00	99.95
OA	81.49	77.14	80.95	81.90	79.36	72.94	82.46
AA	73.30	65.80	71.13	71.62	65.05	63.88	76.97
Kappa	77.80	72.51	77.18	78.31	75.21	67.47	79.09

图 5-3 展示了对比方法在 HR-L 数据集上的可视化分类图。HR-L 数据集中包含大量小范围的地物，而部分地物由于训练像素数较少，该数据集的分类难度更大。相较于其他对比方法，所提方法在各个地物覆盖都有较好的分类结果，说明了所提方法的有效性。




图 5-3 在 HR-L 数据集上与其他算法的可视化对比

Figure 5-3 False color image, ground truth, training pixels, and classification maps of proposed method and compared methods on the HR-L database

3) Salinas 数据集

最后，在 Salinas 数据集上评估所提方法的性能，并与其他方法进行对比，实验结果如表 5-8 所示。结果表明所提方法在大部分类别上优于其他方法，特别地，所提方法在“Vinyard_untrained”类别上显著优于其他方法，这是由于所提方法基于交叉注意力机制融合了局部特征和全局特征，对大范围的目标更加鲁棒，证明了所提方法的有效性。

从表 5-8 中可以看出，本章所提出的算法在分类精度上的表现优于其他所有对比方法。在 16 个类别中的 8 个类别上本章方法的精度达到了最高。在所有对比方法中，DFFN 表现出了最高的精度，OA 达到了 94.78%，AA 达到了 96.70%。而本章所提出的基于注意力引导的双分支网络 OA 和 AA 比 DFFN 分别高出了 1.26% 和 0.9%。

表 5-8 每类的精度，不同方法在 Salinas 数据集上的分类结果

Table 5-8 Accuracy in each category, OA, AA, and Kappa of different methods on the Salinas database

类别	M3D-DCNN	3D-CNN	DFFN	RSSAN	AB-LSTM	SF	Proposed
1	97.66	98.12	98.27	100.00	96.29	93.75	98.57
2	97.26	99.86	99.92	99.86	99.10	99.01	99.94
3	97.37	95.20	93.85	97.31	97.00	88.79	98.21
4	95.10	97.51	97.80	95.24	99.49	92.09	98.74
5	97.48	95.46	99.05	98.78	96.23	95.27	99.23
6	99.64	99.85	100.00	99.90	99.15	99.90	100.00
7	99.71	99.43	99.86	99.83	98.92	99.52	99.97
8	85.83	81.69	93.07	88.91	72.74	82.73	92.35
9	99.97	97.45	100.00	99.57	98.90	96.18	99.93
10	96.67	91.34	94.65	96.08	78.70	91.10	96.68
11	98.09	90.93	97.61	98.28	85.96	59.50	98.91
12	99.31	99.15	99.52	100.00	96.93	99.10	99.65
13	96.55	91.76	99.89	99.44	96.88	88.08	98.57
14	95.71	98.67	97.43	97.52	87.23	98.95	97.58
15	82.59	68.16	78.82	80.96	56.21	80.09	87.15
16	93.79	92.55	97.40	97.74	96.05	93.51	96.05
OA	93.43	89.88	94.78	94.37	85.56	90.30	96.04
AA	95.80	93.57	96.70	96.84	90.99	91.10	97.60
Kappa	92.69	88.73	94.18	93.73	83.93	89.20	95.59




图 5-4 在 Salinas 数据集上与其他算法的可视化对比

Figure 5-4 False color image, ground truth, training pixels, and classification maps of proposed method and compared methods on the Salinas database

图 5-4 展示了不同方法在 Salinas 数据集上的可视化分类图。结果表明所有对比方法在大范围的地物上均有分类错误，即“Grapes_untrained”和“Vinyard_untrained”类别，合理推测这是由于图像块尺寸相对较小的原因，大范围的图像块包含更多的空间信息，更有利于大范围目标的识别。虽然所提方法在这两类地物上也存在错误分类，但相对更少。此外，所提方法在“Corn_senesced_green_weeds”等细长的地物上的分类准确性也显著优于其他方法。

5.4 本章小结

本章提出了基于注意力引导的双分支网络。该网络结合了卷积神经网络与 Transformer 网络在特征提取中各自的优势，同时挖掘大尺寸复杂遥感高光谱图

像局部与全局信息。同时，由浅到深地在不同尺度下提出多层级注意力，用卷积特征指导 Transformer 的自注意力模块关注图像区域中的关键细节。在高光谱图像分类数据集上的大量实验验证了基于注意力引导的双分支网络的有效性，表明该网络在分类精度方面有着卓越的性能表现，达到了领域内的先进水平。

第6章 总结与展望

6.1 总结

当前遥感高光谱图像分类中,基于深度神经网络的分类方法取得了一系列令人瞩目的成果,成为领域内占主导地位的方法。然而,当前该领域中仍然存在一些尚未解决的问题,限制了这些算法的应用。本论文针对这些问题,结合深度神经网络中注意力机制展开了研究,取得了一系列的研究成果。具体来说,本论文的研究成果包含以下几方面。

(1) 针对以卷积神经网络为基础的方法中特征提取对输入图像旋转操作敏感的问题,提出了基于交叉注意力的卷积神经网络。在该网络中设计了交叉空间注意力模块,用于生成与旋转无关的图像特征。针对高光谱图像丰富的光谱信息,设计了交叉光谱注意力模块,用于网络在特征提取的过程中抑制光谱波段中的冗余信息,聚焦与分类任务相关的关键光谱信息。在多个遥感高光谱图像分类数据集上的实验验证了本文所提出的交叉空间注意力模块和交叉光谱注意力模块的有效性。在高光谱分类数据集上与其他最先进算法的对比实验表明基于交叉注意力的卷积神经网络具有优异的性能,在分类精度上已经达到了领域内的先进水平。相关研究成果已发表在遥感领域权威期刊 *IEEE Transactions on Geoscience and Remote Sensing*。

(2) 针对现有 Transformer 网络忽略局部注意力,对输入的图像块序列判别能力不足的问题,提出了基于局部选择的 Transformer 网络。在该网络提出了局部选择模块,能够对序列化的图像块以注意力选择的方式进行筛选,辨别出与类别信息相关性较高,具有判别性的图像区域,抑制类别相关性弱的冗余区域。通过在遥感图像分类数据集上的实验验证了 Transformer 网络作为遥感图像特征提取器的可行性。消融实验与参数实验验证了本文所提出的局部选择模块的有效性。通过在大量遥感图像数据集上的实验表明本文所提出的基于局部注意力选择的 Transformer 网络能够有效学习大尺度图像直接的全局特征关系,在分类任务上具有优异的性能。与其他现有方法的对比表明本文提出的网络达到了领域内的先进水平。相关研究成果已发表在期刊《激光与电子学进展》。

(3) 针对 Transformer 网络面对高光谱图像难以有效提取光谱-空间信息的问题,提出了基于注意力引导的双分支网络。该网络结合了卷积神经网络与 Transformer 网络各自的优势,采用卷积神经网络分支挖掘光谱特征,并通过多层级的注意力引导来指导 Transformer 网络分支学习光谱-空间特征,从而提高网络对不同尺度高光谱图像的适应能力,有效提升分类精度。通过消融实验与参数实验表明本文提出的多层级注意力引导机制能够有效提取高光谱图像的光谱-

空间信息。在多个高光谱图像分类数据集上的大量实验验证了基于注意力引导的双分支网络的有效性，与其他现有算法的对比表明该网络在分类精度方面有着卓越的性能表现，已经达到了领域内的先进水平。相关研究成果已投稿至遥感领域权威期刊 IEEE Transactions on Geoscience and Remote Sensing。

6.2 展望

本论文基于注意力机制，针对当前遥感高光谱图像分类任务存在的一系列问题展开了研究，提出了一系列的分类算法，取得了一定的研究成果。但是目前的工作依然在以下几方面仍然存在不足，需要在未来进行进一步的探索。

（1）现阶段本文研究的方法依然对遥感图像的数据标注具有较强的依赖性，需要大量的有标注样本进行训练。而对于大规模遥感图像，标注数据的收集和标注过程是十分耗时和昂贵的，导致算法的应用范围受限。未来的研究方向需要考虑如何减轻对数据标注的依赖，例如半监督或无监督学习方法。

（2）现有的深度学习模型通常具有较大的参数量，需要大量的计算资源和时间进行训练。这不仅导致训练困难，而且可能导致过拟合问题。在未来的研究中，考虑设计更加轻量化的深度学习模型，以提高训练速度和减少过拟合，使其更易于在多样化的平台上进行部署。

（3）当前工作中，尽管许多算法已经达到了较高的分类精度，但这些优异的性能往往限定在特定数据集范围内。当模型面对训练数据中没有出现过的数据类别可能出现明显的精度下降。在变换应用场景时为了达到较高的精度往往需要新的标注样本重新进行训练，这就大大限制了算法在实际中的应用。未来考虑研究域自适应的遥感影像分类，挖掘各个数据域中的关联，设计泛化性能更强的模型。

参考文献

- [1] Audebert N, Le Saux B, Lefevre S. Deep Learning for Classification of Hyperspectral Data: A Comparative Review[J]. IEEE Geoscience and Remote Sensing Magazine, 2019, 7(2): 159-173.
- [2] Goel P K, Prasher S O, Patel R M, et al. Classification of hyperspectral data by decision trees and artificial neural networks to identify weed stress and nitrogen status of corn[J]. Computers and Electronics in Agriculture, 2003, 39(2): 67-93.
- [3] Ratle F, Camps-Valls G, Weston J. Semisupervised neural networks for efficient hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2010, 48(5): 2271-2282.
- [4] Hu W, Huang Y, Wei L, et al. Deep convolutional neural networks for hyperspectral image classification[J]. Journal of Sensors, 2015, 2015: 1-12.
- [5] Mou L, Ghamisi P, Zhu X X. Deep recurrent neural networks for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(7): 3639-3655.
- [6] Wu H, Prasad S. Semi-supervised deep learning using pseudo labels for hyperspectral image classification[J]. IEEE Transactions on Image Processing, 2017, 27(3): 1259-1270.
- [7] Wu H, Prasad S. Convolutional recurrent neural networks for hyperspectral data classification[J]. Remote Sensing, 2017, 9(3): 298.
- [8] Makantasis K, Karantzas K, Doulamis A, et al. Deep supervised learning for hyperspectral data classification through convolutional neural networks[C]//2015 IEEE international geoscience and remote sensing symposium (IGARSS). IEEE, 2015: 4959-4962.
- [9] Slavkovikj V, Verstockt S, De Neve W, et al. Hyperspectral image classification with convolutional neural networks[C]//Proceedings of the 23rd ACM international conference on Multimedia. 2015: 1159-1162.
- [10] Zhao W, Du S. Spectral-spatial feature extraction for hyperspectral image classification: A dimension reduction and deep learning approach[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(8): 4544-4554.
- [11] Yue J, Zhao W, Mao S, et al. Spectral-spatial classification of hyperspectral images using deep convolutional neural networks[J]. Remote Sensing Letters, 2015, 6(6): 468-477.
- [12] Ben Hamida A, Benoit A, Lambert P, et al. 3-D Deep Learning Approach for Remote Sensing Image Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(8): 4420-4434.
- [13] Luo Y, Zou J, Yao C, et al. HSI-CNN: a novel convolution neural network for

- hyperspectral image[C]//2018 International Conference on Audio, Language and Image Processing (ICALIP). IEEE, 2018: 464-469.
- [14] Li Y, Zhang H, Shen Q. Spectral-spatial classification of hyperspectral imagery with 3D convolutional neural network[J]. Remote Sensing, 2017, 9(1): 67.
- [15] Liu B, Yu X, Zhang P, et al. A semi-supervised convolutional neural network for hyperspectral image classification[J]. Remote Sensing Letters, 2017, 8(9): 839-848.
- [16] He M, Li B, Chen H. Multi-scale 3D deep convolutional neural network for hyperspectral image classification[C]//2017 IEEE International Conference on Image Processing (ICIP). IEEE, 2017: 3904-3908.
- [17] Chen Y, Jiang H, Li C, et al. Deep feature extraction and classification of hyperspectral images based on convolutional neural networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(10): 6232-6251.
- [18] Itti L, Koch C, Niebur E. A model of saliency-based visual attention for rapid scene analysis[J]. IEEE Transactions on pattern analysis and machine intelligence, 1998, 20(11): 1254-1259.
- [19] Mnih V, Heess N, Graves A, et al. Recurrent models of visual attention[J]. Advances in neural information processing systems, 2014, 27.
- [20] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]//International conference on machine learning. PMLR, 2015: 2048-2057.
- [21] Jaderberg M, Simonyan K, Zisserman A, et al. Spatial transformer networks[J]. Advances in neural information processing systems, 2015, 28.
- [22] Zhu J, Fang L, Ghamisi P. Deformable convolutional neural networks for hyperspectral image classification[J]. IEEE Geoscience and Remote Sensing Letters, 2018, 15(8): 1254-1258.
- [23] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [24] Park J, Woo S, Lee J Y, et al. Bam: Bottleneck attention module[J]. arXiv preprint arXiv:1807.06514, 2018.
- [25] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018.
- [26] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.
- [27] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[Z]. 2017.
- [28] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C]//International Conference on Learning Representations. 2021.

- [29] Chen H, Wang Y, Guo T, et al. Pre-trained image processing transformer[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 12299-12310.
- [30] Wang W, Xie E, Li X, et al. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 568-578.
- [31] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 10012-10022.
- [32] Zhou D, Kang B, Jin X, et al. Deepvit: Towards deeper vision transformer[J]. arXiv preprint arXiv:2103.11886, 2021.
- [33] Wang P, Wang X, Wang F, et al. Kvt: k-nn attention for boosting vision transformers[C]//Computer Vision—ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXIV. Springer, 2022: 285-302.
- [34] Zhou D, Shi Y, Kang B, et al. Refiner: Refining self-attention for vision transformers[J]. arXiv preprint arXiv:2106.03714, 2021.
- [35] Ali A, Touvron H, Caron M, et al. Xcit: Cross-covariance image transformers[J]. Advances in neural information processing systems, 2021, 34: 20014-20027.
- [36] Wang Q, Liu S, Chanussot J, et al. Scene classification with recurrent attention of VHR remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 57(2): 1155-1167.
- [37] Yu Y, Li X, Liu F. Attention GANs: Unsupervised deep feature learning for aerial scene classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 58(1): 519-531.
- [38] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [39] Fang B, Li Y, Zhang H, et al. Hyperspectral images classification based on dense convolutional networks with spectral-wise attention mechanism[J]. Remote Sensing, 2019, 11(2): 159.
- [40] Haut J M, Paoletti M E, Plaza J, et al. Visual attention-driven hyperspectral image classification[J]. IEEE transactions on geoscience and remote sensing, 2019, 57(10): 8065-8080.
- [41] Mou L, Zhu X X. Learning to pay attention on spectral domain: A spectral attention module-based convolutional network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 58(1): 110-122.
- [42] Zhu M, Jiao L, Liu F, et al. Residual spectral-spatial attention network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and

- Remote Sensing, 2020, 59(1): 449-462.
- [43] He J, Zhao L, Yang H, et al. HSI-BERT: Hyperspectral image classification using the bidirectional encoder representation from transformers[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 58(1): 165-178.
- [44] Hong D, Han Z, Yao J, et al. SpectralFormer: Rethinking hyperspectral image classification with transformers[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-15.
- [45] Zhong Z, Li Y, Ma L, et al. Spectral-spatial transformer network for hyperspectral image classification: A factorized architecture search framework[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-15.
- [46] Li Z, Liu F, Yang W, et al. A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(12): 6999-7019.
- [47] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [48] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [49] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [50] Szegedy C, Liu W, Jia Y, et al. Going Deeper With Convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015.
- [51] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [52] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [53] Chen Y, Li J, Xiao H, et al. Dual Path Networks[C]//Guyon I, Luxburg U V, Bengio S, et al. Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.
- [54] Iandola F, Moskewicz M, Karayev S, et al. Densenet: Implementing efficient convnet descriptor pyramids[J]. arXiv preprint arXiv:1404.1869, 2014.
- [55] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1492-1500.
- [56] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.

- [57] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
- [58] Farhadi A, Redmon J. Yolov3: An incremental improvement[C]//Computer vision and pattern recognition: Vol. 1804. Springer Berlin/Heidelberg, Germany, 2018: 1-6.
- [59] Law H, Deng J. Cornernet: Detecting objects as paired keypoints[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 734-750.
- [60] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [61] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [62] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [63] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [64] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.
- [65] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer, 2015: 234-241.
- [66] Paszke A, Chaurasia A, Kim S, et al. Enet: A deep neural network architecture for real-time semantic segmentation[J]. arXiv preprint arXiv:1606.02147, 2016.
- [67] Chen L C, Papandreou G, Kokkinos I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 834-848.
- [68] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [69] Bolya D, Zhou C, Xiao F, et al. Yolact: Real-time instance segmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 9157-9166.
- [70] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.

- [71] Kirillov A, He K, Girshick R, et al. Panoptic segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9404-9413.
- [72] Liu H, Peng C, Yu C, et al. An end-to-end network for panoptic segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 6172-6181.
- [73] Cao C, Zhang Y, Zhang C, et al. Action recognition with joints-pooled 3d deep convolutional descriptors.[C]//IJCAI: Vol. 1. 2016: 3.
- [74] Stergiou A, Poppe R. Spatio-temporal FAST 3D convolutions for human action recognition[C]//2019 18th IEEE International Conference On Machine Learning And Applications (ICMLA). IEEE, 2019: 183-190.
- [75] Huang J, Zhou W, Li H, et al. Attention-based 3D-CNNs for large-vocabulary sign language recognition[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(9): 2822-2832.
- [76] Wu Z, Song S, Khosla A, et al. 3d shapenets: A deep representation for volumetric shapes[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1912-1920.
- [77] Maturana D, Scherer S. Voxnet: A 3d convolutional neural network for real-time object recognition[C]//2015 IEEE/RSJ international conference on intelligent robots and systems (IROS). IEEE, 2015: 922-928.
- [78] Song S, Xiao J. Deep sliding shapes for amodal 3d object detection in rgb-d images[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 808-816.
- [79] Zhou Y, Tuzel O. Voxelnet: End-to-end learning for point cloud based 3d object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4490-4499.
- [80] Pastor F, Gandarias J M, García-Cerezo A J, et al. Using 3D convolutional neural networks for tactile object recognition with robotic palpation[J]. Sensors, 2019, 19(24): 5356.
- [81] Han K, Wang Y, Chen H, et al. A Survey on Vision Transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(1): 87-110.
- [82] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]//International conference on machine learning. PMLR, 2021: 10347-10357.
- [83] Han K, Xiao A, Wu E, et al. Transformer in transformer[J]. Advances in Neural Information Processing Systems, 2021, 34: 15908-15919.
- [84] Chu X, Tian Z, Wang Y, et al. Twins: Revisiting the design of spatial attention in vision transformers[J]. Advances in Neural Information Processing Systems, 2021, 34: 9355-9366.
- [85] Lin H, Cheng X, Wu X, et al. Cat: Cross attention in vision transformer[C]//2022

- IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2022: 1-6.
- [86] Huang Z, Ben Y, Luo G, et al. Shuffle transformer: Rethinking spatial shuffle for vision transformer[J]. arXiv preprint arXiv:2106.03650, 2021.
- [87] Chen C F, Panda R, Fan Q. Regionvit: Regional-to-local attention for vision transformers[J]. arXiv preprint arXiv:2106.02689, 2021.
- [88] Yuan L, Chen Y, Wang T, et al. Tokens-to-token vit: Training vision transformers from scratch on imagenet[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 558-567.
- [89] Zhang L, Zhang L, Du B. Deep learning for remote sensing data: A technical tutorial on the state of the art[J]. IEEE Geoscience and remote sensing magazine, 2016, 4(2): 22-40.
- [90] Luo F, Zhang L, Du B, et al. Dimensionality reduction with enhanced hybrid-graph discriminant learning for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(8): 5336-5353.
- [91] Huang Y, Peng J, Ning Y, et al. Graph embedding and distribution alignment for domain adaptation in hyperspectral image classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 7654-7666.
- [92] Chen W, Zheng X, Lu X. Semisupervised spectral degradation constrained network for spectral super-resolution[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 19: 1-5.
- [93] Feng J, Yu H, Wang L, et al. Classification of hyperspectral images based on multiclass spatial-spectral generative adversarial networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(8): 5329-5343.
- [94] Sun W, Du Q. Hyperspectral band selection: A review[J]. IEEE Geoscience and Remote Sensing Magazine, 2019, 7(2): 118-139.
- [95] Peng J, Zhou Y, Sun W, et al. Self-paced nonnegative matrix factorization for hyperspectral unmixing[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(2): 1501-1515.
- [96] Sun H, Li S, Zheng X, et al. Remote Sensing Scene Classification by Gated Bidirectional Network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019: 1-15.
- [97] Li S, Song W, Fang L, et al. Deep learning for hyperspectral image classification: An overview[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(9): 6690-6709.
- [98] Yang B, Li H, Guo Z. Learning a deep similarity network for hyperspectral image classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 14: 1482-1496.
- [99] He L, Li J, Liu C, et al. Recent advances on spectral-spatial hyperspectral image

- classification: An overview and new guidelines[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 56(3): 1579-1597.
- [100] Imani M, Ghassemian H. An overview on spectral and spatial information fusion for hyperspectral image classification: Current trends and challenges[J]. Information fusion, 2020, 59: 59-83.
- [101] Zhou P, Han J, Cheng G, et al. Learning compact and discriminative stacked autoencoder for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(7): 4823-4833.
- [102] Li X, Ding M, Pižurica A. Spectral feature fusion networks with dual attention for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-14.
- [103] Li W, Wu G, Zhang F, et al. Hyperspectral image classification using deep pixel-pair features[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 55(2): 844-853.
- [104] Sun H, Zheng X, Lu X. A supervised segmentation network for hyperspectral image classification[J]. IEEE Transactions on Image Processing, 2021, 30: 2810-2825.
- [105] Cao X, Zhou F, Xu L, et al. Hyperspectral image classification with Markov random fields and a convolutional neural network[J]. IEEE Transactions on image processing, 2018, 27(5): 2354-2367.
- [106] Li W, Chen C, Zhang M, et al. Data augmentation for hyperspectral image classification with deep CNN[J]. IEEE Geoscience and Remote Sensing Letters, 2018, 16(4): 593-597.
- [107] Tang X, Meng F, Zhang X, et al. Hyperspectral image classification based on 3-D octave convolution with spatial-spectral attention network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(3): 2430-2447.
- [108] Feng J, Chen J, Liu L, et al. CNN-based multilayer spatial-spectral feature fusion and sample augmentation with local and nonlocal constraints for hyperspectral image classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2019, 12(4): 1299-1313.
- [109] Jiang Y, Li Y, Zou S, et al. Hyperspectral image classification with spatial consistence using fully convolutional spatial propagation network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(12): 10425-10437.
- [110] Liang X, Zhang Y, Zhang J. Attention symbiotic neural network for hyperspectral image refined classification based on relative water content retrieval[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(7): 5998-6016.
- [111] Sun H, Zheng X, Lu X, et al. Spectral-Spatial Attention Network for Hyperspectral Image Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(5): 3232-3245.
- [112] Li X, Ding M, Pižurica A. Deep feature fusion via two-stream convolutional

- neural network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 58(4): 2615-2629.
- [113] Hao S, Wang W, Ye Y, et al. Two-stream deep architecture for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 56(4): 2349-2361.
- [114] Zhao H, Jia J, Koltun V. Exploring Self-Attention for Image Recognition[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 10073-10082.
- [115] Paoletti M E, Haut J M, Roy S K, et al. Rotation equivariant convolutional neural networks for hyperspectral image classification[J]. IEEE Access, 2020, 8: 179575-179591.
- [116] Li K, Cheng G, Bu S, et al. Rotation-insensitive and context-augmented object detection in remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 56(4): 2337-2348.
- [117] Yang K, Sun H, Zou C, et al. Cross-attention spectral-spatial network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60.
- [118] Chen W, Zheng X, Lu X. Hyperspectral image super-resolution with self-supervised spectral-spatial residual network[J]. Remote Sensing, 2021, 13(7): 1260.
- [119] Chen W, Lu X. Unregistered Hyperspectral and Multispectral Image Fusion with Synchronous Nonnegative Matrix Factorization[C]//Pattern Recognition and Computer Vision. Cham: Springer International Publishing, 2020: 602-614.
- [120] Yuan Y, Zheng X, Lu X. Discovering diverse subset for unsupervised hyperspectral band selection[J]. IEEE Transactions on Image Processing, 2016, 26(1): 51-64.
- [121] Luo F, Du B, Zhang L, et al. Feature learning using spatial-spectral hypergraph discriminant analysis for hyperspectral image[J]. IEEE transactions on cybernetics, 2018, 49(7): 2406-2419.
- [122] Wang J, Huang R, Guo S, et al. NAS-guided lightweight multiscale attention fusion network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(10): 8754-8767.
- [123] Li R, Zheng S, Duan C, et al. Classification of hyperspectral image based on double-branch dual-attention mechanism network[J]. Remote Sensing, 2020, 12(3): 582.
- [124] Lin J, Mou L, Zhu X X, et al. Attention-Aware Pseudo-3-D Convolutional Neural Network for Hyperspectral Image Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(9): 7790-7802.
- [125] Fang L, Liu G, Li S, et al. Hyperspectral image classification with squeeze multibias network[J]. IEEE Transactions on Geoscience and Remote Sensing,

- 2018, 57(3): 1291-1301.
- [126] Hong D, Gao L, Yao J, et al. Graph Convolutional Networks for Hyperspectral Image Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(7): 5966-5978.
- [127] Du X, Zheng X, Lu X, et al. Multisource Remote Sensing Data Classification With Graph Fusion Network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(12): 10062-10072.
- [128] Rasti B, Ulfarsson M O, Sveinsson J R. Hyperspectral Feature Extraction Using Total Variation Component Analysis[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(12): 6976-6985.
- [129] Xu C, Zheng X, Lu X. Multi-Level Alignment Network for Cross-Domain Ship Detection[J]. Remote Sensing, 2022, 14(10): 2389.
- [130] Zheng X, Zhang Y, Lu X. Deep balanced discrete hashing for image retrieval[J]. Neurocomputing, 2020, 403: 224-236.
- [131] Zheng X, Wang B, Du X, et al. Mutual Attention Inception Network for Remote Sensing Visual Question Answering[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60.
- [132] Lin J, Haberstroh F, Karsch S, et al. Applications of object detection networks at high-power laser systems and experiments[J]. High Power Laser Science and Engineering, 2022: 1-11.
- [133] Wu F, Yang X, Ma Y, et al. Machine-learning guided optimization of laser pulses for direct-drive implosions[J]. High Power Laser Science and Engineering, 2022, 10: e12.
- [134] Wang X, Duan L, Shi A, et al. Multilevel Feature Fusion Networks With Adaptive Channel Dimensionality Reduction for Remote Sensing Scene Classification[J]. IEEE Geoscience and Remote Sensing Letters, 2021, PP(99): 1-5.
- [135] Ji J, Zhang T, Jiang L, et al. Combining multilevel features for remote sensing image scene classification with attention model[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 17(9): 1647-1651.
- [136] Chen X, Zheng X, Zhang Y, et al. Remote Sensing Scene Classification by Local-Global Mutual Learning[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [137] Chen C F R, Fan Q, Panda R. CrossViT: Cross-Attention Multi-Scale Vision Transformer for Image Classification[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 347-356.
- [138] Strudel R, Garcia R, Laptev I, et al. Segmenter: Transformer for Semantic Segmentation[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 7242-7252.
- [139] Song H, Sun D, Chun S, et al. ViDT: An Efficient and Effective Fully

- Transformer-based Object Detector[Z]. 2021.
- [140] Cui Y, Jiang C, Wang L, et al. MixFormer: End-to-End Tracking with Iterative Mixed Attention[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 13598-13608.
- [141] Bazi Y, Bashmal L, Rahhal M M A, et al. Vision Transformers for Remote Sensing Image Classification[J]. Remote Sensing, 2021, 13(3).
- [142] Zhang J, Zhao H, Li J. TRS: Transformers for remote sensing scene classification[J]. Remote Sensing, 2021, 13(20): 4143.
- [143] Abnar S, Zuidema W. Quantifying Attention Flow in Transformers[Z]. 2020.
- [144] Li E, Samat A, Du P, et al. Improved Bilinear CNN Model for Remote Sensing Scene Classification[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [145] Cao R, Fang L, Lu T, et al. Self-attention-based deep feature fusion for remote sensing scene classification[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 18(1): 43-47.
- [146] Zhao Z, Li J, Luo Z, et al. Remote sensing image scene classification based on an enhanced attention module[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 18(11): 1926-1930.
- [147] Liang J, Deng Y, Zeng D. A deep neural network combined CNN and GCN for remote sensing scene classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 4325-4338.
- [148] Wang Q, Huang W, Xiong Z, et al. Looking Closer at the Scene: Multiscale Representation Learning for Remote Sensing Image Scene Classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(4): 1414-1428.
- [149] Qing Y, Liu W, Feng L, et al. Improved transformer net for hyperspectral image classification[J]. Remote Sensing, 2021, 13(11): 2216.
- [150] Xue Z, Xu Q, Zhang M. Local transformer with spatial partition restore for hyperspectral image classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15: 4307-4325.
- [151] Sun L, Zhao G, Zheng Y, et al. Spectral-spatial feature tokenization transformer for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.
- [152] Bai J, Wen Z, Xiao Z, et al. Hyperspectral image classification based on multibranch attention transformer networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-17.
- [153] Yang L, Yang Y, Yang J, et al. FusionNet: A Convolution-Transformer Fusion Network for Hyperspectral Image Classification[J]. Remote Sensing, 2022, 14(16): 4066.
- [154] Mei S, Song C, Ma M, et al. Hyperspectral image classification using group-

- aware hierarchical transformer[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.
- [155] Yu H, Xu Z, Zheng K, et al. MSTNet: A Multilevel Spectral–Spatial Transformer Network for Hyperspectral Image Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-13.
- [156] Mei S, Li X, Liu X, et al. Hyperspectral image classification using attention-based bidirectional long short-term memory network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-12.