



全文 文章

E-Mamba: 高效 Mamba 网络 用于 高光谱 与 激光雷达 联合分类

张怡燕 ^a, 高鸿民 ^{a,*}, 陈忠豪 ^a, 张陈凯 ^a, 佩德拉姆 加米西 ^b,
宾 张 ^c^a河海大学 信息 科学与 工程学院, 中国 南京^b德累斯顿-罗森多夫亥姆霍兹研究中心(HZDR), 弗赖贝格亥姆霍兹资源技术研究所, 弗赖贝格, 德国^c航天 信息 研究所, 中国 科学院, 北京, 中国

ARTICLE INFO

关键词:

高光谱
激光雷达
Mamba
选择性 扫描 机制
分类
遥感

ABSTRACT

基于卷积神经网络 (CNNs) 和Transformer的模型在高光谱图像 (HSI) 与激光雷达 (LiDAR) 数据的联合分类任务中取得了显著进展。然而, 这些模型也存在固有缺陷: CNNs受限于网络架构, 难以有效捕捉长距离特征依赖; 而Transformer虽凭借自注意力机制擅长建模全局特征, 但其二次计算复杂度限制了可扩展性。幸运的是, 近期涌现的状态空间模型 (SSM) Mamba在保持Transformer建模能力的同时, 提供了极高的计算效率。本文首次尝试将Mamba架构应用于HSI与LiDAR数据的联合分类任务, 采用双分支孪生视觉状态空间块从两种异构模态中提取差异化特征。核心模块二维选择性扫描 (SS2D) 通过四条不同方向的路径遍历生成多组图像块序列, 每组序列由独立S6块处理, 最终整合合并以捕获图像全局特征。考虑到模态间互补性对提升分类性能的重要性, 我们引入两个轻量级Mamba特征提取与融合模块: 交叉Mamba特征提取块通过特征交互增强跨模态信息流; 模态引导Mamba融合块则利用注意力机制突出各模态相关信息, 进一步提升模型判别能力, 旨在减少训练参数数量的同时保持竞争力的分类性能。E-Mamba是Mamba架构在HSI与LiDAR联合分类领域的开创性实践, 为未来基于Mamba的多源遥感 (RS) 图像分类网络奠定基础。我们在三个真实数据集上验证了E-Mamba的有效性, 在Houston2013、特伦托和MUUFL数据集上分别达到93.81%、99.06%和91.47%的总体分类准确率, 超越了一系列最新的基于CNN和Transformer的模型。代码将发布于<https://github.com/zhangyiyao001/E-Mamba>。

1. 引言

随着遥感(RS)成像技术的进步, 各类数据变得越来越容易获取[1,2]。这些数据为全面有效地监测地表覆盖[3–5]提供了前所未有的机遇。然而, 单模态遥感数据往往难以捕捉土地覆盖的复杂特征, 限制了其有效性[6–8]。为解决这一局限, 融合多源遥感数据进行分类的方法受到了广泛关注

近年来备受关注。特别是高光谱图像 (HSI) 与激光雷达 (LiDAR) 数据的联合分类已成为一个突出的研究焦点[9–13]。高光谱图像由数百个光谱波段组成, 每个波段对应特定的光谱反射特征, 形成各种土地覆盖的“光谱指纹”, 从而实现精确分类[14–21]。然而, 高光谱图像存在一定局限性, 包括缺乏高程信息以及易受环境因素影响而导致

* 通讯作者。

电子邮箱 地址: zhangyiyao@hhu.edu.cn (张义艳), gaohongmin@hhu.edu.cn (高洪敏), chenzhonghao@hhu.edu.cn (陈忠浩), zhangchenkai@hhu.edu.cn (张晨凯), p.ghamisi@hzdr.de (P. Ghamisi), zb@radi.ac.cn (张博)。<https://doi.org/10.1016/j.inffus.2025.103649>

收到 26 二月 2025年; 收到 修订 稿 19 六月 2025年; 接受 20 八月 2025年

2025年8月28日可在线获取

1566-2535/© 2025 爱思唯尔公司 保留所有权利, 包括文本和数据挖掘、AI训练及类似技术的使用权。

光谱反射特征改变,使分类过程复杂化[22-24]。相比之下, LiDAR作为一种主动遥感技术,通过发射激光脉冲并接收其回波信号,精确测量地球表面的三维结构信息[25-27]。LiDAR数据提供详细的地形和高程信息,且不易受大气条件影响。因此, LiDAR数据能有效弥补高光谱图像的不足,两者的互补信息可显著提升地表覆盖分类的精度与鲁棒性。目前,结合HSI和LiDAR的联合分类技术已广泛应用于环境监测[28,29]、精准农业[30,31],和城市规划[32,33]等领域。

近年来,深度学习的快速发展显著推动了遥感图像处理技术的进步。卷积神经网络(CNNs)凭借其强大的特征提取能力,在医学图像分割[34,35]、目标检测[36,37],和人脸识别[38,39]等任务中展现出广阔的应用前景。同样,基于CNN的方法也被广泛应用于HSI与激光雷达数据的联合分类[10,11,40-44]。依托CNNs的骨干框架,研究者开发了多种网络架构,通过提取HSI的光谱与空间特征及激光雷达数据的高程特征,实现多模态数据融合的分类。然而,由于CNNs固有的局部感受野限制,这些方法虽擅长捕捉局部特征和建模数据,却难以捕获全局上下文特征,制约了模型在更大尺度上优化性能的能力。具体而言,CNNs通过卷积操作提取局部特征,但每个卷积核仅能感知其局部范围内的信息。尽管增加网络层数或扩大卷积核尺寸可部分缓解此问题,但这会导致计算复杂度大幅上升,且仍无法充分捕捉数据的全局特征。因此,尽管基于CNN的联合分类方法在提升分类精度和鲁棒性方面成效显著,但如何有效整合局部与全局特征仍是关键挑战。

Transformer的出现为局部特征提取的挑战提供了有效解决方案,在计算机视觉(CV)领域取得显著成功,其性能甚至可与卷积神经网络(CNNs)相媲美或超越[45-49]。许多研究者已成功将Transformer架构应用于HSI与激光雷达数据的联合分类[12,50-55]。Transformer通过自注意力机制擅长融合来自两种数据源的信息,从而提升HSI和激光雷达数据场景下的分类精度与模型鲁棒性。然而,Transformer模型的高计算开销仍是重大挑战——自注意力机制的计算复杂度呈二次方增长,这意味着随着输入数据长度的增加,计算与内存需求会急剧上升,导致训练时间延长和资源消耗增加。

作为自注意力机制的有效替代方案,状态空间模型(SSM),尤其是其最新变体Mamba,已被认可为一种具有线性复杂度[56,57,57,58]的强大特征提取工具。Mamba在保留Transformer捕获长程依赖能力的同时,显著提升了计算效率并降低了内存占用。这使得基于Mamba的模型在计算机视觉领域获得广泛关注,并逐渐延伸至遥感应用领域[59-61]。基于此基础,我们通过根本性创新的架构和方法论,提出了E-Mamba——一个面向HSI与LiDAR数据的新型多模态分类框架。尽管[61]在其工作中同时探索了Mamba在该任务中的应用,但E-Mamba通过独特的两阶段融合流程与

采用二维选择性扫描的孪生视觉状态空间块设计实现了差异化。所提模型既能捕捉多模态数据中的长程依赖,克服CNNs感受野有限的缺陷,又规避了Transformer自注意力机制的巨大计算开销,同时解决了现有Mamba实现方案在处理二维空间数据及多模态融合时的局限性。本文主要贡献如下:

- (1) 为充分发挥Mamba潜力,我们采用双分支孪生视觉状态空间块(VSSB)从HSI和激光雷达模态中提取差异化特征。该方法不仅解决了CNNs在局部特征提取上的局限性,还能以线性计算复杂度实现多源图像的全局特征提取。
- (2) 为提升异质模态的融合效果,我们采用一种交叉相乘机制来增强各模态的特征,并将SSM应用于拼接后的特征嵌入,生成最终的融合结果。
- (3) 在三个基准数据集上的大量实验表明,所提模型性能优于其他对比方法,包括基于CNN和基于Transformer的模型。本研究的源代码已公开,以促进未来研究的协作贡献。

本文其余部分组织结构如下:第2节详细阐述相关研究工作,包括传统方法、基于CNN的方法、基于Transformer的方法及基于Mamba的方法;第3节概述所提模型并深入分析其三大组件;第4节介绍大量实验并对实验结果进行深度分析;第5节总结全文并指出未来研究方向。

2. 相关工作

本节全面综述了HSI与激光雷达联合分类方法,涵盖传统方法、基于CNN的方法及基于Transformer的技术。此外,我们介绍了基于Mamba架构的HSI分类最新研究,这些成果为所提模型提供了重要启发。

2.1. 传统方法

传统的HSI和激光雷达分类方法可大致分为滤波策略、低秩模型和复合核三类。滤波方法主要通过减少冗余信息,同时保留其他区域的关键特征,以有效提取上下文和空间特性。常见方法包括形态学剖面[62],属性剖面[63],以及灭绝剖面[64]。这些方法概念直观,能快速实现HSI与激光雷达的融合,从而获得精确分类。然而,它们往往面临维度灾难及后续分类步骤中高昂计算开销等挑战。低秩模型和复合核为这些局限提供了有效解决方案[65]。低秩模型假设HSI和LiDAR数据中的特征可在低维空间中表示,从而降低HSI维度并简化融合过程。相比之下,复合核方法[42]通过采用多个核函数提取不同特征,处理光谱、空间和高程特征。但设计与选择合适的核函数需谨慎校准。

2.2. 基于CNNs的方法

得益于强大的特征提取能力, CNNs通过端到端网络自动完成HSI和激光雷达的特征提取。Wu等人[66]提出了一种端到端网络, 采用CNNs并结合先进的跨通道重建模块, 实现多源遥感数据的高效融合。Wang等人[67]引入了一种多尺度空间光谱跨模态注意力网络, 其中多尺度金字塔卷积用于提取多尺度特征, 而有效的特征重标定模块则用于增强各尺度特征并抑制无关信息。为捕获更深层次、更抽象的判别性特征, Hang等人[68]提出了一种耦合CNN框架, 通过双分支结构融合异构数据: 一支从HSI中提取光谱-空间特征, 另一支从激光雷达中提取高程细节。部分研究者发现单层特征融合仅能带来边际性能提升, 从而推动了对从浅层到深层的多层特征融合的进一步探索。et al. (2023)提出了一种结合全局与局部特征的网络(NCGLF), 利用CNNs提取高频特征, Transformer处理低频信息, 展现了两种技术的协同效应。Li等人[69]提出了一种独特的双通道长短期记忆神经网络, 搭配三级融合策略, 强化了HSI与激光雷达的融合以实现更优分类。此外, Zhao等人[70]设计了分层随机游走网络(HRWN), 将双隧道CNN与随机游走层结合, 利用LiDAR数据增强空间一致性并解决分类图中的碎片化问题。然而, 基于CNN的方法在感受野方面仍存在固有局限, 其全局特征建模能力有待进一步提升。

2.3. 基于Transformer的方法

近年来, Transformer模型在计算机视觉领域获得了广泛关注。针对多模态遥感图像分类任务, 涌现了大量基于Transformer的模型。例如, Ding等人[54]提出了一种全局-局部Transformer网络, 优化了卷积算子捕捉局部相关特征的能力以及Transformer学习长程依赖关系的优势。然而, 普通视觉Transformer往往忽略局部语义信息。为解决这一问题, Zhao等人[53]提出了分数阶傅里叶图像Transformer, 旨在加速Transformer架构的同时高效捕获有价值的上下文信息。Roy等人[52]开发了多模态融合Transformer网络, 利用多头交叉块注意力机制从HS和LiDAR数据中提取互补特征, 从而获得更好的泛化性能。Yao等人[55]对传统Vision Transformer进行最小化修改, 引入跨模态注意力模块以利用遥感场景中的像素级空间相关性。Zhang等人[12]提出了多模态Transformer网络(MTNet), 通过专用HS光谱与空间Transformer和LiDAR空间Transformer, 配合重新设计的Transformer编码器来探索共享特征, 在模态特定与融合特征学习之间取得平衡。但Transformer存在二次计算复杂度的负担, 会大幅增加内存和时间开销。此外, Yang等人[71]提出LiDAR引导的交叉注意力融合方法, 利用LiDAR数据指导HS波段选择, 并通过交叉注意力融合多模态特征, 在提升分类精度的同时有效减少冗余。Ni等人[72]则提出多尺度头选择Transformer, 在Transformer框架内集成多尺度选择机制, 实现了HS与LiDAR特征在不同尺度上的融合, 增强了对复杂场景的鲁棒性和适应性。

2.4. 基于Mamba的方法

Mamba继承了状态空间模型在序列长度上的线性可扩展性, 同时融入了Transformer的建模能力[56,57,59,73]。与Transformer需要显式存储整个上下文进行推理不同, Mamba结合了选择性扫描(S6)机制, 实现了序列长度的线性扩展与快速推理。随着自然语言处理与计算机视觉的持续融合, 将高性能Mamba架构扩展至CV应用展现出广阔前景。基于Mamba的Vim架构[74], 直接处理图像块序列, 其操作方式类似Vision Transformer(ViT)。该架构将输入图像转为扁平化的二维块, 通过带位置编码的线性投影层保留空间信息, 最终通过类别标记输出分类结果。为更有效捕捉二维空间信息, VMamba[73]引入了跨扫描模块(CSM), 沿水平与垂直轴进行双向扫描。CSM将输入图像转为沿双轴的块序列, 采用选择性状态空间模型进行四方向处理。这种双向机制使每个像素能整合来自四个方向所有其他像素的信息。所有序列最终还原为原始二维布局以重构图像, 再通过扫描合并生成新表征。目前基于Mamba的模型已应用于高光谱图像分类领域。Yao等人[60]提出SpectralMamba, 采用分段序列扫描和门控空间-光谱融合来增强状态域序列学习并校正光谱数据。Li等人[75]开发的HSI-Mamba能同步建模全图长程交互, 同时自适应整合空间与光谱信息。Wang等人[76]提出面向HSI分类的空间-光谱状态空间模型, 包含两个选择性SSM分别提取空间特征和光谱特征, 并通过空间-光谱混合门优化融合效果, 实现了具有竞争力的分类性能。Liao等人[61]提出基于Mamba的联合分类网络, 先采用梯度联合算法(GJA)处理LiDAR数据提取地物边缘轮廓, 再运用Mamba进行特征提取与分类。该方法有效融合了高光谱数据的精确光谱信息和LiDAR的丰富高程信息, 解决了多模态异构特征融合难题。Li等人[77]引入自适应特征对齐网络, 采用全局-局部Mamba编码器通过二维选择性扫描机制建模上下文, 同时加入局部偏置增强地物空间特征。此外, 该方法提出的SSE自适应对齐与融合模块能自适应调整多源特征的相对位置以优化融合效果。

3. 预备知识

3.1. 状态空间模型

状态空间模型(SSMs)是一类用于分析和预测随时间演变的动态系统行为的数学模型。通常, SSMs可以用三个参数定义: $(\mathbf{A}, \mathbf{B}, \mathbf{C})$ 。这些模型通过隐藏状态 $h(t) \in \mathbb{R}^N$ 将时间相关的输入 $x(t) \in \mathbb{R}$ 转换为一组输出 $y(t) \in \mathbb{R}$ 。计算过程可表示为:

$$\begin{aligned} h'(t) &= \mathbf{A}h(t) + \mathbf{B}x(t), \\ y(t) &= \mathbf{C}h(t) + \mathbf{D}x(t), \end{aligned} \quad (1)$$

其中 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 表示状态转移矩阵。 $\mathbf{B} \in \mathbb{R}^{N \times 1}$ 和 $\mathbf{C} \in \mathbb{R}^{1 \times N}$ 是投影矩阵。结构化状态空间模型(S4)受用于一维序列的连续系统启发。

并利用采样时间尺度参数 Δ 将连续状态空间模型转换为离散SSM。因此,连续信号输入 $x(t)$ 到输出 $y(t)$ 的映射被转换为序列到序列的映射: $x_k \rightarrow y_k$, 这便于处理离散标记输入, 如图像和文本。

该过程可分为两个阶段: 第一阶段是离散化, 通过采样时间尺度参数 Δ 将连续参数 $(\mathbf{A}, \mathbf{B})$ 转换为离散参数 $(\mathbf{A}, \mathbf{B})$ 。这一转换通常采用零阶保持(ZOH)实现, 从而得到离散方程:

$$\begin{aligned}\bar{\mathbf{A}} &= e^{\Delta \mathbf{A}}, \\ \bar{\mathbf{B}} &= (\Delta \mathbf{A})^{-1} (e^{\Delta \mathbf{A}} - \mathbf{I}) \cdot \Delta \mathbf{B}, \\ h_k &= \bar{\mathbf{A}} h_{k-1} + \bar{\mathbf{B}} x_k, \\ y_k &= \mathbf{C} h_{k-1}.\end{aligned}\quad (2)$$

其中 $\mathbf{A} \in \mathbb{R}^{N \times N}$, $\mathbf{B} \in \mathbb{R}^{N \times 1}$ 和 $\mathbf{C} \in \mathbb{R}^{1 \times N}$ 。第二个阶段是计算, 该模型通过全局卷积计算输出:

$$\begin{aligned}\bar{\mathbf{K}} &= (\mathbf{C}\bar{\mathbf{B}}, \mathbf{C}\bar{\mathbf{A}}\bar{\mathbf{B}}, \dots, \mathbf{C}\bar{\mathbf{A}}^{L-1}\bar{\mathbf{B}}), \\ y &= x * \bar{\mathbf{K}},\end{aligned}\quad (3)$$

其中 L 是输入序列 x 的长度, 且 $\mathbf{K} \in \mathbb{R}^L$ 是一个一结构化卷积核。

3.2. 选择性状态空间模型 (S6)

先前的线性时不变状态空间模型缺乏上下文感知, 导致S4对所有令牌给予同等关注, 无论其重要性如何变化。实际上, 令牌的重要性在训练过程中会动态变化。因此, 更有效的方法是聚焦重要内容并动态调整关注度以匹配输入复杂度。为此, Mamba将选择机制整合到状态空间模型中, 形成选择性状态空间模型 (S6)。具体而言, 为处理批次大小 B 、长度 L 及 D 通道的输入序列, Mamba将SSM独立应用于每个通道。在Mamba中, S4的矩阵 $\mathbf{B}$ 、 $\mathbf{C}$ 和 Δ 均为输入的函数, 使得模型能自适应地调整其行为。整合选择机制后的离散化过程如下,

$$\bar{\mathbf{B}} = s_B(x) \quad (4)$$

$$\bar{\mathbf{C}} = s_C(x) \quad (5)$$

$$\Delta = \tau_A(\text{Parameter} + s_A(x)), \quad (6)$$

其中 $\mathbf{B} \in \mathbb{R}^{B \times L \times N}$ 、 $\mathbf{C} \in \mathbb{R}^{B \times L \times N}$ 和 $\Delta \in \mathbb{R}^{B \times L \times D}$ 。 $s_B(x)$ 和 $s_C(x)$ 是将输入 x 投影到 N 维空间的线性函数, 而 $s_A(x)$ 则将隐藏状态维度 D 线性投影至目标维度。通过上述计算, 参数 Δ 、 $\mathbf{B}$ 、 $\mathbf{C}$ 变为长度为 L 的输入函数, 从而将时不变模型转化为时变模型, 实现选择性。借助此选择机制, Mamba能够有效建模长序列中存在的复杂交互关系。

4. 方法

4.1. 孪生视觉状态空间块 (SVSSB)

孪生视觉状态空间块 (SVSSB) 被设计为两条并行分支结构, 两种数据类型均通过由权重参数共享的 VSSBlocks 构成的孪生网络进行处理, 从而实现对空间与光谱特征的联合提取, 并减少计算参数 (见图1)。然而, 在自然语言处理 (NLP) 领域, S6 机制

作为状态空间模型 (SSM) 的核心, 更擅长处理 NLP 任务中常见的一维序列数据, 但对具有二维空间结构的图像数据处理效果欠佳。受 VMamba 启发, 我们采用交叉扫描策略来弥合一维序列数据与二维图像之间的鸿沟。

给定原始多源高光谱影像和LiDAR数据, 分别记为 $X_{hsi} \in \mathbb{R}^{H \times W \times C}$ 和 $X_{lidar} \in \mathbb{R}^{H \times W \times 1}$, 两者均采集自同一地理区域, 其中 C 、 H 和 W 分别对应光谱通道、高度和宽度。由于获取方法不同, HSI与LiDAR数据的通道维度差异显著, 需通过 1×1 卷积将LiDAR的单通道数据与HSI的多通道特征空间对齐。处理后的HSI和LiDAR数据可表示为:

$$X_m = \{x_m^{(i,j)} \mid i = 0, 1, \dots, H-1, j = 0, 1, \dots, W-1\} \quad m = \{hsi, lidar\}, \quad (7)$$

其中 m 指代特定模态数据 (HSI 或 LiDAR), $x_m^{(i,j)}$ 表示土地覆盖图中空间位置 (i, j) 处的像素信息。对于HSI和LiDAR数据, 均以真值像素为中心构建图像立方体, 其表达式如下:

$$X_m^{(i,j)} = \begin{pmatrix} x_m^{[i-(p/2), j-(p/2)]} & x_m^{[i-(p/2), j-(p/2)+1]} & \dots & x_m^{[i-(p/2), j+(p/2)]} \\ x_m^{[i-(p/2)+1, j-(p/2)]} & x_m^{[i-(p/2)+1, j-(p/2)+1]} & \dots & x_m^{[i-(p/2)+1, j+(p/2)]} \\ \vdots & \vdots & \ddots & \vdots \\ x_m^{[i+(p/2), j-(p/2)]} & x_m^{[i+(p/2), j-(p/2)+1]} & \dots & x_m^{[i+(p/2), j+(p/2)]} \end{pmatrix} \in \mathbb{R}^{C \times p \times p} \quad (8)$$

其中 $(p/2) \leq i \leq H - (p/2 + 1)$ 和 $(p/2) \leq j \leq W - (p/2 + 1)$ 。为有效利用二维图像的空间结构, 我们对每个图像立方体采用交叉扫描策略 (CSS)。该策略旨在遍历空间域, 并通过四向扫描方法将任意非因果视觉图像转换为序列块序列。具体而言, 图像立方体会沿行和列方向扩展为序列, 随后进行四个不同方向的扫描 (可参考图2)。该过程形式化表示如下 (参见方框I中的式(9)):

其中 $S_{(m, type1)}^{(i,j)}$ 表示从左到右下的扫描顺序。符号 $V \rightarrow H$ 表示从左到右的水平扫描, 当到达行末元素后, 扫描垂直下移一行, 并再次从最左侧元素开始。此过程持续进行直至到达右下像素, 完成整个扫描序列。反之, $S_{(m, type3)}^{(i,j)}$ 表示从右下到左上的扫描顺序, 但扫描方向存在变化。 $H \rightarrow V$ 代表从上到下的垂直扫描, 当到达列末元素后, 扫描会右移至下一列, 并从该列最顶部元素重新开始。此过程持续直至到达右下像素, 形成另一种扫描序列。 $S_{(m, type2)}^{(i,j)}$ 和 $S_{(m, type4)}^{(i,j)}$ 则分别遵循相反顺序。因此, 我们以 $S_{(m, type1)}^{(i,j)}$ 作为示例输入至Mamba架构中,

$$\begin{aligned}h_{(m, type1)}^{(i,j)}(t) &= \bar{\mathbf{A}} h_{(m, type1)}^{(i,j)}(t-1) + \bar{\mathbf{B}} S_{(m, type1)}^{(i,j)}(t) \\ y_{(m, type1)}^{(i,j)}(t) &= \mathbf{C} h_{(m, type1)}^{(i,j)}(t) + \mathbf{D} S_{(m, type1)}^{(i,j)}(t).\end{aligned}\quad (10)$$

接下来, 将不同扫描路径获得的输出序列进行融合, 形成最终的输出地图。

$$S_{(output)} = \text{Merge}\{S_{(m, type1)}^{(i,j)}, S_{(m, type2)}^{(i,j)}, S_{(m, type3)}^{(i,j)}, S_{(m, type4)}^{(i,j)}\}, \quad (11)$$

通过采用互补的遍历路径, SS2D使得图像中的每个像素能够有效地吸收来自所有其他像素在不同方向上的信息, 从而构建全局感受野。




图 1. 所提方法 E-Mamba 及其组件的示意图。(a) E-Mamba 的框架。(b) 交叉选择性扫描。(c) VSSBlock。(d) 跨架构特征提取块。(e) 模态引导 Mamba 融合。(f) 拼接选择性扫描。

$$\begin{aligned}
 S_{(m, \text{type1})}^{(i, j)} &= \left[x_m^{[i-(p/2), j-(p/2)]}, x_m^{[i-(p/2), j-(p/2)+1]}, \dots, x_m^{[i+(p/2), j+(p/2)]} \right]^T & \text{左上} & \rightarrow \text{右下} & (H \rightarrow V) \\
 S_{(m, \text{type2})}^{(i, j)} &= \left[x_m^{[i+(p/2), j+(p/2)]}, x_m^{[i+(p/2), j+(p/2)-1]}, \dots, x_m^{[i-(p/2), j-(p/2)]} \right]^T & \text{右下} & \rightarrow \text{顶部左侧} & (H \rightarrow V) \\
 S_{(m, \text{type3})}^{(i, j)} &= \left[x_m^{[i-(p/2), j-(p/2)]}, x_m^{[i-(p/2)+1, j-(p/2)]}, \dots, x_m^{[i+(p/2), j+(p/2)]} \right]^T & \text{顶部左侧} & \rightarrow \text{底部右侧} & (V \rightarrow H) \\
 S_{(m, \text{type4})}^{(i, j)} &= \left[x_m^{[i+(p/2), j+(p/2)]}, x_m^{[i+(p/2)-1, j+(p/2)]}, \dots, x_m^{[i-(p/2), j-(p/2)]} \right]^T & \text{底部右侧} & \rightarrow \text{顶部左侧} & (\text{伏} \rightarrow \text{赫})
 \end{aligned} \tag{9}$$

Box I.

4.2. 交叉Mamba 特征提取块 (CMFEB)

通过先前引入的SVSSB处理后，两个并行且权重共享的特征提取分支分别对HSI和LiDAR异构数据执行从浅层到深层的特征提取。然而，这两个分支提取的特征仍保持独立。针对多源数据联合分类任务，有效融合这些特征对提升分类性能至关重要。为此，我们提出同样基于Mamba架构的交叉Mamba特征提取块 (CMFEB)，旨在特征层级上融合HSI与激光雷达的特征嵌入。

CMFEB接收两组输入特征并生成两个输出，同时保持输入特征的原始形状。首先，两组输入特征会经过线性层和深度卷积 (DWConv) 处理，随后被传递至交叉选择性扫描模块 (CSSM) ——CMFEB的核心组件。根据Mamba固有的选择机制，系统矩阵 B 、 C 和 δ 会基于输入动态生成，从而实现模型的上下文感知能力。线性投影层被用于构建这些矩阵，其中矩阵 C 用于解码信息

隐藏状态 h_k 并生成输出 y_k 。受多模态任务中广泛使用的交叉注意力机制启发，我们试图促进跨多个状态空间模型 (SSMs) 的信息交换。为实现这一目标，我们提出利用互补模态在选择性扫描操作期间生成的 C 矩阵，使得SSM能够在另一模态的引导下，从隐藏状态重构输出。具体而言，该过程可表示为：

$$\begin{aligned}
 \bar{A}_{\text{hsi}} &= \exp(\Delta_{\text{hsi}} A_{\text{hsi}}), \bar{A}_{\text{lidar}} = \exp(\Delta_{\text{lidar}} A_{\text{lidar}}) \\
 \bar{B}_{\text{hsi}} &= \Delta_{\text{hsi}} B_{\text{hsi}}, \bar{B}_{\text{lidar}} = \Delta_{\text{lidar}} B_{\text{lidar}}, \\
 h_{\text{hsi}}^t &= \bar{A}_{\text{hsi}} h_{\text{hsi}}^{t-1} + \bar{B}_{\text{hsi}} x_{\text{hsi}}^t, h_{\text{lidar}}^t = \bar{A}_{\text{lidar}} h_{\text{lidar}}^{t-1} + \bar{B}_{\text{lidar}} x_{\text{lidar}}^t, \\
 y_{\text{hsi}}^t &= C_{\text{lidar}} h_{\text{hsi}}^t + D_{\text{hsi}} x_{\text{hsi}}^t, y_{\text{lidar}}^t = C_{\text{hsi}} h_{\text{lidar}}^t + D_{\text{lidar}} x_{\text{lidar}}^t, \\
 y_{\text{hsi}} &= [y_{\text{hsi}}^1, y_{\text{hsi}}^2, \dots, y_{\text{hsi}}^T], y_{\text{lidar}} = [y_{\text{lidar}}^1, y_{\text{lidar}}^2, \dots, y_{\text{lidar}}^T],
 \end{aligned} \tag{12}$$

其中 x_m^t 表示时间步的输入， y_m^t 代表选择性扫描操作的输出。矩阵 C_{hsi} 和 C_{lidar} 作为跨模态矩阵，用于从隐藏状态中恢复每个时间步的输出。




图 2. (a) 四方向 交叉扫描 。 (b) 二维选择性扫描 操作。

4.3. 模态引导的 Mamba 融合 块 (MMFB)

两种模态的特征通过跨选择性扫描操作交互，在CMFEB中生成跨模态增强特征。虽然该模块接收来自两种异构数据源的输入并输出相应的增强特征，但我们进一步提出了模态引导的Mamba融合块 (MMFB)，以整合两种模态的关键信息。以往基于Transformer的方法受限于二次方计算复杂度，通常将输入分割为小块，限制了捕获令牌内信息的能力。相比之下，借助Mamba高效的长序列建模能力，我们的MMFB直接处理拼接后的特征，从而保留了两种模态的最大信息量。

具体而言，CMFEB的输出 $\hat{F}_{\text{hsi}}^k$ 和 $\hat{F}_{\text{lidar}}^k \in \mathbb{R}^{H_k \times W_k \times C_k}$ 首先通过线性层和卷积层处理，随后输入至拼接选择性扫描模块 (CSSM)。在CSSM中，两个特征被展平为 $\mathbb{R}^{(H_k \times W_k) \times C_k}$ 并沿序列长度维度拼接，形成形状为 $\mathbb{R}^{(2 \times H_k \times W_k) \times C_k}$ 的序列 S_{Concat}^k 。为从双模态中进一步捕获全面信息，我们对拼接序列 S^k_{Concat} 实施逆向扫描，生成附加序列 $S_{\text{Concat}}^k \in \mathbb{R}^{(2 \times H_k \times W_k) \times C_k}$ 。每个序列随后由一维SSM处理，以捕获跨模态的长程依赖，得到 $\hat{S}^k_{\text{Concat}}$ 和 $\hat{S}^k_{\text{Inverse}}$ 。逆向序列经翻转后与处理后的拼接序列合并，最终求和序列被拆分以恢复原始输入双模态。该过程可表示为：

$$\begin{aligned} \tilde{F}_{\text{hsi}}^k &= \text{DWConv}(\text{Linear}(\hat{F}_{\text{hsi}}^k)), \tilde{F}_{\text{lidar}}^k = \text{DWConv}(\text{Linear}(\hat{F}_{\text{lidar}}^k)), \\ S_{\text{Concat}}^k &= \text{Concat}(\tilde{F}_{\text{hsi}}^k, \tilde{F}_{\text{lidar}}^k, \text{dim} = 0), \\ S_{\text{Inverse}}^k &= \text{Inverse}(S_{\text{Concat}}^k), \\ \hat{S}_{\text{Concat}}^k, \hat{S}_{\text{Inverse}}^k &= \text{SSM}(S_{\text{Concat}}^k), \text{SSM}(S_{\text{Inverse}}^k), \\ \bar{F}_{\text{hsi}}^k, \bar{F}_{\text{lidar}}^k &= \text{Separate}(\hat{S}_{\text{Concat}}^k + \text{Inverse}(\hat{S}_{\text{Inverse}}^k)). \end{aligned} \quad (13)$$

在获取扫描特征 $\tilde{F}_{\text{hsi}}^k$ 和 $\tilde{F}_{\text{lidar}}^k$ 后，这些特征会分别乘以从 $\hat{F}_{\text{hsi}}^k$ 和 $\hat{F}_{\text{lidar}}^k$ 导出的两个缩放参数。所得特征随后沿通道维度拼接，生成形状为 $\mathbb{R}^{H_k \times W_k \times (2 \times C_k)}$ 的特征。最后，应用线性投影层将特征形状缩减至 $\mathbb{R}^{H_k \times W_k \times C_k}$ 。

三种不同数据集的可视化结果，包括HSI伪彩色图和激光雷达灰度图，如图3所示。

5. 实验 结果 与 分析

5.1. 数据集 描述

(1) Houston 2013数据集：Houston2013数据集包含空间分辨率为2.5米的HSI和LiDAR数据，覆盖区域达 349×1905 像素。HS数据包含144个光谱波段，波长范围从0.38至1.05 μm 。该数据集涵盖15种不同的土地覆盖类别。

(2) Trento数据集：Trento数据集包含空间分辨率为1米的HSI和LiDAR数据，覆盖区域达 166×600 像素。HS数据由63个光谱波段组成，波长范围从0.42至0.99 μm 。该数据集包含6种不同的土地覆盖类别。

(3) MUUFL数据集：MUUFL Gulfport¹ 数据集于2010年11月在美国密西西比州长滩的南密西西比大学Gulf Park校区采集。该数据集中，HSI数据包含64个光谱波段，范围从0.38至1.05 μm ，而LiDAR数据则包括2个波长为1.06 μm 的栅格。数据集覆盖了 325×220 像素区域，并包含11种不同的土地覆盖类别。

5.2. 实验 配置

•评估指标：定量分类性能通过三个指标进行评估：总体精度(OA)、平均精度(AA)、Kappa系数(κ)以及每个类的精度。这些指标范围从0到1，值越高表示性能越优。OA、AA和 κ 是通过汇总所有像素级预测并与相应的真实标签比较而具体得出的。

$$\begin{aligned} OA &= \frac{N_c}{N_a}, \\ AA &= \frac{1}{K} \sum_{j=1}^K \frac{N_c^j}{N_a^j}, \\ \kappa &= \frac{OA - P_e}{1 - P_e}. \end{aligned} \quad (14)$$

¹ <https://github.com/GatorSense/MUUFLGulfport>.




图 3. 三个数据集的 HSI 伪彩色图与激光雷达灰度图可视化结果。顶部为休斯顿数据集，左下为特伦托数据集，右下为 MUUFL 数据集。

其中 N_c 和 N_a 分别表示正确分类的样本数和测试样本总数，而 N_c^j 和 N_a^j 则对应特定 j 类的这些数值。 κ 的计算通过纳入偶然一致性的假设概率 P_e 来解决类别不平衡问题，其定义为

$$P_e = \frac{\sum_{j=1}^K N_a^j \times N_p^j}{(N_a)^2}. \quad (15)$$

•实现细节：实验在一台配备256GB内存和RTX 3090 GPU的Linux PC服务器上执行。所提模型使用PyTorch实现，并采用AdamW优化器进行优化。共训练300轮次，初始学习率设置为：Houston数据集0.0003、Trento数据集0.0001、MUUFL数据集0.001，衰减率为0.0001。此外，每30轮次学习率减半。

•对比其他模型：选取了多种基于CNN和基于transformer的模型进行对比实验，其详细配置如下所述。

1. CALC² [78] 是一个包含编码与解码组件的对抗式特征学习框架。编码部分由一个2D卷积（内核尺寸为 3×3 ）组成，后接批量归一化和ReLU激活

激活、和最大池化。池化窗口大小为

2×2 128 32, 且 64,

卷积核数量被设为和。解码部分包含上采样、一个2D卷积（使用 3×3 核）、批量归一化以及ReLU激活。

2. GAMF³ [79] 通过参数共享考虑多传感器数据间的相关性与互补性，采用高斯令牌化进行特征转换。融合模块利用模态特定令牌构建无向加权图，并通过两个全连接层对融合嵌入进行分类以生成最终结果。

3. GLTNet⁴ [54] 的特点在于其多尺度聚合卷积编码器和全局光谱特征学习模块，该模块结合了CNNs与Transformer组件，能够实现精细特征提取，覆盖全局和局部尺度。

4. M2FNet⁵ [80] 采用多尺度3D-2D混合CNN架构，从HSI数据中提取空谱特征，并从LiDAR数据中提取高程特征。这些特征由创新编码器处理，该编码器包含一个融合数学形态学与膨胀操作的特征增强模块。

³ <https://github.com/tyust-dayu/GAMF>.

⁴ <https://github.com/Ding-Kexin/GLT-Net>.

⁵ <https://github.com/cupid6868/M2FNet.git>.

² <https://github.com/Ding-Kexin/CALC>.

受标准Transformer 编码器自注意力机制启发的 卷积 模块 MS2CANet⁶ [67] 利用 金字塔卷积 从多源 遥感影像中捕获多尺度特征。通过引入有效的特征重校准模块 来放大相关特征 并抑制不同尺度下的冗余信息。

6. S²ENet⁷ [81] 模型整合了两个特征增强模块：空间注意力增强模块和光谱注意力增强模块。前者利用HSI特征增强激光雷达数据的空间表征，后者则借助LiDAR信息优化HSI数据的光谱表征。实验结果按照原始研究指定的超参数配置复现。

7. MFT⁸ [52] 采用 Conv3D 与HetConv2D 层 依次处理原始 HSI数据，同时LiDAR数据通过像素或通道标记化 进行处理。特征融合通过HSI与LiDAR区间的交叉注意力 实现。

8. ExViT⁹ [55] 包含 三个 模块， 结合 了可分离 卷积 与 Transformer 编码器， 能够 独立 处理 HSI 和 激光雷达数据， 再进行 特征 融合。

9. HLMamba¹⁰ [61] 首先 对 激光雷达 数据 执行 梯度 联合 算法 以 提取 边缘 轮廓 信息。随后，基于 CNNs 的多模态 特征 提取 模块 (MFEM) 从 HSI 与 激光雷达 数据中 提取 特征。

5.3. 参数 实验

(1) 图像块尺寸影响：所提方法在不同图像块尺寸下的分类性能分析表明，选择最优空间尺寸对有效特征提取和准确分类至关重要。图4展示了休斯顿、特伦托和MUUFL数据集在空间尺寸 5×5 至 15×15 范围内的总体精度 (OA)、平均精度 (AA) 及 κ 值。对于休斯顿数据集，当空间尺寸从 5×5 增至 9×9 时，分类指标明显提升，三项指标 (OA、AA和 κ) 均在 9×9 达到峰值，说明中等空间尺寸最能有效捕获相关特征。

在最小化无关信息引入的同时。然而，超过 9×9 后，性能出现轻微下降，这可能是由于包含了过多对分类任务无实质贡献的周边像素。对于 Trento数据集，性能指标从 5×5 到 9×9 保持稳定高位，并在 9×9 处略有峰值。但当空间尺寸超过 11×11 时，特别是在 15×15 处，三项指标均出现显著下滑。这一急剧下降可归因于数据集特性——更大的空间尺寸可能引入噪声和冗余信息，从而削弱模型准确分类目标的能力。对于 MUUFL数据集，最佳性能出现在较小空间尺寸下 (具体为 5×5)。随着像斑尺寸增大，总体精度、平均精度及 κ 明显下降，最低性能记录于 15×15 处。这表明较小像斑对MUUFL数据集更有效，这很可能源于其独特的特征分布——更少上下文但更聚焦的信息反而更有利。基于这些观察，实现高分类精度同时保持性能的最优像斑尺寸应...

计算 效率 对于 9×9 休斯顿 和 特伦托 数据集 是 7×7 对于 MUUFL 数据集。

(2) 训练比例的影响：我们在Houston数据集、特伦托数据集和 MUUFL数据集上通过改变训练样本比例 (0.1、0.3、0.5、0.7、0.9) 进行了实验。评估了包括CALC、GAMF、GLTNet、M2FNet、MS2CANet、S²ENet、MFT、ExViT以及所提方法在内的多个模型的总体精度 (OA)。结果如图5所示，展示了训练比例与模型性能之间的关系。对于Houston数据集，所提方法随着训练比例的增加呈现出持续上升的OA趋势。值得注意的是，即使在仅有0.1训练样本的情况下，所提方法的性能仍优于某些使用较大训练比例的模型。当训练比例达到0.3及以上时，所提方法继续超越其他模型，展现了其在有限数据下学习的鲁棒性和高效性。而像CALC和GLTNet这样的模型

虽然其他模型也表现出强劲性能，但在较高训练比例下会进入平台期，表明相较于所提方法，它们对额外训练数据的利用效率较低。在Trento数据集中，所提方法再次在不同训练比例下领跑性能表现，尤其在较低比例 (0.1至0.3) 时优于所有其他模型。随着训练比例增加，所提方法的OA持续上升，而如MS2CANet和S²ENet等模型则呈现相对平缓甚至下降趋势，这可能是由于过拟合或泛化能力随训练集增大而减弱所致。对于 MUUFL数据集，所提方法在所有训练比例下均保持强劲表现，始终位居顶级模型之列。当训练比例从0.1增至0.5时，OA提升尤为显著，之后增长率趋于稳定。相比之下，ExViT和S²ENet等模型改进速度较慢，最终落后于所提方法，尤其在较高训练比例时更明显。这凸显了所提方法能有效利用可用数据提升分类精度的优势。总体而言，结果表明所提方法在不同训练样本规模下始终实现卓越分类性能，在训练数据有限场景中表现尤为突出。其在大规模数据集上的鲁棒性和可扩展性进一步彰显了在HSI和激光雷达数据分类任务中更广泛应用的潜力。

(3) VSSBlock层数影响分析：为探究VSSBlock深度对所提方法分类性能的影响，我们通过实验将深度从1层调整至4层。结果如图6所示。随着VSSBlock深度从1层增至4层，分类指标 (包括总体精度、平均精度和 κ) 呈现持续提升。在全部三个数据集中，4层深度均展现出最佳性能，这表明增加VSSBlock深度有助于模型捕捉更复杂的特征，从而提高分类精度。因此，对于这些数据集而言，4层深度的VSSBlock能提供最优分类性能，相比浅层结构具有更好的特征表示能力和更高的准确率。

(4) 计算复杂度分析：为证明所提方法较低的计算复杂度，我们在特伦托和MUUFL数据集上对比了总体精度、平均精度及计算参数数量与其他方法的差异。图8结果显示，所提方法在参数更少的情况下，仍能取得最优的总体精度和平均精度。对比方法如S²ENet和MS2CANet虽具备较强分类精度，但其参数需求远超E-Mamba，这对HSI和激光雷达分类任务的时效性构成挑战。此外，图中明显可见GAMF的气泡面积最大，表明其参数数量巨大，但在这两个数据集上的分类性能却不理想。其他方法如M2FNet虽然参数较少，但其分类精度较所提方法显著偏低。我们还进行了一项新实验来对比训练

⁶ <https://github.com/junhengzhu/MS2CANet>.
⁷ <https://github.com/likyoo/Multimodal-Remote-Sensing-Toolkit>.
⁸ <https://github.com/AnkurDeria/MFT>.
⁹ <https://github.com/jingyao16/ExViT>.
¹⁰ <https://github.com/Dilingliao/HLMamba>.




图 4. 图像立方体空间尺寸对三个数据集从 5×5 到 15×15 的影响。(a) 休斯顿数据集。(b) 特伦托数据集。(c) MUUFL 数据集。




图 5. 不同训练比例对三个数据集从 0.1 到 0.9 以 0.2 为间隔的影响。(a) 休斯顿数据集。(b) 特伦托数据集。(c) MUUFL 数据集。




图 6. VSSBlock 深度对三个数据集从 1 到 4 层的影响。(a) 休斯顿数据集。(b) 特伦托数据集。(c) MUUFL 数据集。

表6展示了不同方法在多个数据集上的训练时间。总体而言，我们的方法不仅以更少参数实现卓越分类性能，同时保持高效训练时间，进一步强化了其在HSI和激光雷达分类任务中的实用性和有效性。

5.4. 与其他模型的比较

基于休斯顿、特伦托和MUUFL数据集的定量实验结果表格，所提方法相比其他模型始终展现出卓越分类性能。三个数据集中各对比方法的定量分类结果见表1-3。对于休斯顿数据集，所提方法以93.81%的总体精度达到最高水平，超越所有其他方法，尤其在“树木”、“铁路”和“跑道”等类别中表现突出。

该方法要么与竞争模型精度相当，要么更胜一筹。平均精度和 κ 分数进一步凸显了所提方法的稳健性，分别达到94.29%和93.28%，表明其不同土地覆盖类型上具有强大的泛化能力和一致的分类性能。在Trento数据集上，所提方法再次超越竞争模型，以99.06%的总体精度创下最高纪录。该方法在“苹果”和“树林”类别的表现尤为突出，实现了近乎完美的分类精度。98.6%的平均精度和 κ 98.74% 的分数进一步证明了其在捕捉Trento数据集固有复杂光谱和空间特征方面的有效性。对于MUUFL数据集，所提方法以91.47%的最高总体精度保持领先优势，在“树木”、“建筑”和“布面板”等类别中展现出强大性能。该方法90.45%的平均精度和 κ 88.77% 的分数凸显了其在多样化的城市与自然地理物覆盖中稳定可靠的表现，始终优于其他对比模型。




图 7. 所提方法 在三个数据集 上得到的混淆矩阵。(a) 休斯顿 数据集。(b) 特伦托 数据集。(c) MUUFL 数据集。




图8. 不同方法在不同数据集上的总体精度、平均精度和训练参数对比。X轴表示总体精度值，Y轴显示平均精度值。气泡大小反映每个模型的训练参数数量。(a)特伦托数据集。(b)MUUFL数据集。

表 1
不同方法 在休斯顿 数据集 上的分类 结果。最佳结果 以加粗 标出，次佳结果 以下划线 标注。

Class 编号	训练/测试	CALC	GAMF	GLTNet	M2FNet	MS2CANet	S²E-Net	MFT	ExViT	HLMamba	所提方法
1	Healthy grass (198/1053)	80.91	83.10	83.10	92.12	82.43	83.10	82.11	83.74	82.18	82.81
2	Stressed grass (190/1064)	83.65	84.68	84.02	84.59	85.15	99.44	93.44	<u>99.46</u>	98.72	99.06
3	Synthetic grass (192/505)	91.88	100.00	96.24	98.22	99.40	100.00	<u>99.43</u>	96.63	98.06	99.80
4	Tree (188/1056)	90.34	87.97	92.04	97.82	<u>99.81</u>	100.00	97.02	99.10	99.93	97.35
5	Soil (186/1056)	100.00	99.62	100.00	96.02	<u>99.91</u>	100.00	99.35	98.47	100.00	100.00
6	Water (182/143)	100.00	93.01	<u>97.90</u>	95.80	100.00	95.8	96.3	96.97	98.15	95.80
7	Residential (196/1072)	86.38	83.58	87.59	88.15	89.37	<u>92.44</u>	95.6	88.33	91.58	<u>92.44</u>
8	Commercial (191/1053)	81.48	76.16	78.82	90.22	89.55	96.68	87.70	90.19	90.32	<u>90.69</u>
9	Road (193/1059)	81.49	69.97	92.26	<u>92.35</u>	85.08	86.69	91.47	87.82	92.85	93.39
10	Highway (191/1036)	68.53	53.19	68.44	52.99	87.64	81.47	73.48	<u>83.36</u>	88.18	89.48
11	Railway (181/1054)	100.00	74.86	82.73	91.08	97.91	93.26	94.69	95.85	98.52	<u>99.91</u>
12	Park lot 1 (192/1041)	96.45	85.21	94.52	<u>97.11</u>	98.17	85.4	88.03	87.99	85.77	87.99
13	Park lot 2 (184/285)	90.18	83.51	91.58	87.72	90.88	88.42	84.87	<u>92.38</u>	93.28	88.77
14	Tennis court (181/247)	99.19	100.00	95.55	100.00	92.71	100.00	100.00	<u>99.34</u>	98.25	99.19
15	Running track (187/473)	<u>99.79</u>	98.10	94.29	<u>99.79</u>	98.31	100.00	100.00	100	97.05	97.67
OA (%)		88.12	82.07	87.54	89.46	92.19	<u>92.66</u>	91.25	92.31	92.97	93.81
AA (%)		90.02	84.86	89.27	90.93	93.09	<u>93.51</u>	92.23	93.31	94.19	94.29
κ×100 (%)		87.12	80.56	86.54	88.58	91.58	<u>92.03</u>	90.51	91.67	93.10	93.28

混淆 矩阵 可由 所提 模型 生成，其 结果 如 图7所示。

5.5. 视觉 评估

基于Houston数据集、特伦托数据集和MUUFL数据集在不同方法下的分类图，可以得出关于每种方法在准确捕捉真实标签性能方面的几个关键观察结果。三种数据集中各方法获得的对应分类图如图9–11所示。对于Houston数据集，所提方法表现出

卓越分类性能，相比其他方法能更精细、准确地呈现各类土地覆盖类型。所提方法在不同类（尤其是复杂区域）间展现出清晰的边界，而CALC和M2FNet等方法在相似类（如不同草种与道路表面）的区分上往往模糊不清。在Trento数据集中，所提方法再次表现优异，以高精度捕捉明显的类边界，特别是在建筑物与葡萄园相邻区域。相较于MS2CANet和ExViT等方法，所提方法显著减少误分类，并更好地保持了道路、树木等小类别的结构特征——这些类别

表 2
不同方法在特伦托数据集上的分类结果。最佳结果以加粗显示，次优结果则标有下划线。

Class 编号	训练/测试	CALC	GAMF	GLTNet	M2FNet	MS2CANet	S ² ENet	MFT	ExViT	HLMamb a	所提方法
1	苹果 (129/3905)	99.95	98.39	99.00	<u>99.36</u>	99.08	97.08	91.92	98.04	99.08	98.21
2	建筑物 (125/1064)	99.64	99.82	99.28	99.82	96.51	100.00	<u>99.97</u>	99.75	99.06	99.14
3	地面 (1058/374)	50.80	93.58	<u>98.93</u>	74.60	95.45	94.39	97.54	86.18	98.03	99.47
4	树林 (154/8969)	99.83	98.75	100.00	99.99	100.00	100.00	100.00	99.78	100.00	100.00
5	葡萄园 (184/10317)	99.71	98.68	100.00	100.00	100.00	99.88	<u>99.96</u>	100.00	99.14	99.71
6	道路 (122/3525)	91.42	92.14	92.37	76.38	<u>94.43</u>	88.37	81.23	92.71	92.17	95.05
总体精度 (%)		98.29	98.03	<u>98.99</u>	97.12	98.88	98.29	96.9	98.69	98.66	99.06
平均精度 (%)		90.22	96.89	<u>98.26</u>	91.69	97.58	96.62	95.10	96.08	98.06	98.60
$\kappa \times 100$ (%)		97.71	97.36	<u>98.65</u>	96.14	98.54	97.71	95.87	98.25	98.06	98.74

表格 3
不同方法在MUUFL数据集上的分类结果。最佳结果以加粗显示，次佳结果以下划线标示。

Class 号	训练/测试	CALC	GAMF	GLTNet	M2FNet	MS2CANet	S ² ENet	MFT	ExViT	HLMamba	所提方法
1	树木 (150/23246)	<u>93.09</u>	89.28	91.31	84.29	94.63	90.66	90.24	88.05	92.32	92.98
2	多为草 (150/4270)	85.95	89.95	78.71	83.88	85.49	<u>86.31</u>	74.07	81.90	86.58	83.13
3	混合地面表面 (150/6882)	81.24	73.57	86.26	80.24	75.83	79.69	76.30	77.70	85.98	84.55
4	泥土和沙子 (150/1826)	97.29	94.39	<u>97.08</u>	91.71	93.68	93.02	93.61	92.5	92.61	93.44
5	道路 (150/6887)	<u>91.72</u>	89.49	90.73	86.43	90.10	90.42	80.96	90.14	89.70	92.61
6	水 (150/466)	100.00	97.47	99.37	100.00	97.78	99.68	<u>99.72</u>	99.72	98.57	99.68
7	建筑阴影 (150/2233)	95.10	94.77	94.19	97.31	93.57	93.76	91.02	<u>95.35</u>	93.78	91.74
8	建筑 (150/6240)	94.88	96.19	<u>96.37</u>	87.80	95.80	95.52	95.78	96.19	96.87	96.93
9	人行道 (150/1385)	78.30	78.38	81.13	87.29	88.58	90.28	66.25	85.31	87.98	<u>89.80</u>
10	黄色路缘 (150/183)	90.91	100.00	87.88	90.91	90.91	87.88	88.46	89.74	92.82	96.97
11	布料面板 (150/269)	99.16	<u>98.32</u>	99.16	99.16	99.16	99.16	96.95	96.95	98.37	99.16
总体精度 (%)		<u>90.94</u>	88.34	90.30	85.38	90.85	89.70	86.28	87.92	91.01	91.47
平均精度 (%)		<u>91.60</u>	91.07	91.11	89.91	91.41	91.49	86.67	90.32	92.32	92.82
$\kappa \times 100$ (%)		<u>88.08</u>	84.78	87.28	81.22	88.05	86.53	82.17	84.36	87.62	88.77




图 9. 不同模型在休斯顿数据集上的分类图。(a) 地面真实值。(b) CALC。(c) GAMF。(d) GLTNet。(e) M2FNet。(f) MS2CANet。(g) S²ENet。(h) MFT。(i) ExViT。(j) HLMamba。(k) 所提方法。

通常难以区分。对于MUUFL数据集，所提方法在准确分类混合地面和建筑区域方面展现出明显优势。它能有效降低S²ENet和GLT等方法分类输出中的噪声，从而生成更连贯可靠的分类图。所提方法

在一致性识别较小类，如泥土和沙子以及建筑阴影方面也表现更优。这些类别常被其他方法误分类。

总体而言，所提方法构建的模型在全部三个数据集上均持续优于其他技术，尤其在<style id='33'>复杂<style id='35'>城市<style id='37'>与




图 10. 不同 模型 在 特伦托 数据集 上的 分类 地图。 (a) 地面 真实值。 (b) CALC。 (c) GAMF。 (d) GLTNet。 (e) M2FNet。 (f) MS2CANet。 (g) S²ENet。 (h) MFT。 (i) ExViT。 (j) HLMamba。 (k) 所提方法。

表 4
关于 数据 源 使用的 消融 研究 结果 （以 总体精度、<style id=’17’> 平均精度、<style id=’19’> κ 衡量）。

指标	休斯顿			Trento			MUUFL		
	OA (%)	AA (%)	$\kappa\times100$ (%)	OA (%)	AA (%)	$\kappa\times100$ (%)	OA (%)	AA (%)	$\kappa\times100$ (%)
Only HSI	91.87	92.32	91.17	96.76	94.88	95.56	89.11	89.88	94.31
Onl ^y ^{LID} AR	53.86	52.74	49.99	87.01	77.91	82.03	74.78	75.40	67.53
HSI+LiDA R	93.81	94.29	93.28	99.06	98.6	98.74	91.47	92.82	88.77

表 5
关于多模态特征融合块（MMFB）和CMFEB不同组合的消融 研究 结果 在 总体精度（OA）、 平均精度（AA） 和 κ 方面 在三个 数据集上的表现。

MMFB	CMFEB	休斯顿			Trento			MUUFL		
		OA (%)	AA (%)	$\kappa\times100$ (%)	OA (%)	AA (%)	$\kappa\times100$ (%)	OA (%)	AA (%)	$\kappa\times100$ (%)
	✓	92.86	93.43	91.87	98.96	98.65	98.83	90.88	92.44	88.24
✓		92.51	93.65	92.41	98.72	98.78	98.88	90.83	92.46	88.51
✓	✓	93.81	94.29	93.28	99.06	98.60	98.74	91.47	92.82	88.77

表 6
不同 方法 在 训练 时间(s)方面 跨 数据集 的 对比

Datasets	CALC	GAMF	GLTNet	M2FNet	MS2CANet	S²ENet	MFT	ExViT	HLMamb a	所提方法
Houston	362.5	1028.8	651.9	458.8	310.8	299.7	358.6	362.5	648.6	318.6
Trento	265.8	815.9	587.3	358.7	287.6	248.3	312.6	352.5	504.1	304.6
MUUFL	292.5	906.8	622	452.6	318.5	287.6	380.6	370.3	562.9	315.6

异质环境中表现突出。该模型能有效捕捉精细的空间与光谱特征，生成更精确且视觉连贯的分类图，与真值高度吻合。这充分证明了所提方法在处理多样化、高难度遥感数据时的鲁棒性与有效性。

5.6. 消融 研究

我们进行了消融实验，以评估两种异构数据源HS和激光雷达对分类任务的各自贡献（见表4）。根据提供的结果，在Houston数据集中，融合多源数据实现了93.81%的总体精度，显著优于仅使用HSI的91.87%和仅使用LiDAR的53.86%。在平均精度和 κ 方面也观察到了类似的提升。对于Trento数据集，融合策略的总体精度达到99.06%，较仅使用HSI的96.76%和仅使用LiDAR的87.01%有显著提高。MUUFL数据集也呈现出可比拟的趋势。总体而言，这些结果表明，融合HSI和LiDAR数据能有效发挥两种模态的优势，

使得 所有 数据集 上的 分类 性能 均 得到提升。这种 融合 方法 在 复杂 场景中 尤其 有益， 能 显著 提升 准确率和 鲁棒性 。

消融实验还突显了MMFB（多模态特征融合块）和CMFEB模块对模型在Houston、Trento和MUUFL数据集上整体性能的贡献（见表5）。单独考察MMFB时，性能有显著提升，尤其在Houston数据集上，OA增至92.86%，AA达93.43%， κ 提升至91.87%。类似地，Trento和MUUFL数据集使用该模块也表现出强劲结果，凸显其在跨模态特征融合中的有效性。同样，单独使用CMFEB模块也带来积极影响，在Houston数据集上OA达92.51%，Trento数据集达98.72%，MUUFL数据集达90.83%，AA和 κ 也相应提高。该模块特别擅长提取跨模态互补特征，增强模型区分不同类别的能力。这些发现清晰证明两个模块对整体性能都至关重要，各自具备独特优势。当二者协同工作时，




图 11. 不同模型在MUUFL 数据集上的分类 结果 对比。(a) 地面真值。(b) CALC。(c) GAMF。(d) GLTNet。(e) M2FNet。(f) MS2CANet。(g) S²ENet。(h) MFT<style id='74'>。<style id='76'>(i)<style id='78'> ExViT<style id='80'>。<style id='82'>(j)<style id='84'> HLMamba<style id='86'>。<style id='88'>(k)<style id='90'> 所提方法。

特征 融合 与 跨模态 提取 共同作用 使得 所有 数据集 取得 最高OA、AA 及 κ 值。因此，这两个 模块 的 协同作用 对于 最大化 模型 性能 至关重要。

6. 结论

本文首次尝试将Mamba架构应用于HSI与LiDAR数据的联合分类任务，其性能超越了当前最先进的基于CNN和基于Transformer的方法。具体而言，我们首先采用具有共享权重的双分支VSSB结构，独立捕获HSI和LiDAR的独特特征。该VSSB结构在保持线性计算复杂度的同时，具备建模全局特征的能力。这些处理后的特征随后通过CMFEB模块进行模态间充分交互，交互方式包括线性层、DWConv和CSSM结构。最终，特征嵌入被输入MMFB模块，模态特定特征在此获得二次增强。通过引入注意力机制筛选各模态显著信息，进一步提升了网络的判别能力。大量实验表明，所提模型在全部三个数据集上均取得了令人满意的分类性能。未来工作中，我们计划设计更高效的Mamba模块以充分挖掘HSI和LiDAR的特性差异，例如针对HSI复杂光谱波段开发专用光谱特征提取模块，以及构建专门处理LiDAR高程信息的模块。此外，我们还将把Mamba的高性能拓展至其他HSI相关任务，如高光谱变化检测、目标检测等下游任务。

CRediT 作者 贡献 声明

Yiyan Zhang: Writing – review & editing, Writing – original draft, Visualization, Validation, Software, Resources, Investigation, Formal analysis, Data curation, Conceptualization. **Hongmin Gao:** Validation, Supervision, Funding acquisition. **Zhonghao Chen:** Formal analysis, Data curation, Conceptualization. **Chenkai Zhang:** Visualization, Validation, Software. **Pedram Ghamisi:** Validation, Supervision. **Bing Zhang:**验证, 监督, 数据整理。

利益冲突 声明

作者 们 声明，他们 没有 已知 的 竞争 性财 务利益 或 个人 关系，这些 可能 影响 到 本文 所 报告 的 研究 成果。

致谢

作者感谢特伦托大学的Lorezone Bruzzone教授提供Trento数据集。本研究由国家自然科学基金委员会项目62071168资助，部分由江苏省自然科学基金项目BK20211201资助。

数据 可用性

数据 将 根据 请求 提供。

参考资料

- [1] J. Li, D. Hong, L. Gao, J. Yao, K. Zheng, B. Zhang, J. Chanussot, Deep learning in multimodal remote sensing data fusion: A comprehensive review, *Int. J. Appl. Earth Obs. Geoinf.* 112 (2022) 102926.
- [2] L. Fang, Z. Yang, T. Ma, J. Yue, W. Xie, P. Ghamisi, J. Li, Open-world recognition in remote sensing: Concepts, challenges, and opportunities, *IEEE Geosci. Remote. Sens. Mag.* 12 (2) (2024) 8–31.
- [3] L. Gómez-Chova, D. Tuia, G. Moser, G. Camps-Valls, Multimodal classification of remote sensing images: A review and future directions, *Proc. IEEE* 103 (9) (2015) 1560–1584.
- [4] P. Ghamisi, B. Rasti, N. Yokoya, Q. Wang, B. Hofle, L. Bruzzone, F. Bovolo, M. Chi, K. Anders, R. Gloaguen, et al., Multisource and multitemporal data fusion in remote sensing: A comprehensive review of the state of the art, *IEEE Geosci. Remote. Sens. Mag.* 7 (1) (2019) 6–39.
- [5] M. Appel, F. Lahn, W. Buytaert, E. Pebesma, Open and scalable analytics of large earth observation datasets: From scenes to multidimensional arrays using SciDB and GDAL, *ISPRS J. Photogramm. Remote Sens.* 138 (2018) 47–56.
- [6] X. Guo, J. Lao, B. Dang, Y. Zhang, L. Yu, L. Ru, L. Zhong, Z. Huang, K. Wu, D. Hu, et al., Skysense: A multi-modal remote sensing foundation model towards universal interpretation for earth observation imagery, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 27672–27683.
- [7] L. Zhang, L. Zhang, Q. Yuan, Large remote sensing model: Progress and prospects, *Geomat. Inf. Sci. Wuhan Univ.* 48 (10) (2023) 1574–1581.
- [8] S. Li, X. Kang, L. Fang, J. Hu, H. Yin, Pixel-level image fusion: A survey of the state of the art, *Inf. Fusion* 33 (2017) 100–112.
- [9] J.M. Bioucas-Dias, A. Plaza, G. Camps-Valls, P. Scheunders, N. Nasrabadi, J. Chanussot, Hyperspectral remote sensing data analysis and future challenges, *IEEE Geosci. Remote. Sens. Mag.* 1 (2) (2013) 6–36.
- [10] S. Mohla, S. Pande, B. Banerjee, S. Chaudhuri, Fusatnet: Dual attention based spectrospatial multimodal fusion network for hyperspectral and lidar classification, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2020, pp. 92–93.
- [11] J. González-Santiago, F. Schenkel, W. Gross, W. Middelmann, Deep self-supervised hyperspectral-Lidar fusion for land cover classification, in: *IGARSS 2023-2023 IEEE International Geoscience and Remote Sensing Symposium*, IEEE, 2023, pp. 5910–5913.
- [12] Y. Zhang, S. Xu, D. Hong, H. Gao, C. Zhang, M. Bi, C. Li, Multimodal transformer network for hyperspectral and LiDAR classification, *IEEE Trans. Geosci. Remote Sens.* 61 (2023) 1–17.

- [13] Y. Chen, Q. Yuan, Y. Tang, Y. Xiao, J. He, Z. Liu, SENSE: Hyperspectral video object tracker via fusing material and motion cues, *Inf. Fusion* 109 (2024) 102395.
- [14] E.A. Cloutis, Review article hyperspectral geological remote sensing: evaluation of analytical techniques, *Int. J. Remote Sens.* 17 (12) (1996) 2215–2242.
- [15] H. Gao, Y. Zhang, Y. Zhang, Z. Chen, C. Li, H. Zhou, A 3D-2D multibranch feature fusion and dense attention network for hyperspectral image classification, *Micromach.* 12 (10) (2021) 1271.
- [16] P. Ghamisi, R. Souza, J.A. Benediktsson, L. Rittner, R. Lotufo, X.X. Zhu, Hyperspectral data classification using extended extinction profiles, *IEEE Geosci. Remote. Sens. Lett.* 13 (11) (2016) 1641–1645.
- [17] Y. Zhang, T. Wang, C. Zhang, S. Xu, H. Gao, C. Li, A dual-branch siamese spatial-spectral transformer attention network for hyperspectral image change detection, *Expert Syst. Appl.* 238 (2024) 122125.
- [18] Y. Zhang, Y. Zhou, S. Xu, D. Hong, H. Gao, C. Li, Q. Zhong, B. Zhang, Depthwise separable convolutional autoencoders for hyperspectral image change detection, *IEEE Geosci. Remote. Sens. Lett.* 20 (2023) 1–5, <http://dx.doi.org/10.1109/LGRS.2023.3281335>.
- [19] Z. Chen, G. Wu, H. Gao, Y. Ding, D. Hong, B. Zhang, Local aggregation and global attention network for hyperspectral image classification with spectral-induced aligned superpixel segmentation, *Expert Syst. Appl.* 232 (2023) 120828.
- [20] Z. Chen, Z. Lu, H. Gao, Y. Zhang, J. Zhao, D. Hong, B. Zhang, Global to local: A hierarchical detection algorithm for hyperspectral image target detection, *IEEE Trans. Geosci. Remote Sens.* 60 (2022) 1–15.
- [21] Y. Chen, Y. Tang, X. Su, J. Li, Y. Xiao, J. He, Q. Yuan, PHTrack: Prompting for hyperspectral video tracking, *IEEE Trans. Geosci. Remote Sens.* (2024).
- [22] M. Jouni, M.D. Mura, P. Comon, Hyperspectral image classification based on mathematical morphology and tensor decomposition, *Math. Morphol. Theory Appl.* 4 (1) (2020) 1–30.
- [23] R.A. Borsoi, T. Imbiriba, J.C.M. Bermudez, C. Richard, J. Chanussot, L. Drumetz, J.-Y. Tourneret, A. Zare, C. Jutten, Spectral variability in hyperspectral data unmixing: A comprehensive review, *IEEE Geosci. Remote. Sens. Mag.* 9 (4) (2021) 223–270.
- [24] P.-A. Thouvenin, N. Dobigeon, J.-Y. Tourneret, Hyperspectral unmixing with spectral variability using a perturbed linear mixing model, *IEEE Trans. Signal Process.* 64 (2) (2015) 525–538.
- [25] D. Lee, M. Jung, W. Yang, A. Kim, LiDAR odometry survey: recent advancements and remaining challenges, *Intell. Serv. Robot.* 17 (2) (2024) 95–118.
- [26] Y. Shen, J. Huang, J. Wang, J. Jiang, J. Li, V. Ferreira, A review and future directions of techniques for extracting powerlines and pylons from LiDAR point clouds, *Int. J. Appl. Earth Obs. Geoinf.* 132 (2024) 104056.
- [27] Y. Chen, Q. Yuan, Y. Tang, Y. Xiao, J. He, T. Han, Z. Liu, L. Zhang, SSTtrack: A unified hyperspectral video tracking framework via modeling spectral-spatial-temporal conditions, *Inf. Fusion* 114 (2025) 102658.
- [28] B. Zhang, D. Wu, L. Zhang, Q. Jiao, Q. Li, Application of hyperspectral remote sensing for environment monitoring in mining areas, *Environ. Earth Sci.* 65 (2012) 649–658.
- [29] R. Rajabi, A. Zehtabian, K.D. Singh, A. Tabatabaenejad, P. Ghamisi, S. Homayouni, Hyperspectral imaging in environmental monitoring and analysis, 2024.
- [30] L. Centorame, A. Ilari, A. Del Gatto, E.F. Pedretti, A systematic review on precision agriculture applied to sunflowers, the role of hyperspectral imaging, *Comput. Electron. Agric.* 222 (2024) 109097.
- [31] B.G. Ram, P. Oduor, C. Igathinathane, K. Howatt, X. Sun, A systematic review of hyperspectral imaging in precision agriculture: Analysis of its current state and future prospects, *Comput. Electron. Agric.* 222 (2024) 109037.
- [32] J.M. Salcido, D.F. Laefer, Urban hyperspectral reference data availability and reuse: State-of-the-practice review, *Photogramm. Rec.* (2024).
- [33] S. Gakhar, K. Tiwari, Extraction of urban targets using fusion of spectral and shape features in AVIRIS-NG hyperspectral data: Use of hyperspectral data for detecting roads and roofs, in: *Advanced Geospatial Practices in Natural Environment Resource Management*, IGI Global, 2024, pp. 167–188.
- [34] H. Tang, Y. Chen, T. Wang, Y. Zhou, L. Zhao, Q. Gao, M. Du, T. Tan, X. Zhang, T. Tong, HTC-net: A hybrid CNN-transformer framework for medical image segmentation, *Biomed. Signal Process. Control.* 88 (2024) 105605.
- [35] X. Shu, J. Wang, A. Zhang, J. Shi, X.-J. Wu, CSCA U-net: A channel and space compound attention CNN for medical image segmentation, *Artif. Intell. Med.* 150 (2024) 102800.
- [36] A. Ben Saad, G. Facciolo, A. Davy, On the importance of large objects in CNN based object detection algorithms, in: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2024, pp. 533–542.
- [37] A.S. Sagor, Y. Chen, Y. Xie, H.S. Kim, MSA R-CNN: A comprehensive approach to remote sensing object detection and scene understanding, *Expert Syst. Appl.* 241 (2024) 122788.
- [38] A.K. Shukla, A. Shukla, R. Singh, Automatic attendance system based on CNN-LSTM and face recognition, *Int. J. Inf. Technol.* 16 (3) (2024) 1293–1301.
- [39] M. Rostami, A. Farajollahi, H. Parvin, Deep learning-based face detection and recognition on drones, *J. Ambient. Intell. Humaniz. Comput.* 15 (1) (2024) 373–387.
- [40] S. Zhang, X. Meng, Q. Liu, G. Yang, W. Sun, Feature-decision level collaborative fusion network for hyperspectral and LiDAR classification, *Remote. Sens.* 15 (17) (2023) 4148.
- [41] H. Gao, H. Feng, Y. Zhang, S. Xu, B. Zhang, AMSSE-net: Adaptive multiscale spatial-spectral enhancement network for classification of hyperspectral and LiDAR data, *IEEE Trans. Geosci. Remote Sens.* 61 (2023) 1–17.
- [42] Y. Chen, C. Li, P. Ghamisi, X. Jia, Y. Gu, Deep fusion of remote sensing data for accurate classification, *IEEE Geosci. Remote. Sens. Lett.* 14 (8) (2017) 1253–1257.
- [43] W. Han, W. Miao, J. Geng, W. Jiang, CMSE: Cross-modal semantic enhancement network for classification of hyperspectral and LiDAR data, *IEEE Trans. Geosci. Remote Sens.* (2024).
- [44] Z. Zeng, T. Song, X. Ma, Y. Jiu, H. Sun, Joint classification of hyperspectral and Lidar data using cross-modal hierarchical frequency fusion network, in: *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing*, ICASSP, IEEE, 2024, pp. 5390–5394.
- [45] F. Chen, Z. Luo, L. Zhou, X. Pan, Y. Jiang, Comprehensive survey of model compression and speed up for vision transformers, 2024, arXiv preprint arXiv: 2404.10407.
- [46] T. Lin, Y. Wang, X. Liu, X. Qiu, A survey of transformers, *AI Open* 3 (2022) 111–132.
- [47] S. Khan, M. Naseer, M. Hayat, S.W. Zamir, F.S. Khan, M. Shah, Transformers in vision: A survey, *ACM Comput. Surv.* 54 (10s) (2022) 1–41.
- [48] A.A. Aleissae, A. Kumar, R.M. Anwer, S. Khan, H. Cholakkal, G.-S. Xia, F.S. Khan, Transformers in remote sensing: A survey, *Remote. Sens.* 15 (7) (2023) 1860.
- [49] K. He, C. Gan, Z. Li, I. Rekik, Z. Yin, W. Ji, Y. Gao, Q. Wang, J. Zhang, D. Shen, Transformers in medical image analysis, *Intell. Med.* 3 (1) (2023) 59–78.
- [50] Y. Zhang, H. Gao, J. Zhou, C. Zhang, P. Ghamisi, S. Xu, C. Li, B. Zhang, A cross-modal feature aggregation and enhancement network for hyperspectral and LiDAR joint classification, *Expert Syst. Appl.* (2024) 125145.
- [51] S.K. Roy, A. Deria, C. Shah, J.M. Haut, Q. Du, A. Plaza, Spectral-spatial morphological attention transformer for hyperspectral image classification, *IEEE Trans. Geosci. Remote Sens.* 61 (2023) 1–15.
- [52] S.K. Roy, A. Deria, D. Hong, B. Rasti, A. Plaza, J. Chanussot, Multimodal fusion transformer for remote sensing image classification, *IEEE Trans. Geosci. Remote Sens.* (2023).
- [53] X. Zhao, M. Zhang, R. Tao, W. Li, W. Liao, L. Tian, W. Philips, Fractional Fourier image transformer for multimodal remote sensing data classification, *IEEE Trans. Neural Netw. Learn. Syst.* (2022).
- [54] K. Ding, T. Lu, W. Fu, S. Li, F. Ma, Global-local transformer network for HSI and LiDAR data joint classification, *IEEE Trans. Geosci. Remote Sens.* 60 (2022) 1–13.
- [55] J. Yao, B. Zhang, C. Li, D. Hong, J. Chanussot, Extended vision transformer (ExViT) for land use and land cover classification: A multimodal deep learning framework, *IEEE Trans. Geosci. Remote Sens.* (2023).
- [56] A. Gu, T. Dao, Mamba: Linear-time sequence modeling with selective state spaces, 2023, arXiv preprint arXiv:2312.00752.
- [57] R. Xu, S. Yang, Y. Wang, B. Du, H. Chen, A survey on vision mamba: Models, applications and challenges, 2024, arXiv preprint arXiv:2404.18861.
- [58] H. Zhang, Y. Zhu, D. Wang, L. Zhang, T. Chen, Z. Wang, Z. Ye, A survey on visual mamba, *Appl. Sci.* 14 (13) (2024) 5683.
- [59] X. Liu, C. Zhang, L. Zhang, Vision mamba: A comprehensive survey and taxonomy, 2024, arXiv preprint arXiv:2405.04404.
- [60] J. Yao, D. Hong, C. Li, J. Chanussot, Spectralmamba: Efficient mamba for hyperspectral image classification, 2024, arXiv preprint arXiv:2404.08489.
- [61] D. Liao, Q. Wang, T. Lai, H. Huang, Joint classification of hyperspectral and LiDAR data base on mamba, *IEEE Trans. Geosci. Remote Sens.* (2024).
- [62] J. Benediktsson, J. Palmason, J. Sveinsson, Classification of hyperspectral data from urban areas based on extended morphological profiles, *IEEE Trans. Geosci. Remote Sens.* 43 (3) (2005) 480–491.
- [63] M.D. Mura, J.A. Benediktsson, B. Waske, L. Bruzzone, Morphological attribute filters for the analysis of very high resolution remote sensing images, in: *2009 IEEE International Geoscience and Remote Sensing Symposium*, Vol. 3, IEEE, 2009, pp. III-97–III-100.
- [64] P. Ghamisi, R. Souza, J.A. Benediktsson, X.X. Zhu, L. Rittner, R.A. Lotufo, Extinction profiles for the classification of remote sensing data, *IEEE Trans. Geosci. Remote Sens.* 54 (10) (2016) 5631–5645.
- [65] B. Rasti, P. Ghamisi, J. Plaza, A. Plaza, Fusion of hyperspectral and LiDAR data using sparse and low-rank component analysis, *IEEE Trans. Geosci. Remote Sens.* 55 (11) (2017) 6354–6365.
- [66] X. Wu, D. Hong, J. Chanussot, Convolutional neural networks for multimodal remote sensing data classification, *IEEE Trans. Geosci. Remote Sens.* 60 (2021) 1–10.
- [67] X. Wang, J. Zhu, Y. Feng, L. Wang, MS2CANet: Multi-scale spatial-spectral cross-modal attention network for hyperspectral image and LiDAR classification, *IEEE Geosci. Remote. Sens. Lett.* (2024).
- [68] R. Hang, Z. Li, P. Ghamisi, D. Hong, G. Xia, Q. Liu, Classification of hyperspectral and LiDAR data using coupled CNNs, *IEEE Trans. Geosci. Remote Sens.* 58 (7) (2020) 4939–4950.

- [69] H.-C. Li, W.-S. Hu, W. Li, J. Li, Q. Du, A. Plaza, A 3 clnn: Spatial, spectral and multiscale attention convlstm neural network for multisource remote sensing data classification, *IEEE Trans. Neural Netw. Learn. Syst.* 33 (2) (2020) 747–761.
- [70] X. Zhao, R. Tao, W. Li, H.-C. Li, Q. Du, W. Liao, W. Philips, Joint classification of hyperspectral and LiDAR data using hierarchical random walk and deep CNN architecture, *IEEE Trans. Geosci. Remote Sens.* 58 (10) (2020) 7355–7370.
- [71] J.X. Yang, J. Zhou, J. Wang, H. Tian, A.W.C. Liew, LiDAR-guided cross-attention fusion for hyperspectral band selection and image classification, *IEEE Trans. Geosci. Remote Sens.* (2024).
- [72] K. Ni, D. Wang, Z. Zheng, P. Wang, MHST: Multiscale head selection transformer for hyperspectral and lidar classification, *IEEE J. Sel. Top. Appl. Earth Obs. Remote. Sens.* (2024).
- [73] Y. Liu, Y. Tian, Y. Zhao, H. Yu, L. Xie, Y. Wang, Q. Ye, Y. Liu, VMamba: Visual state space model, 2024, arXiv preprint [arXiv:2401.10166](https://arxiv.org/abs/2401.10166).
- [74] L. Zhu, B. Liao, Q. Zhang, X. Wang, W. Liu, X. Wang, Vision mamba: Efficient visual representation learning with bidirectional state space model, 2024, arXiv preprint [arXiv:2401.09417](https://arxiv.org/abs/2401.09417).
- [75] Y. Li, Y. Luo, L. Zhang, Z. Wang, B. Du, MambaHSI: Spatial-spectral mamba for hyperspectral image classification, *IEEE Trans. Geosci. Remote Sens.* (2024).
- [76] G. Wang, X. Zhang, Z. Peng, T. Zhang, X. Jia, L. Jiao, S2Mamba: A spatial-spectral state space model for hyperspectral image classification, 2024, arXiv preprint [arXiv:2404.18213](https://arxiv.org/abs/2404.18213).
- [77] S. Li, S. Huang, AFA-Mamba: Adaptive feature alignment with global-Local mamba for hyperspectral and LiDAR data classification, *Remote. Sens.* 16 (21) (2024) 4050.
- [78] T. Lu, K. Ding, W. Fu, S. Li, A. Guo, Coupled adversarial learning for fusion classification of hyperspectral and LiDAR data, *Inf. Fusion* 93 (2023) 118–131.
- [79] J. Cai, M. Zhang, H. Yang, Y. He, Y. Yang, C. Shi, X. Zhao, Y. Xun, A novel graph-attention based multimodal fusion network for joint classification of hyperspectral image and LiDAR data, *Expert Syst. Appl.* 249 (2024) 123587.
- [80] L. Sun, X. Wang, Y. Zheng, Z. Wu, L. Fu, Multiscale 3-d-2-d mixed cnn and lightweight attention-free transformer for hyperspectral and lidar classification, *IEEE Trans. Geosci. Remote Sens.* 62 (2024) 1–16.
- [81] S. Fang, K. Li, Z. Li, S²ENet: Spatial-spectral cross-modal enhancement network for classification of hyperspectral and LiDAR data, *IEEE Geosci. Remote. Sens. Lett.* 19 (2021) 1–5.