

HSI-MFormer: 集成Mamba和Transformer专家进行高光谱图像分类

严和, IEEE学生会会员, Bing Tu, IEEE高级会员, 刘波, IEEE会员, 李军, IEEE会士, 以及 Antonio Plaza, IEEE会士

摘要—高光谱图像 (HSI) 分类是众多遥感应用的基础, 能够对材料属性和环境条件进行详细分析。基于选择性状态空间模型 (SSM) 的Mamba (S6) 在长距离序列建模方面表现出色, 具有线性计算效率, 而基于自注意力机制 Transformer 则特别擅长捕捉短距离依赖关系。为利用这些模型的互补优势, 本文介绍了一种新型混合Mamba-Transformer框架 (HSI-MFormer), 有效探索高光谱数据的多尺度特性以进行 HSI 分类。首先, 开发了一个多尺度标记生成 (MTG) 模块, 将 HSI 立方体转换为不同尺度下的多个空间-光谱标记组。为充分捕捉细粒度多尺度空间-光谱模式, 设计了内部尺度 Transformer 专家 (ITE), 该专家结合分组自注意力操作, 在每个尺度下对标记组进行短距离序列建模。同时, 引入了跨尺度Mamba专家 (CME), 该专家集成了跨尺度序列化机制和双向Mamba模块, 用于长距离序列建模, 进一步探索不同尺度下标记组之间的交互和互补性。研究了多种混合策略以集成 ITE 和 CME, 以最大化其互补性, 包括并行、间隔和串行结构。大量实验表明, 所提出的 HSI-MFormer 显著优于基于 Transformer 和 Mamba 的最先进 HSI 分类方法。代码可在 <https://github.com/tubingnuist/HSI-MFormer> 获取。

索引词—高光谱图像 (HSI) 分类, Mamba, Transformer。

收到于2024年12月20日; 修订于2025年2月6日和2025年4月5日; 接受于2025年4月20日。发表日期2025年4月24日; 当前日期
版本 5 2025年5月。这项工作部分由国家自然科学基金资助 (项目编号 62271200), 部分由南京信息工程大学人才引进启动基金资助 (项目编号 2023r091)。(通讯作者: Tu Bing。)

何岩, Tu Bing, 和刘波在南京信息工程大学的光电学院、大气光电探测与信息融合国家重点实验室培育基地、江苏国际联合气象光子学与光电探测实验室以及江苏大气智能光电传感技术工程研究中心工作, 地址为中国南京 210044 (邮箱: 975861884@qq.com; tubing@nuist.edu.cn; bo@nuist.edu.cn)。

李军是地球科学学院计算机科学系的一员, 中国地质大学 (武汉), 中国430074 (电子邮件: lijuncug@cug.edu.cn)。
安东尼奥·普拉扎是赫斯珀斯光谱计算实验室、计算机与通信技术系、西班牙埃斯特雷马杜拉理工大学的一员, 10003 卡塞斯, 西班牙 (电子邮件: aplaza@unex.es)。

数字对象标识符 10.1109/TGRS.2025.3564167

YPERSPECTRAL 1. 引言

H 图像 (HSI) 分类已成为遥感领域的基本研究, 由 HSI 数据中丰富的光谱和空间信息驱动。通过分析电磁谱中数百个连续的光谱波段, HSI 分类能够在像素级别实现精确的物质识别, 捕捉成分和结构的细微变化。这项技术支撑了多种遥感应用, 范围从环境监测和精准农业 [1], [2], [3] 到城市规划 [4], [5] 和军事侦察 [6], [7]。

随着深度学习技术的进步, 卷积神经网络 (CNN) 在赫斯珀斯光谱分类 [8], [9], [10], [11], [12], [13] 中引起了广泛关注。胡等人 [14] 首次提出了一种层次化的1-D CNN 架构, 有效地捕获了高光谱数据沿光谱维度的特征。认识到赫斯珀斯光谱图像 (HSI) 中固有的强空间相关性, 李和权 [15] 引入了一种由多个2-D卷积层组成的上下文深度2-D CNN 架构。虽然这种方法有效地捕获了单个光谱带内的局部空间模式, 但它未能充分利用不同光谱带之间的相关性, 可能限制其利用赫斯珀斯光谱图像中丰富的光谱信息的能力。为了解决这一局限性, 哈米达等人 [16] 开发了一种能够通过多个堆叠的3-D卷积核捕获更复杂的时空表示的3-D CNN 架构。通过将赫斯珀斯光谱数据视为一个体积而不是一组独立的2-D图像, 3-D CNN 能够更好地捕获光谱带和空间结构之间的复杂交互, 特别是在空间和光谱特性都具有高变异性的场景中。此外, 罗伊等人 [17] 引入了一种混合光谱架构 (HybridSN), 该架构结合了多个时空3-D CNN 块和空间2-D CNN 块, 有效地捕获了细粒度的时空模式, 同时降低了计算复杂度。作为一种主要的骨干架构, 基于 CNN 的模型在局部特征提取方面表现出色; 然而, 它们通常面临捕获像素之间全局依赖关系的挑战。

受益于注意力机制, Transformer 架构逐渐展现出主导地位

1558-0644 © 2025 IEEE。所有权利均受保护, 包括文本和数据挖掘的权利, 以及人工智能的训练以及类似技术。个人使用是允许的, 但再出版/重新分发需要 IEEE 许可。

有关更多信息, 请参阅 <https://www.ieee.org/publications/rights/index.html>。
经授权的使用有限制于: CHONGQING UNIVER SITY. 于2025年8月22日 01:24:41 UT 下载 C f 来自 IEEE Xplore。适用限制。

HSI分类 [18], [19], [20], [21], [22], [23]。经典地, He等人 [24] 提出了一种双向编码器表示Transformer网络 (HSI-BERT)。基于多头自注意力 (MHSA) 机制, HSI-BERT能够学习多个注意力头来编码上下文感知的语义表示, 从而捕获判别性的时空谱特征。Hong等人 [25] 从光谱序列的角度重新考虑了HSI分类, 并开创性地构建了一个基于纯Transformer的光谱Former (SF) 网络。超越传统Transformer中的波段表示, SF致力于捕获相邻高光谱波段之间的光谱序列信息, 从而生成组状光谱嵌入。考虑到光谱数据的尺度相似性和各向异性图像特征, Hu等人 [26] 为HSI分类引入了一种新的多尺度多角度注意力网络 (MMAN)。该模型结合了多尺度CNN网络和多角度Transformer结构, 有效地对局部和全局尺度下的图像特征之间的内部关系进行建模。为了全面集成HSI分类的空间和光谱信息, Peng等人 [27] 引入了一种具有交叉注意力机制的双分支时空谱Transformer (CASST)。空间分支负责捕获细粒度的空间信息, 光谱分支专注于建立光谱序列之间的相互依赖关系。此外, He等人 [23] 研究了一种混合多尺度时空谱框架 (HMSSF)。它从时空域的多个尺度建模全局依赖关系, 实现了混合时空特征的协同提取, 用于HSI分类。尽管Transformer在捕获依赖关系方面已显示出显著的有效性, 但内在注意力机制的复杂度随序列长度呈平方级增长。因此, Transformer通常适用于建模短序列变化 [28], 而在长序列范围内则表现出明显的局限性。

最近, Mamba [29], 基于状态空间模型构建, 已成为序列建模的一种有前景的替代方案。通过结合选择机制和硬件感知实现, Mamba 实现了与序列长度成线性复杂度的扩展, 在与Transformer的长期建模性能方面表现出竞争力。受益于其建模能力和可扩展性, Mamba 架构已广泛应用于遥感应用, 包括HSI分类

[30], [31], [32], [33], [34], [35], [36], [37][38]。例如, Yang等人 [39] 提出了HSIMamba, 这是一个为高效HSI分类设计的新型框架。该模型受益于具有双向处理机制的状态空间模型 (SSM), 这使其能够从高光谱数据中高效提取光谱和空间特征, 同时保持计算效率。Li等人 [30] 提出了一种基于Mamba的新型图像级HSI分类模型, 命名为MambaHSI。为了全面利用空间和光谱信息, 该模型构建了一个空间和光谱Mamba块, 以分别对空间像素和光谱带之间的长程交互进行建模,

同时, 采用了一个空间-光谱融合模块来自适应地整合两个领域的信息。Yao等人 [40] 引入了SpectralMamba, 这是一个从序列建模角度解决光谱变化、冗余和计算效率挑战的高级HSI分类框架。该框架集成了分段顺序扫描 (PSS) 和门控空间-光谱合并 (GSSM), 以编码潜在的空间规律性和光谱特性, 生成鲁棒的判别性表示。Liu等人 [31] 引入了一种用于HSI分类的新型光谱-空间自适应Mamba (HyperMamba)。该模型集成了一个空间邻域自适应扫描 (SNAS) 模块和一个光谱自适应增强扫描 (SAES) 模块, 有效编码局部空间邻域信息和光谱特征, 增强了空间-光谱交互, 同时确保了计算效率。考虑到光谱数据的高维度, He等人 [32] 研究了一种用于全局光谱-空间关系建模的新型3D光谱-空间Mamba框架 (3DSS-Mamba)。引入了3D光谱-空间选择性扫描 (3DSS) 机制, 沿光谱和空间维度对3D高光谱标记进行逐像素选择性扫描, 并构建了五条扫描路径以研究维度优先级的影响。此外, Huang等人 [35] 探索了Mamba在HSI跨场景分类中的潜力。提出的动态标记增强Mamba (DTAM) 集成了一个动态标记增强模块和双向扫描机制, 有效捕获跨不同图像块的全局特征。

借鉴语言模型中混合架构的优势 [41], 这项工作提出了一种用于HSI分类的新型混合Mamba-Transformer架构HSI-MFormer。该框架由一个多尺度标记生成 (MTG) 模块、一个内尺度Transformer专家 (ITE)、一个跨尺度Mamba专家 (CME) 和一个分类器组成。具体来说MTG采用多尺度3-D卷积操作将HSI立方体转换为不同尺度上的多个空间-光谱标记组。这些组随后分别以内尺度和跨尺度的方式重塑为短序列和长序列。ITE结合了分组自注意力操作用于在每个尺度上标记组内的短序列建模有效地捕获多尺度空间-光谱模式同时最小化计算复杂度。CME基于SSM引入了一个双向Mamba块用于长序列建模进一步探索不同尺度上标记组之间的交互和互补性。研究了多种混合策略用于集成ITE和CME以最大化它们的互补性包括并行间隔和串行结构。据我们所知HSI-MFormer是首次尝试将Mamba和Transformer用于HSI分类。主要贡献总结如下。

- 1) A hybrid Mamba-Transformer architecture HSI-MFormer is proposed for HSI classification, which achieves multiscale spectral-spatial feature extraction




图1. MHSA 的架构。

通过利用Transformer和Mamba的短程和长程建模能力。

- 2) 研究了几种结合 ITE 和 CME 专家的混合策略。通过识别最佳混合结构，可以最大化 Transformer 和 Mamba 的互补优势。
- 3) 在四个公开的高光谱数据集（印度针叶林、帕维亚大学、休斯顿 2013 年和 WHU-Hi-LongKou）上进行的广泛实验验证了所提出方法的有效性和优越性。

本文的其余部分按以下顺序组织。第二节回顾了 Transformer 和 Mamba 的基础知识。第三节提供了所提出框架的全面描述。第四节概述了实验结果和分析。结论和未来工作在第五节讨论。

第二节. 基础知识

A. 多头自注意力

多头注意力机制的结构如图1所示。通过将输入标记投影到多个注意力头中，模型可以有效地捕获数据中的复杂依赖关系。假设输入特征矩阵表示为 $A \in \mathbb{R}^{H \times W \times C}$ ，其中 C 表示通道数， H 和 W 对应空间维度，首先对 A 应用线性变换以生成三个不同的矩阵：查询矩阵 Q 、键矩阵 K 和值矩阵 V ，如下所示：

$$Q = A \times W_Q, \quad K = A \times W_K, \quad V = A \times W_V \quad (1)$$

其中 W_Q 、 W_K 和 W_V 是维度为 $C \times d_k$ 的可学习权重矩阵， d_k 是注意力空间的维度。接下来，对这些转换后的特征 Q 、 K 和 V 执行自注意力计算过程，使用缩放点积注意力，可以表示为

$$SA = \text{Attention}(Q, K, V) = \text{SoftMax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (2)$$

MHSA机制涉及将多个权重矩阵 W_Q 、 W_K 和 W_V 映射到计算多头注意力值。每个头的注意力值是

独立计算的，然后所有头的输出沿着特征维度连接在一起。计算过程如下：

$$\text{MHSA}(Q, K, V) = \text{Concat}(SA_1, \dots, SA_i, \dots, SA_h)W \quad (3)$$

其中 h 是头的数量， W 表示学习的参数矩阵。

由于需要计算序列中所有元素之间的成对交互，自注意力机制相对于序列长度表现出二次计算复杂度。计算复杂度可以描述为

$$\text{Complex}(\text{MHSA}) = 4HWC^2 + 2(HW)^2C. \quad (4)$$

以注意力机制为核心组件，Transformer在处理长序列时不可避免地会面临巨大的计算和内存需求，这在需要高效建模扩展时间或空间依赖的应用中带来了挑战。

B. 状态空间模型

基于线性时不变系统的原理，状态空间模型（SSMs）被构建为通过中间隐藏状态 $h(t) \in \mathbb{R}^N$ 将一维输入信号 $x(t) \in \mathbb{R}$ 映射到输出序列 $y(t) \in \mathbb{R}$ 。这种转换可以通过以下线性常微分方程（ODE）进行数学描述：

$$\begin{aligned} h'(t) &= \mathbf{A}h(t) + \mathbf{B}x(t) \\ y(t) &= \mathbf{C}h(t) \end{aligned} \quad (5)$$

其中 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 是状态转换参数， $\mathbf{B} \in \mathbb{R}^{N \times 1}$ ， $\mathbf{C} \in \mathbb{R}^{N \times 1}$ 是投影矩阵。

为了将(5)中描述的连续时间系统集成到基于离散序列的深度模型中，连续参数 $\mathbf{A}$ 和 $\mathbf{B}$ 通过具有时间尺度参数 Δ 的零阶保持（ZOH）技术进行离散化。这个过程可以用以下数学表示：

$$\begin{aligned} \bar{\mathbf{A}} &= \exp(\Delta \mathbf{A}) \\ \bar{\mathbf{B}} &= (\Delta \mathbf{A})^{-1}(\exp(\Delta \mathbf{A}) - \mathbf{I}) \cdot \Delta \mathbf{B} \end{aligned} \quad (6)$$

其中 $\bar{\mathbf{A}}$ 和 $\bar{\mathbf{B}}$ 分别表示参数 $\mathbf{A}$ 和 $\mathbf{B}$ 的离散形式。随后，离散化 SSM 系统可以表示为

$$\begin{aligned} h_t &= \bar{\mathbf{A}}h_{t-1} + \bar{\mathbf{B}}x_t \\ y_t &= \mathbf{C}h_t + \mathbf{D}x_t. \end{aligned} \quad (7)$$

为了高效实现，上述线性递归过程通过以下卷积运算实现，该运算可以表示为：

$$\begin{aligned} \bar{\mathbf{K}} &= (\mathbf{C}\bar{\mathbf{B}}, \mathbf{C}\bar{\mathbf{A}}\bar{\mathbf{B}}, \dots, \mathbf{C}\bar{\mathbf{A}}^{L-1}\bar{\mathbf{B}}) \\ \mathbf{y} &= \mathbf{x} * \bar{\mathbf{K}} \end{aligned} \quad (8)$$

其中 L 表示输入序列的长度， $\mathbf{K} \in \mathbb{R}^L$ 作为结构化卷积核。

Mamba [29] 介绍了选择性SSMs（S6），这使得投影矩阵可以被修改为




图2. Mambablock的架构。

输入相关的, 以在每个序列单元上实现选择性注意力。这种结构如图2所示。具体来说, 它涉及定义区间 Δ , 以及矩阵B、C作为输入 $x \in \mathbb{R}^{B \times L \times D}$ 的函数, 这可以表示为

$$\begin{aligned} \mathbf{B} &= \text{Projection}_B(x) \\ \mathbf{C} &= \text{Projection}_C(x) \\ \Delta &= \tau_\Delta(\text{Parameter} + \text{Projection}_\Delta(x)) \end{aligned} \quad (9)$$

其中 $\mathbf{B} \in \mathbb{R}^{B \times L \times N}$, $\mathbf{C} \in \mathbb{R}^{B \times L \times N}$ 和 $\Delta \in \mathbb{R}^{B \times L \times D}$ 。函数 $\text{Projection}_B(\cdot)$ 和 $\text{Projection}_C(\cdot)$ 将数据线性投影到N维空间, 符号 τ_Δ 表示Softplus激活函数。

基于上述状态转换过程, Mamba表现出线性计算复杂度和选择性信息处理, 在长距离序列依赖建模方面具有显著优势。如 [42], 中所述, 计算复杂度可以表示为

$$\text{Complex(Mamba)} = 3L(2D)N + L(2D)N. \quad (10)$$

Mamba的计算复杂度与序列长度L呈线性关系。状态维度N是一个固定参数, 默认设置为16。

III. 提出的网络

所提出的用于HSI分类的HSI-MFormer的架构如图3所示, 它由一个MTG、一个ITE、一个CME和一个分类器组成。MTG处理裁剪的输入块, 将其转换为跨不同尺度的多个并行空间-光谱令牌组。ITE专家基于分组自注意力机制运行, 而CME专家采用双向SSM, 分别从短程和远程建模视角捕获多尺度空间-光谱信息。最后, 分类器整合了前序组件提取的互补信息以执行分类。

A. 多尺度令牌生成模块

传统的HSI分类方法通常在单一尺度内进行数据分词, 这不可避免地限制了模型捕捉多尺度空间-光谱细节和结构信息的能力。为了克服这一限制, 所提出的MTG模块集成了具有不同内核尺度的多个3-D卷积, 用于

MTG, 这些卷积随后被传输到Transformer和Mamba专家进行短程和远程空间-光谱特征提取。

如图3所示, MTG由三个并行的小、中、大尺度的3-D卷积组构成。每个组由一个3-D卷积层(3DConv)、一个批量归一化(BN)层和一个整流线性激活函数(ReLU)组成。以裁剪的HSI块x为输入, 该过程可表示为

$$\begin{aligned} f_S &= \text{ReLU}(\text{BN}(3\text{DConv}_{s \times s \times s}(x))) \\ f_M &= \text{ReLU}(\text{BN}(3\text{DConv}_{m \times m \times m}(x))) \\ f_L &= \text{ReLU}(\text{BN}(3\text{DConv}_{l \times l \times l}(x))) \end{aligned} \quad (11)$$

在 $s \times s \times s$, $m \times m \times m$, 以及 $l \times l \times l$ 分别表示对应于小、中和大卷积组的3-D核尺寸。所有组的卷积滤波器数量设置为32。

在每个卷积组之后, MTG进一步涉及一个用于维度转换的线性嵌入层。此过程可以表示为

$$\begin{aligned} T_S &= \text{Linear}(f_S) \\ T_M &= \text{Linear}(f_M) \\ T_L &= \text{Linear}(f_L) \end{aligned} \quad (12)$$

其中 T_S , T_M , 和 T_L 分别表示具有不同尺度的 $S \times S \times C$, $M \times M \times C$, 和 $L \times L \times C$ 生成的频谱-空间标记组。值得注意的是, 嵌入操作对每个组独立进行, 没有参数共享。

B. 内尺度 Transformer 专家

Transformer 利用自注意力机制来访问标记并建立依赖关系。虽然其二次计算复杂度给高效处理长序列任务带来了重大挑战, 但它对于短程依赖建模仍然具有优势。鉴于此, 所提出的ITE结合了分组自注意力策略, 在每个尺度上对标记组内的短程依赖建模, 在最小化计算复杂度的同时有效地捕获细粒度多尺度空间-频谱模式。

如图3所示, ITE不是将所有token组作为一个整体进行处理, 而是将不同尺度的每个token组视为一个独立的短序列, 在每个token组内独立执行标准自注意力计算。具体来说, 生成的token组 $T_S \in \mathbb{R}^{S \times S \times C}$, $T_M \in \mathbb{R}^{M \times M \times C}$ 和 $T_L \in \mathbb{R}^{L \times L \times C}$ 并行输入到分组MHSA模块进行短程依赖建模, 并结合残差操作。计算过程可以表示为

$$\begin{aligned} F_S &= T_S + \text{MHSA}_S(\text{LN}(T_S)) \\ F_M &= T_M + \text{MHSA}_M(\text{LN}(T_M)) \\ F_L &= T_L + \text{MHSA}_L(\text{LN}(T_L)) \end{aligned} \quad (13)$$

where $\text{LN}(\cdot)$ 指的是层归一化操作。 $\text{MHSA}_S(\cdot)$, $\text{MHSA}_M(\cdot)$ 和 $\text{MHSA}_L(\cdot)$ 表示标准




图 3. 混合 Mamba-Transformer 框架 (HSI-MFormer) 的整体架构, 以并行结构为例。

MHSA机制, 针对相应的token组进行定制, 详细的计算方法参考(3)。

之后, 所有组的输出特征按顺序连接起来, 以全面利用获得的信息, 如所表示的那样

$$F_{ITE} = \text{Concat}(F_S, F_M, F_L) \quad (14)$$

其中 $\text{Concat}(\cdot)$ 表示连接操作。然后, 主要使用 FFN 模块执行非线性变换, 增强模型的表示能力和性能

$$F_{ITE} = F_{ITE} + \text{FFN}(F_{ITE}) \quad (15)$$

其中 $\text{FFN}(\cdot)$ 表示由两个线性层和一个激活函数组成的前馈网络。

根据 (4), 当将 Transformer 应用于将所有标记组作为一个整体进行注意力计算时, 复杂度可以表示为:

$$\text{Complex}(T) = 4(S + M + L)^2 C^2 + 2(S + M + L)^4 C \quad (16)$$

这不可避免地会带来巨大的计算负担。

相比之下, ITE的计算复杂度被描述为分组注意力块的总和, 可以表示为

$$\begin{aligned} \text{Complex}(\text{ITE}) &= 4(S^2 + M^2 + L^2)C^2 \\ &\quad + 2(S^4 + M^4 + L^4)C. \end{aligned} \quad (17)$$

显然, 所提出的ITE显著降低了计算复杂度, 同时有效地实现了多尺度频谱-空间信息提取。

C. 跨尺度Mamba专家

最新的Mamba集成了一种选择性机制来保留相关信息并过滤掉无关信息, 从而实现无限期保留。这种具有线性复杂度特性的选择性机制允许Mamba保留重要的长期模式, 同时忽略瞬态波动 [43]。基于这种启发, 本文介绍了CME, 它执行长程序列建模, 以进一步探索

不同尺度下标记组之间的交互和互补性。

如图3所示, CME首先将所有标记组按分辨率顺序集成并展平为一个长程序列。考虑了正向和反向扫描方向, 以增强对空间感知处理的能力。以生成的标记组 $T_S \in \mathbb{R}^{S \times S \times C}$ 、 $T_M \in \mathbb{R}^{M \times M \times C}$ 和 $T_L \in \mathbb{R}^{L \times L \times C}$ 为输入, 展平过程可以表示为

$$\begin{aligned} S_{\text{Forward}} &= [T_S^1, \dots, T_S^{S^2}, T_M^1, \dots, T_M^{M^2}, T_L^1, \dots, T_L^{L^2}] \\ S_{\text{Backward}} &= [T_L^{L^2}, \dots, T_L^1, T_M^{M^2}, \dots, T_M^1, T_S^{S^2}, \dots, T_S^1] \end{aligned} \quad (18)$$

其中 $S_{\text{Forward}} \in \mathbb{R}^{C \times (S^2 + M^2 + L^2)}$ 表示生成的正向序列, 而 $S_{\text{Backward}} \in \mathbb{R}^{C \times (S^2 + M^2 + L^2)}$ 表示反向序列。

随后, 展平的序列被传输到一个双向 Mamba 模块中进行独立的远程序列建模。对于每个方向, 序列首先被归一化, 然后通过两个并行的线性嵌入层: 一个分支随后通过一个激活函数生成门控信号, 而另一个分支则进行一维卷积操作。假设 $S \in \{S_{\text{Forward}}, S_{\text{Backward}}\}$, 每个方向的步骤可以表示为

$$z = \sigma(\text{Linear}(\text{Norm}(S))) \quad (19)$$

$$f = \sigma(\text{Conv}(\text{Linear}(\text{Norm}(S)))) \quad (20)$$

其中 σ 表示 Silu 激活 [44] 操作。之后, 生成的表示 f 被输入到 S6 模型中进行状态空间演化, 随后进行层归一化和门控操作。最后, 特征被输入到带有残差连接的最终线性层

$$F = \text{Linear}(\text{Norm}(S6(f)) \otimes z) + S \quad (21)$$

其中 $\otimes$ 表示矩阵乘法操作。S6($\cdot$) 模型作为核心单元, 其具体计算参考(7)。

在并行顺序处理之后, 生成的特征 F_{Forward} 和 F_{Backward} 随后通过向量加法进行聚合, 得到最终输出作为

$$F_{\text{CME}} = F_{\text{Forward}} + F_{\text{Backward}} \quad (22)$$




图4. HSI-MFormer的混合结构。(a) 并行结构。(b) 间隔结构。(c) 串行结构v1。(d) 串行结构v2。

受益于跨尺度序列化策略和长程建模特性, 所提出的 CME 为高光谱数据提供了增强的感受野, 促进了具有线性计算复杂度的多尺度时空-光谱模式提取。

D. HSI-MFormer的混合结构

为了充分发挥 Transformer 和 Mamba 的互补优势, 本文研究了一系列结合 ITE 和 CME 层的混合结构, 如图 4 所示。

1) 并行结构: 在每个阶段, ITE和CME并行运行, 其输出通过直接相加融合。ITE和CME的深度均设置为 N 。因此, 该结构可以描述如下:

$$F_{i+1} = \text{ITE}(F_i) + \text{CME}(F_i) \quad \forall i = 1, 2, \dots, N. \quad (23)$$

2) 间隔结构: 在此配置中, ITE和CME以逐层交错的方式顺序堆叠, 可以表示为

$$F_{i+1} = \text{CME}(\text{ITE}(F_i)) \quad \forall i = 1, 2, \dots, N. \quad (24)$$

3) 串行结构V1: 在此结构中, ITE部署在最初的 N 层, 随后CME部署在接下来的 N 层。该过程可以描述为

$$F_{i+1} = \begin{cases} \text{ITE}(F_i), & \text{if } i \leq N \\ \text{CME}(F_i), & \text{if } N < i \leq 2N. \end{cases} \quad (25)$$

4) 串行结构 V2: 在此配置中, CME 和 ITE 专家的顺序被反转, 有 N 个连续的 CME 层面先于 N 个连续的 ITE 层面

$$F_{i+1} = \begin{cases} \text{CME}(F_i), & \text{if } i \leq N \\ \text{ITE}(F_i), & \text{if } N < i \leq 2N. \end{cases} \quad (26)$$

所提出的 HSI-MFormer 允许采用上述结构, 最终输出将发送到分类器进行最终分类

$$\text{pred} = \text{Classifier}(F_{\text{out}}) \quad (27)$$

其中 $\text{Classifier}(\cdot)$ 由一个嵌入维度为 32 的感知器层组成。分类使用交叉熵损失函数进行优化。实验部分全面评估了不同架构的性能。

IV. 性能评估

A. 数据集描述

为了展示所提出方法的有效性, 在四个公开的 HSI databases 上进行了广泛的实验比较: 印度针叶林、帕维亚大学、休斯顿 2013 年和 WHU-Hi-LongKou [45]。表 I 提供了关于训练集和测试集划分的详细信息。

1) 印度松树林: 该数据集由机载/可见光红外成像光谱仪 (AVIRIS) 于 1992 年在印第安纳州西北部的印度松树林上采集。光谱仪的波长范围从 0.4 到 2.5 μm 。去除水吸收通道后, 它包含 200 个光谱波段, 每个像素的空间分辨率为 20 m, 覆盖面积为 145×145 像素。共有 10249 个地面采样点, 代表 16 个不同的类别。

2) 帕维亚大学: 该数据集由反射光学系统成像光谱仪 (ROSIS) 在意大利北部帕维亚市上采集。光谱仪的成像波长范围从 0.43 到 0.86 μm 。去除 12 个噪声波段后, 它包含 103 个光谱波段, 每个像素的空间分辨率为 1.3 m, 覆盖面积为 610×340 像素。共有 42776 个标记的地面物体像素, 分为 9 个不同的类别。

3) Houston 2013: 该数据集由 ITRES CASI-1500 传感器在休斯顿大学校园上收集, 周边地区, 由 2013 年 GRSS 数据融合提供

表 I

类别名称, 印度松树、帕维亚大学、休斯顿 2013 年和 WHU-HI-LONGKOU 数据集上每个类训练集和测试集的样本数量

Indian Pines				Pavia University			Houston 2013			WHU-Hi-LongKou		
No.	Category	Train	Test	Category	Train	Test	Category	Train	Test	Category	Train	Test
1	Alfalfa	5	41	Asphalt	332	6299	Healthy grass	125	1126	Corn	345	34166
2	Corn-notill	143	1285	Meadows	932	17717	Stressed grass	125	1129	Cotton	84	8290
3	Corn-mintill	83	747	Gravel	105	1994	Synthetic grass	70	627	Sesame	30	3001
4	Corn	24	213	Trees	153	2911	Trees	124	1120	Broad-leaf soybean	632	62580
5	Grass-pasture	48	435	Painted metal sheets	67	1278	Soil	124	1118	Narrow-leaf soybean	42	4109
6	Grass-trees	73	657	Bare soil	251	4778	Water	33	292	Rice	119	11735
7	Grass-pasture-mowed	3	25	Bitumen	67	1263	Residential	127	1141	Water	671	66385
8	Hay-windrowed	48	430	Self-blocking bricks	184	3498	Commercial	124	1120	Roads and houses	71	7053
9	Oats	2	18	Shadows	47	900	Road	125	1127	Mixed weed	52	5177
10	Soybean-notill	97	875				Highway	123	1104			
11	Soybean-mintill	245	2210				Railway	123	1112			
12	Soybean-clean	59	534				Parking Lot 1	123	1110			
13	Wheat	20	185				Parking Lot 2	47	422			
14	Woods	126	1139				Tennis Court	43	385			
15	Buildings	39	347				Running Track	66	594			
16	Stone	9	84									
Total		1024	9225	Total	2138	40638	Total	1502	13527	Total	2046	202496

表 II

不同混合结构在所有数据集上关于 OA (%)、AA (%) 和 KAPPA (%) 的有效性分析

	Indian Pines			Pavia University			Houston2013			WHU-Hi-LongKou		
	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa
Parallel Structure	99.01	98.91	98.87	99.67	99.38	99.57	99.31	99.37	99.25	99.59	98.58	99.46
Interval Structure	98.85	98.63	98.68	99.57	99.21	99.43	99.26	99.36	99.20	99.54	98.41	99.41
Serial Structure v1	98.90	98.45	98.74	99.65	99.3	99.53	99.32	99.41	99.27	99.59	98.53	99.46
Serial Structure v2	98.87	98.30	98.71	99.4	98.86	99.21	99.26	99.41	99.27	99.51	98.34	99.35

竞赛。光谱仪的成像波长范围从0.38到1.05 μm 。该数据集包含144个光谱波段, 覆盖面积为 340×1905 像素, 空间分辨率为每个像素2.5米。它包括总共15029个样本像素, 分为15种具有挑战性的类型。

4) WHU-Hi-LongKou: 该数据集于 2018 年在中国湖北省龙口镇获取, 配备在 DJI Matrice 600 Pro (DJI M600 Pro) 飞行器平台上的一台 8 毫米焦距 Headwall Nano-Hyperspec 成像传感器。光谱仪的成像波长范围从 400 到 1000 纳米。它包含 270 个光谱波段, 覆盖面积为 550×400 像素, 空间分辨率为每像素 0.463 米。该数据集分为 9 个具有挑战性的物种: 玉米、棉花、芝麻、大豆、窄叶大豆, 水稻, 水, 道路和房屋, 以及混合杂草。

B. 实验设置

1) 评估指标: 遵循现有的HSI分类协议, 评估指标包括总体分类精度 (OA)、平均分类精度 (AA) 和 kappa系数 (Kappa), 用于评估。所有实验均在相同的实验条件下进行, 报告的结果是五次连续试验的平均值。

2) 实现细节: 所有实验均在PyTorch平台上使用单个RTX 3070Ti GPU实现。使用Adam优化器进行参数优化, 学习率为0.001。训练过程

运行100次迭代, 并选择第100次迭代的模型作为最优模型。批大小设置为64。裁剪的HSI图像块大小设置为 15×15 。PCA降维的维度设置为30。MTG中的核尺度s、m和l分别设置为9、7和5。Mamba分支中的状态维度和扩展率分别固定为16和1。

3) 竞争方法: 选择四种具有代表性的HSI分类架构进行综合比较, 包括传统方法 (SVM [46])、基于CNN的方法 (2D-CNN和3D-CNN [16])、基于Transformer的方法 (HSI-BERT [24], SF [25]和CASST [27])、基于Mamba的方法 (3DSS-Mamba [32], MambaHSI [30], 和HyperMamba [31])。

C. 分析不同的混合结构

本节探讨了所构建的四种混合结构的有效性, 包括并行结构、区间结构、串行结构 v1 和串行结构 v2。在三个数据集上的分类结果如图 II 所示。所有结构在分类性能上的突出表现突出了 HSI-MFormer 在有效整合 Mamba 和 Transformer 优势方面的优越性。

对于印度针叶林数据集, 所有混合结构都实现了高 OA, 其中串行结构v1实现了最高值98.90%, 其次是并行结构。在AA方面, 并行结构领先, 为98.66%, 而 Kappa系数在各个方法中相当, 其中串行结构v1表现略好。

表 III
在OA、AA、 κ 和印度针叶林数据集上比较方法的分类精度。最佳精度以粗体显示

Class	Conventional	CNN-based Methods		Transformer-based Methods			Mamba-based Methods			HSI-MFormer
	SVM	2D-CNN	3D-CNN	HSI-BERT	SF	CASST	3DSS-Mamba	MambaHSI	HyperMamba	
1	20.73	76.09	95.65	48.78	100.0	78.26	78.05	90.24	100.0	95.12
2	73.07	92.16	88.31	78.44	78.37	97.34	90.27	96.61	97.66	96.26
3	62.99	87.23	84.94	80.58	89.29	97.71	93.04	98.91	97.85	99.73
4	50.70	64.98	87.76	51.17	81.22	99.58	93.43	98.58	99.53	100.0
5	92.64	96.48	96.48	91.24	89.89	92.96	97.70	93.73	100.0	99.54
6	94.90	98.77	96.16	96.19	97.41	97.81	97.26	99.07	99.23	99.85
7	76.00	32.14	78.57	20.00	84.00	96.43	96.00	87.50	100.0	100.0
8	96.63	100.0	100.0	98.83	100.0	99.79	99.30	100.0	100.0	100.0
9	33.33	30.00	70.00	0.00	27.78	65.00	38.89	93.75	83.33	100.0
10	68.69	91.87	92.80	78.37	94.97	92.80	96.80	98.96	98.97	98.29
11	85.16	95.93	91.20	92.85	93.44	98.37	98.91	99.72	99.23	99.68
12	64.89	93.42	88.03	62.47	81.65	91.40	91.39	97.54	96.06	98.13
13	97.03	97.56	94.15	96.19	87.03	91.71	95.68	100.0	98.37	99.46
14	96.49	98.81	99.05	94.46	94.82	99.76	99.65	98.75	99.91	100.0
15	55.33	81.35	89.38	87.89	96.83	95.34	94.52	100.0	99.42	100.0
16	93.93	97.85	100.0	65.06	95.24	81.72	84.52	96.38	98.80	96.43
OA (%)	79.82	93.34	92.17	85.45	90.67	96.65	95.82	98.46	98.76	99.01
AA (%)	72.03	83.41	90.78	71.41	87.00	92.25	90.33	96.86	97.96	98.91
Kappa	76.84	92.39	91.08	83.36	89.36	96.18	95.23	97.66	98.59	98.87




图 5. 在印度针叶林数据集上比较方法得到的分类图。(a) 原始数据。(b) 参考图。(c) SVM。(d) 2D-CNN。(e) 3D-CNN。(f) HSI-BERT。(g) SF。(h) CASST。(i) 3DSS-Mamba。(j) MambaHSI。(k) HyperMamba。(l) HSI-MFormer。

在帕维亚大学数据集上，串行结构v1在OA (99.65%)、并且混合集成策略的鲁棒性，串行结构v1和并行结构在所有数据集上都始终取得具有竞争力的结果。并行结构紧随其后，其OA为99.64%，AA为99.28%，Kappa为99.52%，表明其在该数据集上的鲁棒性。

对于休斯顿2013数据集，序列结构v1实现了99.32%的最佳OA和99.27%的Kappa，而序列结构v1和v2实现了最高的AA。其他混合结构表现出轻微变化，但在所有指标上仍保持高性能。

在WHU-Hi-LongKou数据集上，并行结构在OA方面表现最佳 (99.59%)，AA (99.58%)，和 Kappa (99.46%)。TheSerial Structure v1 非常接近，这产生了一个略微较低的 AA 为 99.53%。这些结果展示了强大的性能

D. 与竞争方法的实验比较

印度Pines、帕维亚大学、休斯顿2013和WHU-Hi-LongKou数据集的定量精度 [OA (%), AA (%), 和 Kappa (%)] 总结在表 III–VI 中，最优结果以粗体突出显示。相应的分类图显示在图5–8中。

1) *Indian Pines Dataset*: The experiments on the Indian Pines dataset are performed with 10% of the reference samples. The corresponding quantitative classification accuracies and visualization are shown in Table III and Figure 5.

表 IV
在 Pavia 大学数据集上, 比较方法在 OA、AA、 κ 和每个类别的精度方面的分类精度。最佳精度以粗体显示

Class	Conventional	CNN-based Methods		Transformer-based Methods			Mamba-based Methods			HSI-MFormer
	SVM	2D-CNN	3D-CNN	HSI-BERT	SF	CASST	3DSS-Mamba	MambaHSI	HyperMamba	
1	91.63	96.31	95.94	97.63	94.75	99.17	99.33	99.87	99.55	99.32
2	97.56	99.37	99.71	99.93	98.14	99.95	99.34	99.97	100.0	100.0
3	73.90	82.22	89.76	86.51	84.70	98.28	95.09	99.59	98.19	98.90
4	92.10	94.35	97.36	97.53	96.81	93.08	95.91	96.87	98.45	99.11
5	98.51	99.85	100.0	99.61	99.22	98.66	99.69	100.0	100.0	99.77
6	86.04	93.65	97.41	93.05	94.37	99.60	99.43	100.0	100.0	100.0
7	84.09	89.17	96.69	95.80	84.56	99.62	95.88	99.84	100.0	100.0
8	90.25	88.73	93.92	97.86	92.65	94.73	96.20	98.81	98.62	99.43
9	99.22	97.57	100.0	99.67	100.0	96.41	97.22	98.31	98.44	97.89
OA (%)	92.75	95.77	97.62	97.61	96.60	98.63	98.48	99.58	99.56	99.67
AA (%)	90.37	93.47	96.75	96.40	93.91	97.72	97.56	99.25	99.25	99.38
Kappa	90.35	94.37	96.84	96.82	94.17	98.19	97.98	99.37	99.44	99.57




图 6。在 Pavia 大学数据集上, 比较方法获得的分类图。(a) 原始数据。(b) 参考图。(c) SVM。(d) 2D-CNN。(e) 3D-CNN。(f) HSI-BERT。(g) SF。(h) CASST。(i) 3DSS-Mamba。(j) MambaHSI。(k) HyperMamba。(l) HSI-MFormer。

如表III所示, 所提出的HSI-MFormer在现有的传统、基于CNN、基于Transformer和基于Mamba方法上表现出明显的优越性和有效性。与次优的HyperMamba方法相比, HSI-MFormer在OA、AA和Kappa上分别提高了0.25%、0.95%和0.28%。传统和基于CNN的方法, 如SVM和2D-CNN, 本质上受限于手工制作的描述符和局部感受野, 不可避免地受到特征提取能力有限和分类性能下降的限制。最近的基于Mamba的方法, 如

Mamba-HSI 和 HyperMamba, 通过构建空间 Mamba 和光谱 Mamba 算子的并行和串行组合, 分别执行光谱-空间特征提取。虽然这些方法比基于 Transformer 的方法表现出更具竞争力的性能, 但它们仍然劣于所提出的方法。这种现象可以归因于 HSI-MFormer 同时受益于 Mamba 和 Transformer 架构, 有效地利用长程和短程建模的优势来实现光谱-空间特征提取。此外, 如图 5 所示, 比较方法, 包括 SVM、2D-CNN、3D-CNN 和 HSI-BERT, 通常容易受到明显的噪声干扰。相比之下, 所提出的 HSI-MFormer 展现出良好维持的类别边界和最小的误标记, 进一步突显了所提出方法的优势。

表V
在OA、AA、 κ 和休斯顿2013数据集上比较方法的分类精度。最佳精度以粗体显示

Class	Conventional	CNN-based Methods		Transformer-based Methods			Mamba-based Methods			HSI
	SVM	2D-CNN	3D-CNN	HSI-BERT	SF	CASST	3DSS-Mamba	MambaHSI	HyperMamba	-MFormer
1	98.53	98.40	97.04	92.26	99.29	97.04	99.02	99.82	99.46	98.93
2	98.05	99.20	98.48	83.15	98.05	98.01	99.56	99.73	99.91	100.0
3	98.88	100.0	100.0	99.20	100.0	98.71	100.0	99.83	100.0	99.84
4	97.81	98.31	98.95	93.47	96.43	99.04	97.68	99.45	99.10	99.38
5	98.57	99.28	99.44	99.73	100.0	100.0	99.91	100.0	100.0	100.0
6	92.64	92.62	100.0	78.76	95.89	95.38	98.29	98.96	100.0	100.0
7	91.98	94.01	93.38	91.06	96.06	95.90	97.55	99.46	96.84	97.63
8	91.96	89.63	94.29	86.68	91.70	96.22	96.16	95.39	98.83	97.77
9	85.09	83.87	93.61	89.60	94.59	95.53	96.27	94.08	97.60	99.65
10	93.16	94.62	96.33	89.03	97.46	99.27	99.55	100.0	99.63	100.0
11	87.01	90.53	96.84	95.31	90.56	97.89	98.20	97.36	98.02	100.0
12	87.25	89.38	95.46	88.63	99.28	98.54	98.38	98.08	99.27	99.64
13	32.35	77.83	94.24	93.12	56.40	97.23	96.68	93.31	96.20	98.10
14	98.91	99.30	98.60	97.92	98.44	100.0	99.48	100.0	100.0	100.0
15	85.08	100.0	99.85	99.66	99.66	99.39	100.0	100.0	100.0	100.0
OA (%)	91.74	93.93	96.77	91.67	95.46	97.85	98.37	98.38	98.94	99.35
AA (%)	90.03	93.80	97.10	91.84	94.25	97.88	98.44	98.38	98.99	99.40
Kappa	91.06	93.44	96.51	90.99	95.09	97.68	98.24	100.0	98.85	99.30




图7. 在休斯顿2013数据集上比较方法获得的分类图。(a) 原始数据。(b) 参考图。(c) SVM。(d) 2D-CNN。(e) 3D-CNN。(f) HSI-BERT。(g) SF。(h) CASST。(i) 3DSS-Mamba。(j) MambaHSI。(k) HyperMamba。(l) HSI-MFormer。

在对比中，所提出的 HSI-MFormer 表现出良好维持的类别边界和最小的误标记，进一步突显了所提出方法的优势。

2) 佩扎亚大学数据集：在佩扎亚大学数据集上的分类实验使用5%的参考样本执行。与各种竞争方法的定量结果和可视化图分别见表IV和图6。通过结合Mamba和Transformer结构的优势，所提出的HSI-MFormer始终优于其他竞争方法，在所有方面均表现出最高值

三个指标。基于Transformer的架构，如CASST，受限于单一注意力机制，与混合HSI-MFormer相比，在OA、AA和Kappa上分别导致1.04%、1.66%和1.38%的显著精度下降。此外，依赖单一选择性SSM的Mamba基础框架，在复杂光谱-空间模式建模方面也表现出有限的建模能力。与次优HyperMamba相比，所提出的方法在OA、AA和Kappa上分别实现了0.11%、0.13%和0.13%的定量改进。根据图6中的可视化图，传统方法和基于CNN的方法都表现出明显的错分，这受限于手工制作的描述符和局部部

表 VI
在 WHU-HI-LONGKOU 数据集上, 比较方法在 OA、AA、 κ 方面的分类精度, 以及每个类别的精度。最佳精度以粗体显示

Class	Conventional	CNN-based Methods		Transformer-based Methods			Mamba-based Methods			HSI
	SVM	2D-CNN	3D-CNN	HSI-BERT	SF	CASST	3DSS-Mamba	MambaHSI	HyperMamba	-MFormer
1	99.17	99.92	99.33	99.94	99.80	99.46	99.85	99.63	99.97	99.97
2	81.44	94.18	93.32	93.40	91.35	99.42	99.64	99.17	99.39	99.69
3	55.56	86.47	92.41	94.00	89.20	98.80	96.70	91.45	99.83	96.86
4	97.34	98.68	98.60	99.58	99.07	99.39	98.95	99.39	99.74	99.80
5	55.66	76.02	91.61	86.10	87.34	99.03	96.37	99.33	98.73	99.19
6	98.95	99.44	98.35	99.84	98.73	98.57	98.88	99.93	99.81	99.76
7	99.94	99.96	99.74	99.99	99.78	99.98	99.94	99.82	99.95	99.95
8	85.32	90.87	90.81	90.98	93.25	94.97	96.91	94.74	97.17	96.04
9	79.35	83.87	89.90	92.77	89.16	86.90	93.90	96.07	90.03	95.90
OA (%)	95.60	97.88	98.14	98.71	98.25	99.06	99.16	99.23	99.49	99.59
AA (%)	83.64	92.16	94.90	95.18	94.19	97.39	97.90	97.72	98.30	98.58
Kappa	94.19	97.21	97.56	98.30	97.70	98.76	98.90	99.16	99.33	99.46




图 8. 在 WHU-Hi-LongKou 数据集上, 比较方法获得的分类图。(a) 原始数据。(b) 参考图。(c) SVM。(d) 2D-CNN。(e) 3D-CNN。(f) HSI-BERT。(g) SF。(h) CASST。(i) 3DSS-Mamba。(j) MambaHSI。(k) HyperMamba。(l) HSI-MFormer。

各自的核, 分别。相比之下, 所提出的方法实现了与真实值最一致的分类结果, 特别是在树木、沥青和自阻塞砖等类别中表现优异。这些现象进一步揭示了所提出的混合架构在 HSI 分类任务中的巨大潜力。

3) Houston 2013 数据集: 在 Houston 2013 数据集上的实验使用的是参考样本的 10%。分类结果和分类图示于表 V 和图 7。结果表明, 所提出的 HSI-MFormer 实现了 OA、AA 和 Kappa 为 99.35%、90.40% 和 90.30 %。尽管这个测试场景的复杂度增加且具有离散特性, HSI-MFormer 基于选择性 SSMs 和注意力机制, 进行长短期空间-光谱上下文建模, 展现出显著的性能优势

受其建模能力的限制, 经典的 HSI-BERT 不可避免地导致分类结果下降, 与 HSI-MFormer 相比, OA、AA 和 Kappa 分别减少了 7.68%、7.56% 和 8.31%。如图 7 中的可视化图所示, 所提出的 HSI-MFormer 进一步提供了最精确的预测细节, 展现出更优的对象完整性。这些实验结果表明, 所提出的方法有效地利用了 Transformer 和 Mamba 的互补优势, 显著增强了光谱-空间特征表示能力。

4) WHU-Hi-LongKou Dataset: Table VI and Fig. 8 present 相应的分类结果和可视化地图。在 WHU-Hi-LongKou 数据集上的实验使用的是 1% 的参考样本。如所示




图9. 所提方法对不同输入块大小的敏感性分析。

由结果可知, 所提出的HSI-MFormer实现了最高的OA、AA和Kappa, 分别为99.59%、90.58%和99.46%。由于特征提取的固有局限性, 传统方法和基于CNN的方法表现出相对较弱的性能。通过结合选择性SSMs和注意力机制的优势, HSI-MFormer优于基于Mamba和基于Transformer的方法。与次优的HyperMamba相比, 所提出的HSI-MFormer在OA、AA和Kappa上分别实现了0.10%、0.28%和0.13%的定量提升。如图8中的可视化地图所示, HSI-MFormer进一步提供了最准确的预测细节, 这与表VI中的定量结果一致。这些观察结果表明, 所提出的方法在高分辨率场景中仍保持其有效性和优越性。

E. 讨论与分析

1) 对不同输入块大小的敏感性: 进行消融实验以讨论不同输入块大小对分类性能的影响, 如图9所示。输入块范围从 11×11 到 19×19 , 增长间隔为 2。随着块大小的增加, 所有数据集都显示相似的趋势, 性能要么持续提升, 要么相对稳定。然而, 在达到识别点时, OA 会逐渐下降(对于休斯顿2013年、帕维亚大学和 WHU-Hi-LongKou数据集为 15×15 , 对于印第安纳州数据集为 17×17)。这种下降可能是由于块过大引入冗余或噪声, 导致信息混叠。尽管 17×17 对印第安纳州数据集的块大小证明是最优的, 但 15×15 仍然保持接近最优的性能。基于这些观察, 15×15 适合我们实验中的所有数据集。

2) 对不同嵌入维度和深度的敏感性: 进行消融实验以研究所提出的HSI-MFormer对阶段深度N和特征嵌入维度的敏感性。图10和图11展示了在三个数据集上OA (%)、AA (%) 和Kappa (%) 方面的性能变化。深度范围设置为{1, 2, 3, 4, 5}, 嵌入维度覆盖{8, 16, 32, 48, 64}的区间。如所观察, 较低的深度和

嵌入维度足以实现有前景的分类性能。相反, 过高的维度和更深的深度只能提供有限的精度提升。这种局限性可能归因于高光谱数据的样本量不足, 无法支持模型的学习能力, 并可能导致过拟合。因此, 所提出的 HSI-MFormer被构建为轻量级结构, 嵌入维度设置为 32, 阶段深度确定为3。

3) 对不同核尺度的敏感性: 核尺度

在MTG中对应不同的感受野, 允许用于捕获不同光谱-空间模式 [5, 7, 9]以4的尺度差异实现了在休斯顿2013年和 WHU-Hi-LongKou数据集上的优异性能。这种改进可能归因于尺度差异足够时增强的特征可区分性。这些发现表明, 具有较大尺度差异的配置对于复杂和高分辨率HSI场景相对有利, 这些配置可以在我们未来的工作中优先考虑。

为了探索更好的参数组合可能性, 我们进一步研究了 MTG对不同尺度配置的敏感性。如图12所示, 尺度差为 1的相邻尺度配置[3, 4, 5], 在所有数据集上都表现不佳。可能的原因是过相似的核尺度可能导致模型捕获冗余信息, 减少不同尺度提取特征的多样性和互补性。相比之下, 配置

[3, 7, 11] 以4个数量级的差异实现了卓越

以4的尺度差异实现了在休斯顿2013年和 WHU-Hi-LongKou数据集上的优异性能。这种改进可能归因于尺度差异足够时增强的特征可区分性。这些发现表明, 具有较大尺度差异的配置对于复杂和高分辨率HSI场景相对有利, 这些配置可以在我们未来的工作中优先考虑。

4) ITE 和 CME 的有效性: 本节系统地研究了 ITE 和 CME 专家的有效性。在三个数据集上的分类性能列于表 VII。可以看出, ITE 和 CME 各自独立都实现了显著的分类性能, 揭示了内在自注意力机制和 SSMs 的有效性。此外, 这两个专家的集成进一步增强了分类能力, 在所有数据集上都表现出强大的互补性和鲁棒性。这种改进可归因于混合架构能够结合 Transformer 和 Mamba 的优势, 从而有效地捕捉短程和远程的多尺度频谱-空间依赖性。通常, ITE 和 CME 都有助于分类, 并且所有这些组件共同在不同的场景下产生了最优越的结果。

5) MTG 的有效性: 本节系统地评估了有和没有 MTG 的分类性能




图 10. 所提出的方法在不同阶段深度方面的敏感性分析, 包括 (a)OA, (b) AA, 以及 (c) Kappa。




图 11. 所提出的方法在不同特征嵌入维度方面的敏感性分析, 包括 (a) OA, (b)AA, 以及 (c)Kappa。




图 12. 所提出的方法在不同尺度方面的敏感性分析, 包括 (a) OA, (b)AA, 以及 (c)Kappa。

在四个HSI数据集上的模块。OA、AA和Kappa的结果如图表VIII所示。“w/o MTG”指的是将s、m和的尺度设置为相同, 使模型在单一尺度内运行。与w/o MTG配置相比, 具有MTG的HSI-MFormer的分类性能表现出明显改进, OA平均提高了0.29%, AA平均提高了0.48%, Kappa平均提高了0.34%。通过在不同尺度上构建多个空间-光谱标记组, MTG使模型能够全面捕获不同粒度的光谱-空间细节和结构, 这对于解决高变异性复杂性的高光谱数据至关重要。这些结果突出了MTG模块在多尺度空间-光谱信息提取中的关键作用, 显著提高了模型在高光谱分类任务中的性能。

F. 对不同训练比例的敏感性

为了评估所提出的 HSI-MFormer 框架的鲁棒性, 通过改变

印度针叶林、帕维亚大学、休斯顿 2013 和 WHU-Hi-LongKou 数据集上训练样本的比例。图 13 展示了性能变化, 其中所提出的 HSI-MFormer 由红色曲线突出显示。四个数据集上选择的训练样本百分比覆盖区间为 $\{1.0\% \ 2.0\% \dots, 10.0\%\}$, $\{0.5\% \ 1.0\% \dots, 5.0\%\}$, $\{1.0\% \ 2.0\% \dots, 10.0\%\}$, 和 $\{0.1\% \ 0.2\% \dots, 1.0\%\}$, 分别。结果表明分类精度持续提高

HSI-MFormer 随着训练样本比例的增加。同时, HSI-MFormer 始终优于其他在大多数测试数据集的百分比上采用竞争性方法, 进一步突出了所提出的混合架构的鲁棒性和有效性。

G. 计算复杂度分析

如表IX所示, 研究了所提出的HSI-MFormer的计算复杂度, 重点关注模型参数、Flops、训练时间和测试时间。参数




图13. 在四个数据集上, 不同比例的标记数据对比较方法的分类性能。(a) 印度针叶林。(b) 帕维亚大学。(c) 休斯顿2013。(d) 武汉-黄鹤楼。

表VII

在OA (%), AA (%) 和 KAPPA (%) 方面对所有数据集的ITE 和 CME 的有效性分析

ITE	CME	Indian Pines			Pavia University			Houston2013			WHU-Hi-LongKou		
		OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa
✓		98.75	98.23	98.57	99.52	98.99	99.36	99.07	99.18	99.00	99.35	98.25	99.32
	✓	98.3	97.64	98.06	99.55	98.98	99.4	99.22	99.3	99.16	99.44	98.37	99.43
✓	✓	99.01	98.91	98.87	99.67	99.38	99.57	99.35	99.40	99.30	99.59	98.58	99.46

表VIII

在OA (%), AA (%) 和 KAPPA (%) 方面对所有数据集的MTG 的有效性分析

	Indian Pines			Pavia University			Houston2013			WHU-Hi-LongKou		
	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa
w/o MTG	98.54	98.18	98.33	99.38	98.67	99.18	99.05	99.16	98.98	99.48	98.33	99.32
HSI-MFormer	99.01	98.91	98.87	99.67	99.38	99.57	99.35	99.40	99.30	99.59	98.58	99.46

表IX

参数、FLOPS、训练时间和测试时间方面, 各种比较方法在计算复杂度上的分析

Metrics	CNN-based Methods		Transformer-based Methods			Mamba-based Methods			HSI-MFormer
	2D-CNN	3D-CNN	HSI-BERT	SF	CASST	3DSS-Mamba	MambaHSI	HyperMamba	
Params (M)	0.0132	0.0123	0.3773	0.1133	6.5316	0.0105	0.0370	0.0861	0.1322
Flops (G)	0.0002	0.0017	6.8135	0.0163	0.9893	0.0230	13.030	0.0031	0.0689
Training time (s)	4.47	4.02	62.13	97.28	45.82	168.85	233.61	20.12	81.26
Testing time (s)	0.34	0.44	20.18	2.4	2.62	3.95	0.02	1.54	3.89

是指整个网络中可学习参数的数量。Flops表示模型执行的浮点运算次数。尽管基于CNN的方法在参数数量、FLOPs以及训练和测试时间方面相对较少, 但它们捕获复杂空间-光谱信息的能力受限于局部感受野, 导致分类精度欠佳。基于Transformer的架构由于固有的MHSA机制导致二次计算复杂度, 导致更高的训练和测试时间 (例如, HSI-BERT的测试时间为20.18秒)。与双分支Transformer-based CASST相比, 所提出的HSI-MFormer显著减少了计算参数和Flops。基于Mamba的方法 (例如, MambaHSI、HyperMamba) 由于SSM的线性计算复杂度, 测试时间较低。更高的训练时间 (例如, MambaHSI为233.61秒) 主要源于较大的epoch设置和直接处理全局HSI数据而不是分块输入。相比之下, 所提出的HSI-MFormer结合了Transformer和Mamba专家的互补优势, 其计算复杂度略高于纯粹的Mamba-based

HyperMamba等。所有数据集的分类精度均有显著提升 (见表III-VI), 表明额外的计算成本是合理且可接受的。总之, 所提出的HSI-MFormer在计算效率和分类精度之间取得了极佳的平衡, 突出了其在HSI分类任务中的巨大潜力和优越性。

V. 结论

在本研究中, 我们提出了一种新颖的混合Mamba-Transformer 专家架构 HSI-MFormer, 该架构利用SSM和自注意力机制来捕获短程和长程依赖关系中的多尺度空间-光谱信息。基于Transformer的ITE在每个尺度上对标记组进行短程依赖建模, 有效地捕获细粒度的空间-光谱模式, 同时最小化计算复杂度。基于Mamba的CME专家专注于长程序列建模, 显著捕获跨不同尺度的标记组之间的互补性, 具有线性计算复杂度。大量实验

表明所提出的 HSI-MFormer 高效地突破了当前最先进 Transformer 和 Mamba 架构的性能和效率限制。未来的研究将集中于开发自适应策略, 以优化不同网络架构的集成, 并将它们的应用扩展到更具挑战性的场景。

参考文献

- [1] C. M. Gevaert, J. Suomalainen, J. Tang, and L. Kooistra, "Generation of spectral-temporal response surfaces by combining multispectral satellite and hyperspectral UAV imagery for precision agriculture applications," *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, vol. 8, no. 6, pp. 3140–3146, Jun. 2015.
- [2] C. Wang et al., "A review of deep learning used in the hyperspectral image analysis for agriculture," *Artif. Intell. Rev.*, vol. 54, no. 7, pp. 5205–5253, Oct. 2021.
- [3] B. Lu, P. Dao, J. Liu, Y. He, and J. Shang, "Recent advances of hyperspectral imaging technology and applications in agriculture," *Remote Sens.*, vol. 12, no. 16, p. 2659, Aug. 2020.
- [4] L. Ni, H. Xu, and X. Zhou, "Mineral identification and mapping by synthesis of hyperspectral VNIR/SWIR and multispectral TIR remotely sensed data with different classifiers," *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, vol. 13, pp. 3155–3163, 2020.
- [5] K. Siebels, K. Goita, and M. Germain, "Estimation of mineral abundance from hyperspectral data using a new supervised neighbor-band ratio unmixing approach," *IEEE Trans. Geosci. Remote Sens.*, vol. 58, no. 10, pp. 6754–6766, Oct. 2020.
- [6] J.-P. Ardouin, J. Lévesque, and T. A. Rea, "A demonstration of hyperspectral image exploitation for military applications," in *Proc. 10th Int. Conf. Inf. Fusion*, Jul. 2007, pp. 1–8.
- [7] S. Peyghambari and Y. Zhang, "Hyperspectral remote sensing in lithological mapping, mineral exploration, and environmental geology: An updated review," *J. Appl. Remote Sens.*, vol. 15, no. 3, Jul. 2021, Art. no. 031501.
- [8] Y. Chen, H. Jiang, C. Li, X. Jia, and P. Ghamisi, "Deep feature extraction and classification of hyperspectral images based on convolutional neural networks," *IEEE Trans. Geosci. Remote Sens.*, vol. 54, no. 10, pp. 6232–6251, Oct. 2016.
- [9] W.-S. Hu, H.-C. Li, L. Pan, W. Li, R. Tao, and Q. Du, "Spatial-spectral feature extraction via deep ConvLSTM neural networks for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 58, no. 6, pp. 4237–4250, Jun. 2020.
- [10] X. Ma, H. Wang, and J. Geng, "Spectral-spatial classification of hyperspectral image based on deep auto-encoder," *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, vol. 9, no. 9, pp. 4073–4085, Sep. 2016.
- [11] Z. Zhong, J. Li, D. A. Clausi, and A. Wong, "Generative adversarial networks and conditional random fields for hyperspectral image classification," *IEEE Trans. Cybern.*, vol. 50, no. 7, pp. 3318–3329, Jul. 2020.
- [12] M. E. Paoletti, J. M. Haut, R. Fernandez-Beltran, J. Plaza, A. J. Plaza, and F. Pla, "Deep pyramidal residual networks for spectral-spatial hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 57, no. 2, pp. 740–754, Feb. 2019.
- [13] M. Zhang, W. Li, Y. Zhang, R. Tao, and Q. Du, "Hyperspectral and LiDAR data classification based on structural optimization transmission," *IEEE Trans. Cybern.*, vol. 53, no. 5, pp. 3153–3164, May 2023.
- [14] W. Hu, Y. Huang, L. Wei, F. Zhang, and H. Li, "Deep convolutional neural networks for hyperspectral image classification," *J. Sensors*, vol. 2015, pp. 1–12, Feb. 2015.
- [15] H. Lee and H. Kwon, "Contextual deep CNN based hyperspectral classification," in *Proc. IEEE Int. Geosci. Remote Sens. Symp. (IGARSS)*, Jul. 2016, pp. 3322–3325.
- [16] A. Ben Hamida, A. Benoit, P. Lambert, and C. Ben Amar, "3-D deep learning approach for remote sensing image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 56, no. 8, pp. 4420–4434, Aug. 2018.
- [17] S. K. Roy, G. Krishna, S. R. Dubey, and B. B. Chaudhuri, "HybridSN: Exploring 3-D–2-D CNN feature hierarchy for hyperspectral image classification," *IEEE Geosci. Remote Sens. Lett.*, vol. 17, no. 2, pp. 277–281, Feb. 2020.
- [18] X. Yang, W. Cao, Y. Lu, and Y. Zhou, "Hyperspectral image transformer classification networks," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, 2022, Art. no. 5528715.
- [19] S. K. Roy, A. Deria, C. Shah, J. M. Haut, Q. Du, and A. Plaza, "Spectral-spatial morphological attention transformer for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 61, 2023, Art. no. 5503615.
- [20] J. Zhang, Z. Meng, F. Zhao, H. Liu, and Z. Chang, "Convolution transformer mixer for hyperspectral image classification," *IEEE Geosci. Remote Sens. Lett.*, vol. 19, pp. 1–5, 2022.
- [21] E. Ouyang, B. Li, W. Hu, G. Zhang, L. Zhao, and J. Wu, "When multigranularity meets spatial-spectral attention: A hybrid transformer for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 61, 2023, Art. no. 4401118.
- [22] Z. Li et al., "Supervised contrastive learning-based unsupervised domain adaptation for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 61, 2023, Art. no. 5524017.
- [23] Y. He, B. Tu, B. Liu, Y. Chen, J. Li, and A. Plaza, "Hybrid multi-scale spatial-spectral transformer for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5527918.
- [24] J. He, L. Zhao, H. Yang, M. Zhang, and W. Li, "HSI-BERT: Hyperspectral image classification using the bidirectional encoder representation from transformers," *IEEE Trans. Geosci. Remote Sens.*, vol. 58, no. 1, pp. 165–178, Sep. 2019.
- [25] D. Hong et al., "SpectralFormer: Rethinking hyperspectral image classification with transformers," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, 2022, Art. no. 5518615.
- [26] J. Hu, B. Tu, Q. Ren, X. Liao, Z. Cao, and A. Plaza, "Hyperspectral image classification via multiscale multiangle attention network," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5510718.
- [27] Y. Peng, Y. Zhang, B. Tu, Q. Li, and W. Li, "Spatial-spectral transformer with cross-attention for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, 2022, Art. no. 5537415.
- [28] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI*, Jun. 2023, vol. 37, no. 9, pp. 11121–11128.
- [29] A. Gu and T. Dao, "Mamba: Linear-time sequence modeling with selective state spaces," 2023, *arXiv:2312.00752*.
- [30] Y. Li, Y. Luo, L. Zhang, Z. Wang, and B. Du, "MambaHSI: Spatial-spectral mamba for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5524216.
- [31] Q. Liu, J. Yue, Y. Fang, S. Xia, and L. Fang, "HyperMamba: A spectral-spatial adaptive mamba for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5536514.
- [32] Y. He, B. Tu, B. Liu, J. Li, and A. Plaza, "3DSS-mamba: 3D-spectral-spatial mamba for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5534216.
- [33] Y. He, B. Tu, P. Jiang, B. Liu, J. Li, and A. Plaza, "IGroupSS-mamba: Interval group spatial-spectral mamba for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5538817.
- [34] A. Yang, M. Li, Y. Ding, L. Fang, Y. Cai, and Y. He, "GraphMamba: An efficient graph structure learning vision mamba for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5537414.
- [35] X. Huang, Y. Zhang, F. Luo, and Y. Dong, "Dynamic token augmentation mamba for cross-scene classification of hyperspectral image," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5539713.
- [36] D. Liao, Q. Wang, T. Lai, and H. Huang, "Joint classification of hyperspectral and LiDAR data based on mamba," *IEEE Trans. Geosci. Remote Sens.*, vol. 62, 2024, Art. no. 5530915.
- [37] H. Li, B. Tu, B. Liu, J. Li, and A. Plaza, "Adaptive feature self-attention in spiking neural networks for hyperspectral classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 63, 2025, Art. no. 5500915.
- [38] J. Sheng, J. Zhou, J. Wang, P. Ye, and J. Fan, "DualMamba: A lightweight spectral-spatial mamba-convolution network for hyperspectral image classification," *IEEE Trans. Geosci. Remote Sens.*, vol. 63, 2025, Art. no. 5501415.
- [39] J. X. Yang, J. Zhou, J. Wang, H. Tian, and A. W. C. Liew, "HSIMamba: Hyperspectral imaging efficient feature learning with bidirectional state space for classification," 2024, *arXiv:2404.00272*.
- [40] J. Yao, D. Hong, C. Li, and J. Chanussot, "SpectralMamba: Efficient mamba for hyperspectral image classification," 2024, *arXiv:2404.08489*.
- [41] J. Park et al., "Can mamba learn how to learn? A comparative study on in-context learning tasks," 2024, *arXiv:2402.04248*.
- [42] L. Zhu, B. Liao, Q. Zhang, X. Wang, W. Liu, and X. Wang, "Vision mamba: Efficient visual representation learning with bidirectional state space model," 2024, *arXiv:2401.09417*.

- [43] X. Xu et al., "SST: Multi-scale hybrid mamba-transformer experts for long-short range time series forecasting," 2024, *arXiv:2404.14757*.
- [44] S. Elfving, E. Uchibe, and K. Doya, "Sigmoid-weighted linear units for neural network function approximation in reinforcement learning," *Neural Netw.*, vol. 107, pp. 3–11, Nov. 2018.
- [45] Y. Zhong, X. Hu, C. Luo, X. Wang, J. Zhao, and L. Zhang, "WHU-hi: UAV-borne hyperspectral with high spatial resolution (H^2) benchmark datasets and classifier for precise crop identification based on deep convolutional neural network with CRF," *Remote Sens. Environ.*, vol. 250, Dec. 2020, Art. no. 112012.
- [46] F. Melgani and L. Bruzzone, "Classification of hyperspectral remote sensing images with support vector machines," *IEEE Trans. Geosci. Remote Sens.*, vol. 42, no. 8, pp. 1778–1790, Sep. 2004.



李军 (IEEE Fellow) 于2004年在中国湖南师范大学获得地理信息系统学士学位, 于2007年在中国北京获得北京大学遥感硕士学位, 并于2011年在葡萄牙里斯本的技术大学 (IST) 获得电气工程博士学位。

从2013年到2021年, 她担任中国广州中山大学正教授。自2022年起, 她担任中国武汉中国地质大学 (武汉) 正教授。她获得了多项国家级和国际级的重要资助项目。她撰写了160多篇期刊引证报告 (JCR) 文章、60篇国际会议论文和一本书的章节。

李博士自2021年起担任《应用地球观测与遥感专题期刊》主编。



Yan He (学生会员, IEEE) 于2020年从中国湖南长沙的湖南大学获得计算机科学硕士学位。她的研究方向是高光谱图像处理和遥感图像配准。



Bing Tu (高级会员, IEEE) 于2009年从中国广西桂林的桂林理工大学获得控制科学与工程硕士学位, 并于2013年从中国北京理工大学获得机电工程博士学位。

2015年至2016年, 他作为访问研究员在美国内华达大学里诺分校计算机科学与工程学院工作, 该工作由中国国家留学基金委资助。

他目前是南京信息科学和技术 (南京信息工程大学), 南京, 中国。稀疏表示、模式识别和 g.

刘波 (IEEE会员) 于2008年和2013年分别在北京邮电大学获得光学工程学士学位和博士学位。他目前是南京信息工程大学 (NUIST) 物理与光电学院教授。他的研究兴趣包括全光信号处理、光纤无线和宽带光通信。

大学...
他的研究兴趣包括
遥感分析

APPLIED EARTH OBSERVATIONS AND REMOTE SENSING



Antonio Plaza (IEEE Fellow) 于1999年和2002年分别从西班牙Extremadura大学的计算机与通信技术学院超光谱计算实验室获得理学硕士学位和博士学位。

他目前是Extremadura大学计算机与通信技术学院超光谱计算实验室的负责人。他已发表600余篇论文, 包括200余篇JCR期刊文章 (其中160余篇发表在IEEE期刊上)、23章书籍章节以及约300篇同行评审的会议论文。他的研究兴趣包括超光谱数据处理和遥感数据的并行计算。

Plaza博士曾是IEEE地球科学与遥感简报编辑委员会成员 (2011-2012年) 和IEEE地球科学与遥感杂志成员 (2013年)。他还担任过IEEE《应用地球观测与遥感专题期刊》(JSTARS) 指导委员会成员。他是IEEE Fellow, 因在超光谱数据处理和地球观测数据并行计算方面的贡献而获此殊荣。他于2009年获得IEEE地球科学与遥感快报最佳审稿人认可, 于2010年获得IEEE地球科学与遥感汇刊最佳审稿人认可, 并担任副主编 (2007-2012年)。他还获得了2015年IEEE信号处理杂志最佳专栏奖、2013年JSTARS期刊最佳论文奖以及2005-2010年《并行与分布式计算》期刊高被引论文奖。他在IEEE空间技术国际会议和IEEE信号处理与信息技术专题研讨会上获得最佳论文奖。他担任IEEE地球科学与遥感协会 (GRSS) 教育活动总监 (2011-2012年) 和西班牙GRSS分会主席 (2012-2016年)。他为50多种不同的期刊审阅了500余篇稿件。他担任IEEE地球科学与遥感汇刊主编 (2013-2017年)。他为不同期刊客座编辑了十期超光谱遥感专题。他还是IEEE ACCESS的副主编 (2017年获得杰出副主编认可)。更多信息请访问 <http://www.umbc.edu/rssipl/people/aplaza>。